

Real-is-Sim: 利用動態數位分身彌合虛實遷移差距 (Sim-to-Real Gap)

Jad Abou-Chakra ¹, Lingfeng Sun ¹, Krishan Rana ²,
Brandon May ¹, Karl Schmeckpeper ¹, Niko Suenderhauf ²,
Maria Vittoria Minniti ¹, Laura Herlant ¹
¹ 機器人與人工智慧研究所, ² 昆士蘭科技大學

摘要

我們推出了 real-is-sim, 這是一種將模擬整合到行為複製 (Behavior Cloning) 流程中的新方法。相較於缺乏部署前安全測試能力的純真實環境 (Real-only) 方法, 以及需要複雜適應過程來跨越虛實遷移差距的虛實遷移 (Sim-to-Real) 方法, 我們的框架允許策略在真實硬體執行與平行虛擬環境執行之間無縫切換。real-is-sim 的核心是由 Embodied Gaussian 模擬器驅動的動態數位分身, 它能以 60 Hz 的頻率與真實世界同步。這個分身充當了行為複製策略與真實機器人之間的媒介。策略使用源自模擬器狀態的表示法進行訓練, 且始終作用於模擬機器人, 而非真實機器人。在部署期間, 真實機器人僅需跟隨模擬機器人的關節狀態, 而模擬過程則會根據真實世界的測量數據不斷進行修正。在這種由模擬器驅動所有策略執行並與物理世界保持即時同步的架構下, 跨越虛實遷移差距的責任從策略本身轉移到了數位分身的同步機制上。我們在長程操作任務 (PushT) 上展示了 real-is-sim, 證明虛擬評估結果與真實世界的一致性。我們進一步展示了如何利用虛擬展開 (Virtual Rollouts) 來增強真實世界數據, 並比較了基於模擬器狀態衍生的不同表示法所訓練的策略, 包括物體位姿以及來自靜態和機器人搭載攝影機的渲染圖像。我們的研究結果突顯了 real-is-sim 框架在訓練、評估和部署階段的靈活性。影片請見 <https://real-issim.github.io>。

1 緒論

模擬環境是開發機器人操作策略 (policies) 的強大工具。它們提供了關鍵優勢, 例如持續的效能監控、大規模平行展開 (parallel rollouts)、對狀態資訊的完整存取, 以及對重置和環境變化的精確控制。這些特性使得在模擬中進行策略學習變得更加高效且實用。然而, 將這些優勢轉化到現實世界卻充滿挑戰。主要的困難在於確保策略在模擬和現實中的行為一致。這需要達成兩件事: 對齊策略在兩個領域中所見的輸入分佈, 並確保模擬機器人與真實機器人對相同的策略輸出做出相似的反應。要可靠地同時實現這兩點非常困難。

為了克服這項限制, 我們提出了 real-is-sim, 這是一種全新的範式。在這種範式中, 一個與現實世界持續同步的模擬器是行為複製 (behavior cloning) 策略的唯一介面, 且始終存在, 即使在現實世界執行期間也是如此。此範式由 Embodied Gaussians [1] 提供支援, 這是第一個透過整合 Gaussian splatting [2] 與基於粒子的物理學 (particle-based physics) [3], 以可泛化方式實現與物理環境即時同步的模擬器。該模擬器能夠建立物理系統的動態數位分身 (digital twin), 並可透過感測器回饋進行即時更新。策略是基於模擬器狀態所衍生的表示法進行訓練, 有效地將現實世界的互動重新定義為模擬體驗, 並統一了訓練與部署。




圖 1: real-is-sim 框架, 說明了其組件之間的資訊流。在可與現實世界同步的物理模擬器 [1] 中訓練的策略控制著一個模擬機器人。現實世界的觀測結果會持續更新模擬器, 使其狀態保持接近真實情況 (ground truth)。接著, 真實機器人會鏡像模擬機器人的關節位置。這種方法將 sim-to-real 的差距挑戰從策略轉移到了物理模擬器上。

Real-is-sim 的運作方式是在現實世界的互動過程中收集同步的模擬狀態，並將其作為策略訓練的示範軌跡。我們避免使用純模擬的示範，以確保所有軌跡都能反映真實機器人可以可靠執行的動作，同時保持模擬與現實世界的同步。這些策略在源自模擬器的表示法上運行，並為模擬機器人產生關節空間動作。此過程在兩種主要的運行模式中保持一致：(i) 部署在真實機器人上時，以及 (ii) 在虛擬環境中進行評估時。當連接到真實機器人時，物理機器人會鏡像模擬機器人的配置，而感測器數據則持續更新模擬器中物件的狀態。這種架構將策略與物理硬體解耦，確保策略始終在與訓練數據分佈相似的模擬器狀態下運行。Real-is-sim 範式實現了現實世界部署與虛擬評估之間的無縫切換，因為這兩種模式之間唯一的區別僅在於真實機器人跟隨行為 (follower behavior) 的啟動或停用。

透過維持即時的數位分身 (digital twin)，real-is-sim 框架統一了模擬與現實，實現了一致的策略執行、可擴展的離線評估以及靈活的表示學習。我們在 PushT 任務上的實驗展示了 real-is-sim 的三個關鍵應用：(i) 在與現實世界表現強烈相關的虛擬環境中實現快速的策略評估；(ii) 透過混合真實與模擬數據來支援數據增強，進而提升效能；以及 (iii) 識別最佳的模擬衍生表示法，以最大化任務成效。

2 預備知識

2.1 數位分身

real-is-sim 框架是圍繞著一個與現實世界保持同步的模擬器所建構的。這是透過 Embodied Gaussians [1] 實現的，該模擬器利用來自現實世界觀測的 RGB 回饋不斷進行自我修正。此系統使用兩個緊密耦合的組件來表示環境：

導向粒子 (Oriented particles)：捕捉物理屬性，如位置、旋轉、質量和半徑。這些是使用基於粒子的物理系統 [3] 進行模擬的。




圖 2：改編自 [1]。此圖說明了 Embodied Gaussians 如何利用物理粒子和視覺高斯 (Gaussians) 來表示世界。高斯透過真實的 RGB 影像進行修正，進而對粒子施加虛擬視覺力 (fictitious visual forces)，使模擬與現實世界保持一致。此改編版本強調了該機制如何整合至 real-is-sim 框架中。

3D 高斯 (3D Gaussians)：透過位置、旋轉、縮放、顏色和不透明度等參數對視覺外觀進行建模。這些是使用高斯潑濺 (Gaussian splatting) [2] 技術進行渲染的。

每個粒子都可以與多個 Gaussian 進行剛性連結，使物理與視覺表示能夠同步移動。當物理系統更新粒子時，附加的 Gaussian 也會隨之移動。Embodied Gaussians 的關鍵創新在於其基於光度誤差 (photometric error) 的修正機制。透過比較真實攝影機影像與渲染視圖，系統會計算作用於粒子上的虛擬視覺力。這些力會持續調整模擬，使其與現實保持一致。此修正迴圈以 60 Hz 的頻率執行，確保模擬器同時維持物理一致性與視覺準確性。圖 2 提供修正機制的說明，更多細節請參閱 [1]。

2.2 行為複製 (Behaviour Cloning)

在行為複製 (BC) 中，目標是學習一個由 θ 參數化的策略 π_θ ，該策略將時間步 t 的觀測值 o_t 映射到時界 H 內的一系列未來動作 $A_t = [a_t, a_{t+1}, \dots, a_{t+H-1}]$ 。給定一個包含 N 個專家演示的資料集 $\mathcal{D} = \{(o^i, A^i)\}_{i=1}^N$ ，其中 $o^i = \{o_1^i, \dots, o_T^i\}$ 是觀測序列，而 $A^i = \{a_1^i, \dots, a_T^i\}$ 是對應的動作序列，策略訓練旨在對條件分佈 $p(A_t | o_t)$ 進行建模。這通常透過最小化行為複製損失來實現：

$$\mathcal{L}_{BC}(\pi_\theta) = \mathbb{E}_{(o,A) \sim \mathcal{D}} [\|\pi_\theta(o) - A\|^2],$$

其中，策略預測的動作序列會根據其與專家提供動作序列的偏差而受到懲罰。

建模長時間跨度的動作序列 (temporally extended action sequences)，而非單步動作，能實現更平滑且更一致的控制 [4, 5]。我們的方法採用了條件流匹配 (Conditional Flow Matching, CFM) [6]，這是一種學習動作連續軌跡分佈的生成式建模方法。CFM 建模了一個以 o_t 為條件的向量場 $v^\theta(A_t^\tau | o_t)$ ，預測從零軌跡到地面真值 (ground-truth) A_t 之間路徑 A_t^τ 的中間速度。訓練目標是最小化條件流匹配損失 (conditional flow-matching loss)：

$$\mathcal{L}_{CFM} = \mathbb{E}_{\tau, p(A_t | o_t), q_\tau(A_t^\tau | A_t)} \|u(A_t^\tau | A_t) - v^\theta(A_t^\tau | o_t)\|^2,$$

其中 $\tau \sim \mathcal{U}(0, 1)$ 是均勻取樣的插值時間步長， $q_r(A_t^\tau | A_t)$ 定義了參考軌跡（例如：圍繞線性插值的高斯擾動），而 $u(\cdot)$ 則表示對應的 Ground-truth 速度。

3 方法

Real-is-sim 是一個將模擬器作為真實世界與學習策略（learnt policy）之間中介的框架。為了讓此方法奏效，模擬器必須根據真實世界的觀測結果不斷更新其狀態，進而與物理世界保持同步。在我們的研究中，我們使用 Embodied




圖 3：三種範式的比較：(a) Real-is-Sim、(b) Real-Only 以及 (c) Sim-to-Real，重點展示了它們在線上（真實世界互動）與離線（基於模擬）的能力。Real-is-Sim 提供了一個統一的框架，在虛擬環境中部署僅是真實世界部署的簡化版本，僅缺少即時修正，這確保了無縫的可轉移性。Real-Only 侷限於真實世界的執行。Sim-to-Real 則面臨分佈不匹配（distribution mismatch）與動力學差異（dynamics discrepancies）的挑戰，使得成功的轉移具有不確定性。

以 Gaussians 作為模擬器，因為它提供了即時對齊所需的必要機制。本節首先將框架正式化，接著詳細介紹完整的流程：建立場景、收集示範、訓練與部署策略，以及評估最終生成的策略。

3.1 框架

我們的框架由三個子系統組成：(i) 真實世界系統、(ii) 模擬器，以及 (iii) 學習後的策略（learned policy）。Real-is-sim 區分為兩種模式：在線（online）模式下，模擬器會與真實世界系統連接並保持同步；離線（offline）模式下，系統則完全在模擬環境中執行，並可進行平行化處理。我們在 Figure 3a 與 Figure 4 中展示了這些連接關係。

實體世界系統由一組輸出 RGB 影像（表示為 O_{rgb} ）的攝影機，以及一個高阻抗關節控制器組成，該控制器接收具有 d 個自由度之機器人的期望關節配置 $c \in \mathbb{R}^d$ 作為輸入。

模擬器在每個時間步 t 維持環境狀態 s_t 、模擬機器人狀態 r_t 、環境修正輸入 u_t 以及模擬機器人控制輸入 q'_t 。這些定義為

$$s_t = \{p_t^i, R_t^i, v_t^i, \omega_t^i\}_{i=1}^{N_{\text{obj}}}, \quad u_t = \{f_t^i, \tau_t^i\}_{i=1}^{N_{\text{obj}}}, \quad r_t = \{q_t, \dot{q}_t\}.$$

對於每個模擬物件 $i \in 1, \dots, N_{\text{obj}}$ ，其狀態由位置 $p \in \mathbb{R}^3$ 、朝向 $R \in SO(3)$ 、線速度 $v \in \mathbb{R}^3$ 和角速度 $\omega \in \mathbb{R}^3$ 描述。使模擬狀態與實體世界對齊的修正控制輸入，被計算為施加於每個物件的虛擬力 $f \in \mathbb{R}^3$ 和轉矩 $\tau \in \mathbb{R}^3$ 。對於模擬機器人，其狀態包括關節位置 $q \in \mathbb{R}^d$ 、關節速度 $\dot{q} \in \mathbb{R}^d$ 和期望關節配置 $q' \in \mathbb{R}^d$ 。下一個狀態 s_{t+1} 和 r_{t+1} 透過模擬器的物理步驟計算： $s_{t+1}, r_{t+1} = F(s_t, u_t, r_t)$ 。如果連接了實體世界系統，機器人的期望關節配置 c 在每個時間步被設置為 q_t ，且修正輸入 u_t 被設置為 $u_t = C(s_t, O_{\text{rgb}})$ ，其中 C 代表 Embodied Gaussians 中的修正機制（如圖 2 所示）。





圖 4：子系統之間的資訊流。

(a) Real-is-Sim - Real World Deployment (**Online Mode**)



(b) Real-is-Sim - Virtual Deployment (**Offline Mode**)



圖 5：Real-is-Sim 框架的兩種模式：真實世界部署與虛擬環境部署。

策略是一個函數 $\pi(r_t, q_t)$ ，將表示法 $r_t = g(s_t)$ 映射到軌跡 $a_{t:t+H} \in \mathbb{R}^{m \times (d+1)}$ ，其中 r_t 衍生自模擬器狀態 s_t ， m 是軌跡中的路徑點數量（也稱為動作層次，action horizon）。每個路徑點 a 包含一個期望的關節配置 $q' \in \mathbb{R}^d$ 以及對任務完成進度的估計 $p \in [0, 1]$ 。一旦計算出軌跡，模擬機器人將在時間層次 H 內遵循該軌跡，每隔 H/m 秒更新其期望的關節配置 $q'_{desired}$ ，以達到軌跡中的下一個路徑點 a 。在軌跡完成後，會生成一個新的軌跡。在我們的實作中，我們設定 $H = 1$ 秒且 $m = 32$ 。

3.2 流程 (Pipeline)

場景設置 我們按照 Embodied Gaussians 的程序建構環境。每個物體由 4 個視角生成，最終由一個位置 p 、一個旋轉 R 以及一組用於碰撞幾何的固定半徑球體來表示。視覺外觀則是透過將 Gaussians 附加到每個物體上來建模，並使用 Gaussian splatting [2] 進行優化。地面與機器人的幾何形狀及外觀則是手動指定的。

示範收集 (Demonstration Collection) 示範是透過 Embodied Gaussians 利用即時攝影機觀測值持續修正模擬狀態來收集的。在模擬器運行中進行收集，讓使用者能監控同步品質並調整其示範動作以維持同步。為了提高同步效果，在示範過程中，我們透過讓機器人本體避開攝影機視野來減少遮擋、在未接觸物體時快速移動、在互動期間減速，並在物體邊緣周圍保持充足的間隙。在每次示範中，我們以 60 Hz 的頻率記錄完整的模擬狀態序列。雖然模擬建模了豐富的物理屬性，但隨時間變化的只有物體姿態和機器人關節配置；所有其他物理參數僅初始化一次並保持不變。同樣地，視覺狀態 (Gaussians) 僅儲存在初始時間步。靜態參數的完整列表請參見 [7]。

策略訓練 (Policy Training) 我們的策略輸出一個動作軌跡 $a_{t:t+H}$ ，其中每個路徑點包含一個目標關節配置 $q' \in \mathbb{R}^d$ 和一個純量進度值 $p \in [0, 1]$ 。進度值代表任務的相對完成度，並根據示範中經過的時間進行標記，假設所有示範都在目標位置結

束。此啟發式方法已在 [8] 中得到驗證，使我們能夠在不手動設計獎勵函數的情況下評估策略。策略以機器人當前的關節配置 q_t 為條件。對於基於物體狀態的策略，我們額外以物體的姿態為條件，由位置和四元數¹表示。對於基於影像的策略，我們使用 ResNet 將渲染影像編碼為 64 維向量。Embodied Gaussians 能夠從任意視角渲染影像，從而建立虛擬攝影機。用於條件約束的表示法（包括物體姿態和渲染影像）如圖 6 所示。

策略部署 (Policy Deployment) 在部署期間，模擬器與真實機器人同步運行，以確保其與物理世界保持同步。訓練好的策略處理模擬器的狀態，並輸出模擬機器人的目標關節配置。這意味著策略是在與訓練時相同類型的輸入下運作，控制模擬機器人的方式與示範收集期間相同。與真實世界系統的整合是透過




圖 6: Real-to-Sim 框架的表示法與真實影像基準的比較：(a) 基於狀態的表示法（物體位置與方向），(b) 機器人末端執行器上的虛擬攝影機，(c) 真實攝影機位置處的虛擬攝影機，(d) 真實攝影機影像，用於修正模擬，但不作為策略的直接輸入。

兩個關鍵機制：(1) 來自真實世界攝影機的 RGB 影像會持續輸入系統，為模擬物件的狀態提供即時修正。這種回饋機制使模擬器能夠不斷調整，並讓模擬環境與真實世界保持一致。(2) 真實機器人的關節控制器被配置為跟隨模擬機器人的關節位置 q （而非目標關節 q' ）。這種讓真實機器人作為跟隨者的設計選擇，實現了在真實機器人操作與純虛擬環境操作之間的平滑切換。

策略評估 (Policy Evaluation) 透過停用真實世界耦合與修正力計算 (u_t)，相同的設置即可用於純虛擬環境。這使得環境易於平行化，進而實現快速的策略評估。在虛擬部署中，當同時執行 20 個環境時，根據所選的策略表示方式，我們可以獲得 5 到 8 倍的加速。

4 實驗

實驗設置 我們在 PushT 任務上評估我們的框架：這是一個長程任務，機器人使用推桿將 T 形物體移動到預定位置。T-Block 的幾何形狀（表示為附著在單一主體框架上的一組球形形狀）是使用 Embodied Gaussians [1] 的方法自動生成的。我們使用三台 RealSense D455 攝影機，以 90 fps 的幀率和 420×270 的解析度運行。機器人網格 (mesh) 是已知的，而地面則是從攝影機生成的點雲中估算出來的。附著在機器人、桌面和 T-Block 上的高斯分佈 (Gaussians) 是使用 [1] 中概述的 Gaussian Splatting 程序學習一次，並在各個實驗中重複使用。

對於基於物件狀態的策略，我們使用編碼為平移向量 $\mathbf{p} \in \mathbb{R}^3$ 與單位四元數 $\mathbf{R} \in \mathbb{SO}(3)$ 的物件位姿。對於基於影像的策略，我們使用由 ResNet [5] 輸出的 64 維特徵向量，該網路與策略共同訓練。輸入至 ResNet 的影像是從模擬環境中，利用 Gaussian Splatting 從虛擬

Offline vs Online Policy Evaluation




圖 7：模仿學習策略的成功率與訓練步數的關係，並比較了在真實環境與虛擬環境中的評估結果。兩條曲線之間的一致性顯示，速度較快的純虛擬評估是真實世界測試的可靠替代指標，為策略評估提供了一個實用的選擇。誤差線代表 95% 的信心區間。




圖 8：(a) 不同示範收集策略的成功率。(b) 使用不同表示法來調節 Flow Matching 策略的成功率。誤差線為 95% 的信心區間。

攝影機渲染而成。這些攝影機可以放置在任何位置。在我們的實驗中，我們使用了一個放置在與真實攝影機相同位置的靜態攝影機，以及一個安裝在模擬機器人末端執行器上的虛擬夾爪攝影機（如圖 6 所示）。

為了評估 PushT 任務的策略成功率，我們在桌面上定義了 20 個不屬於示範集的起始姿勢。在真實世界的測試中，成功與否取決於策略是否能將 T-Block 從這些姿勢移動到目標位置。每個姿勢測試三次，每次成功率評估共計 60 次測量。在純虛擬測試中，當策略輸出的進度值 (progress value) 超過 0.9 時即判定為成功，此策略已在 [8] 中得到驗證，可作為衡量成功的良好指標，且無需設計複雜的獎勵值 (reward values)。

離線評估 (Offline Evaluation)：在此實驗中，我們展示了 real-is-sim 的離線模式如何促進策略訓練與評估。模仿學習 (imitation learning) 中的一個關鍵挑戰在於選擇最佳的部署檢查點 (checkpoints)。這種困難源於行為複製 (behavior

cloning) 中所使用的損失函數 (loss) 並不能可靠地反映策略性能，且真實世界的機器人評估需要耗費大量的時間與資源。因此，研究人員通常預設使用最終的訓練檢查點，儘管這並非最佳選擇。

我們證明了 real-is-sim 的離線模式能透過快速評估實現高效的檢查點選擇。針對一個基於狀態 (state-based) 並在 30 個示範上訓練的策略，我們實作了一個訓練 50,000 步的 flow-matching 策略 (圖 7)。接著，我們比較了兩種評估方法：(i) 僅在虛擬世界中評估 (未連接真實機器人且未啟動修正機制) 以及 (ii) 真實世界的線上評估。我們的純虛擬方法使用與真實世界評估相同的測試案例來初始化環境。純虛擬評估透過策略回報的進度來計算成功率。雖然我們使用此指標是為了保持通用性，但從業者可以針對其特定任務實作更複雜的獎勵函數。

我們選擇了四個具代表性的檢查點 (10k、15k、25k、50k) 進行真實世界評估，並利用更快速的離線評估進行了更全面的分析。圖 7 顯示，雖然絕對性能可能有所不同，但檢查點的相對排序是一致的——這使得離線評估成為一種實用的工具，能在幾分鐘而非幾小時內選出高性能策略。值得注意的是，後期的檢查點並不一定優於前期的檢查點，這顯示從業者可以利用離線評估來進行提前停止 (early stopping) 或選擇最佳檢查點。雖然本實驗在兩種評估模式中使用相同的初始狀態以建立相關性，但在實際應用中，訓練階段的評估可以從隨機初始狀態中獲益。

離線數據收集與增強 在本實驗中，我們展示了如何利用 real-is-sim 的離線模式來收集額外的演示數據，以提升任務效能 (圖 8)。我們使用在連線模式下收集的 30 份真實世界演示數據來訓練一個基於狀態的策略 (state-based policy)，其成功率約為 57%。我們也利用

僅使用模擬器 (離線模式) 來增強真實世界的演示數據。為了收集額外的演示，我們將此策略以離線模式部署在多個平行環境中，並識別出策略陷入局部最小值 (local minima) 的失敗狀態。接著將這些失敗狀態呈現給使用者，以便針對這些具挑戰性的配置額外提供 30 份解決任務的演示。透過結合原始的 30 份真實世界演示與 30 份新的模擬演示，我們重新訓練策略，並觀察到成功率顯著提升至 80%。

最後作為基準測試，我們也收集了 30 份僅在模擬環境中的演示。產生的純模擬策略在部署期間達到了相似的成功率。僅離線策略的成功率與在真實演示上訓練的策略相當。這主要歸功於 PushT 任務的運動學特性，這意味著成功的策略執行主要取決於姿勢而非動力學效應。這正是 Embodied Gaussians 在部署時可以輕易修正的部分。

本實驗突顯了 real-is-sim 離線模式一個簡單但強大的應用。使用 real-is-sim 模擬器來增強策略訓練數據的成本，遠低於在真實世界中進行。作為對比，我們也使用在沒有增強的情況下收集的 60 份真實世界演示來訓練策略。有趣的是，這種方法產生的效能提升與增強後的數據集相似，強調了 real-is-sim 離線模式在高效增強策略訓練方面的有效性。

表示彈性 real-is-sim 離線模式的另一個主要優點，在於能從 Embodied Gaussians 模擬中提取多樣化表示的彈性。例如，它允許存取在現實世界中難以取得的特權資訊 (privileged information)，例如精確的物體位姿 (object poses)。此外，虛擬攝影機可以在系統中自由定位，有助於從多個視角進行視覺運動策略 (visuomotor policy) 學習。在我們的實驗中，我們證明了利用不同表示 (包括基於狀態的物體位姿、安裝在夾爪上的虛擬攝影機以及靜態虛擬攝影機) 的策略都能成功解決任務 (圖 8b、圖 6)。值得注意的是，這些方法的效能與僅依賴現實世界影像和機器人動作的基準策略相當，在某些情況下甚至更為優異。

有趣的是，使用夾爪虛擬攝影機的策略在所有表示中達到了最高效能 (82%)。該策略還展現出一些行為，例如當 T 型塊離開攝影機視野時會主動尋找 (請參閱我們網站上的影片)。這些發現與先前強調在某些情境下腕部攝影機優於靜態攝影機的研究結果一致 [9]。在 real-to-sim 框架內，我們可以系統地評估不同的虛擬攝影機配置 [10] 及其對策略學習的影響——這一切都使用同一組示範資料。這種彈性使我們能夠在離線模式下為給定的操作任務識別出最佳表示，並將其無縫部署到在線執行中。

5 相關工作

現實世界策略評估的局限性：直接在現實世界中評估機器人策略雖然可靠，但存在勞動力密集、耗時 [11, 12] 等缺點，且由於手動流程而面臨擴展性瓶頸 [13]。因此，研究人員探索利用模擬進行更安全、可重複且具擴展性的評估 [14, 15, 16, 17]，通常專注於提高模擬保真度 [14, 17, 16, 15]。我們的框架與此方法不同，它在整個策略生命週期 (訓練、評估、部署) 中整合了一個持續同步的模擬器。這種透過感測器數據進行的即時對齊，使得模擬訓練的策略無需進一步微調即可直接部署，並確保了統一的觀測與控制空間，以實現具擴展性的評估。

解決機器人操作中的虛實轉移差距 (Sim-to-Real Gap)：模擬環境為現實世界的評估提供了一個具擴展性的替代方案 [11]，但虛實轉移差距仍是一項關鍵挑戰。現有的策略包括透過領域隨機化 (Domain Randomization) 來增強魯棒性 [18]、利用領域自適應 (Domain Adaptation) 來對齊表徵 [19]，以及專注於對齊模擬動力學 [20, 21] 或使用 Real-to-Sim-to-Real 方法 [22, 23]。像是 DeepMind 的機器人足球等框架，也結合了神經渲染與領域隨機化 [24]。雖然這些方法旨在透過增強策略的魯棒性或調整表徵來彌合虛實差距，但我們的「Real-is-Sim」範式則完全消除了這一差距。透過持續將模擬器與現實世界對齊，並將其視為執行環境，我們將策略與虛實差異解耦。領域對齊的挑戰轉移到了模擬器本身，並透過即時更新來解決。

利用世界模型 (World Models) 進行機器人研究：學習到的世界模型使機器人能夠預測未來結果，以進行規劃與控制。這些模型的範圍涵蓋從 2D 預測器 [25] 到更具結構性的 3D 物理基礎模型，例如利用 Gaussian Splatting [26, 1] 的模型，這類模型支援即時追蹤與模擬互動。我們的工作以此為基礎，探索將此類先進的 3D 世界模型整合至行為複製 (Behavior Cloning) 框架中。其目標是透過在這些模型提供的動態更新、即時數位分身 (Digital Twin) 上訓練策略，直接在現實任務中發揮模擬環境的優勢。

6 結論

我們介紹了 *real-is-sim*，這是一個用於策略訓練、評估與部署的統一框架，在整個流程中維持持續修正的模擬環境。透過將模擬視為一個由 Embodied Gaussians 驅動的持久、即時介面，我們消除了訓練與部署領域之間的脫節。這將策略評估重新定義為一個模擬原生的過程，即使在現實世界場景中也是如此。我們在 PushT 任務上的結果顯示，離線效能與現實世界效能之間具有強烈的一致性，證明了 *real-is-sim* 能夠在不犧牲保真度的情況下，實現具備擴展性且高效的評估。我們希望此框架能為未來利用模擬與現實緊密結合的現實世界學習演算法奠定基礎。

7 限制 (Limitations)

雖然我們的框架展示了令人期待的結果，但其適用性從根本上受到底層物理模擬器保真度的限制。與模擬器建模假設顯著偏離的場景，對前向預測和修正機制都構成了挑戰。未來的工作可以透過改進模擬器的準確性來解決這些限制，例如透過自適應參數估計——例如在 [26] 和 [27] 中探索的摩擦力或質量等物理屬性的即時優化。

目前框架的另一個限制是其依賴視覺力量來修正模擬器狀態。這限制了其適用場景，僅限於物體頻繁可見，且不會在缺乏觀察的情況下經歷長時間遮擋或操作的情況。

Moreover, for Embodied Gaussians to function effectively, visual corrections must not conflict significantly with the dynamics predicted by the physics simulator. The approach assumes that both the simulator and the visual feedback are aligned, that is, they attempt to move the object in compatible directions. When this assumption breaks down and the corrections diverge, synchronization between the simulation and the real world may not be reliable. However, this limitation can be addressed. The synchronization mechanism can be extended with additional corrective signals beyond visual forces. For example, semantic cues, such as correspondence detection via methods like TAPIR [28] or loss augmentation using segmentation masks as in [29], could provide more robust alignment in challenging settings. The current framework was designed to demonstrate the simplest viable instantiation. Future extensions could incorporate these more sophisticated correction signals to broaden applicability across diverse and visually ambiguous environments.

Another limitation lies in the scene initialization process. In this work, we employed a simple scheme that is sensitive to factors such as the number and placement of cameras, object complexity, and visibility. However, recent advances in learned priors for geometry initialization, such as InstantMesh [30] and InstantSplat [31], offer promising alternatives that could replace or enhance our approach, expanding the set of objects that can be initialized effectively.

Although we focused on the PushT task to validate the core contributions, the proposed methodology is broadly applicable to other manipulation domains. Extending this approach to tasks such as multi-object rearrangement, cloth manipulation, or non-prehensile pushing will require adapting the simulator's dynamics and corrective policies to accommodate more complex interactions.

ACKNOWLEDGMENT

QUT 的作者感謝昆士蘭科技大學 (QUT) 機器人中心 (Centre for Robotics) 的持續支持。他們的工作部分由澳洲政府透過澳洲研究委員會 (Australian Research Council) 的探索專案資助計劃 (專案編號 DP220102398) 提供支持。

參考文獻

- [1] J. Abou-Chakra, K. Rana, F. Dayoub, and N. Suenderhauf. Physically embodied gaussian splatting: A visually learnt and physically grounded 3d representation for robotics. In 8th Annual Conference on Robot Learning, 2024. URL <https://openreview.net/forum?id=AEqOonGrN2>.
- [2] B. Kerbl, G. Kopanas, T. Leimkühler, and G. Drettakis. 3d gaussian splatting for real-time radiance field rendering. ACM Transactions on Graphics, 42(4), July 2023. URL <https://repo-sam.inria.fr/fungraph/3d-gaussian-splatting/>.
- [3] M. Macklin, M. Müller, and N. Chentanez. Xpbd: Position-based simulation of compliant constrained dynamics. In Proceedings of the 9th International Conference on Motion in Games, MIG '16, page 49-54, New York, NY, USA, 2016. Association for Computing Machinery.
- ISBN 9781450345927. doi:10.1145/2994258.2994272. URL <https://doi.org/10.1145/2994258.2994272>.
- [4] T. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware. Robotics: Science and Systems XIX, 2023.
- [5] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. The International Journal of Robotics Research, page 02783649241273668, 2023.
- [6] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le. Flow matching for generative modeling, 2023. URL <https://arxiv.org/abs/2210.02747>.
- [7] M. Macklin. Warp: A high-performance python framework for gpu simulation and graphics. In NVIDIA GPU Technology Conference (GTC), 2022.
- [8] K. Rana, J. Abou-Chakra, S. Garg, R. Lee, I. Reid, and N. Suenderhauf. Affordance-centric policy learning: Sample efficient and generalisable robot policy learning using affordancecentric task frames. arXiv preprint arXiv:2410.12124, 2024.
- [9] K. Hsu, M. J. Kim, R. Rafailov, J. Wu, and C. Finn. Vision-based manipulators need to also see from their hands. In ICLR, 2022.

- [10] A. Goyal, J. Xu, Y. Guo, V. Blukis, Y.-W. Chao, and D. Fox. Rvt: Robotic view transformer for 3d object manipulation. In *Conference on Robot Learning*, pages 694-710. PMLR, 2023.
- [11] Z. Zhou, P. Atreya, Y. L. Tan, K. Pertsch, and S. Levine. Autoeval: Autonomous evaluation of generalist robot manipulation policies in the real world. *arXiv preprint arXiv:2503.24278*, 2025.
- [12] H. Kress-Gazit, K. Hashimoto, N. Kuppuswamy, P. Shah, P. Horgan, G. Richardson, S. Feng, and B. Burchfiel. Robot learning as an empirical science: Best practices for policy evaluation. *arXiv preprint arXiv:2409.09491*, 2024.
- [13] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 2024.
- [14] A. Kadian, J. Truong, A. Gokaslan, A. Clegg, E. Wijmans, S. Lee, M. Savva, S. Chernova, and D. Batra. Sim2real predictivity: Does evaluation in simulation predict real-world performance? *IEEE Robotics and Automation Letters*, 5(4):6670-6677, 2020.
- [15] X. Li, K. Hsu, J. Gu, O. Mees, K. Pertsch, H. R. Walke, C. Fu, I. Lunawat, I. Sieh, S. Kirmani, S. Levine, J. Wu, C. Finn, H. Su, Q. Vuong, and T. Xiao. Evaluating real-world robot manipulation policies in simulation. In P. Agrawal, O. Kroemer, and W. Burgard, editors, *Proceedings of The 8th Conference on Robot Learning*, volume 270 of *Proceedings of Machine Learning Research*, pages 3705-3728. PMLR, 06-09 Nov 2025. 
- [16] S. Silwal, K. Yadav, T. Wu, J. Vakil, A. Majumdar, S. Arnaud, C. Chen, V.-P. Berges, D. Batra, A. Rajeswaran, et al. What do we learn from a large-scale study of pre-trained visual representations in sim and real environments? In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 17515-17521. IEEE, 2024. 
- [17] M. Khanna, Y. Mao, H. Jiang, S. Haresh, B. Shacklett, D. Batra, A. Clegg, E. Undersander, A. X. Chang, and M. Savva. Habitat synthetic scenes dataset (hssd-200): An analysis of 3d scene scale and realism tradeoffs for objectgoal navigation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16384-16393, 2024. 
- [18] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, and P. Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2017. 
- [19] S. James, P. Wohlhart, M. Kalakrishnan, D. Kalashnikov, A. Irpan, J. Ibarz, S. Levine, R. Hadsell, and K. Bousmalis. Sim-to-real via sim-to-sim: Data-efficient robotic grasping via randomized-to-canonical adaptation networks. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [20] A. Z. Ren, H. Dai, B. Burchfiel, and A. Majumdar. Adaptsim: Task-driven simulation adaptation for sim-to-real transfer. In J. Tan, M. Toussaint, and K. Darvish, editors, *Proceedings of The 7th Conference on Robot Learning*, volume 229 of *Proceedings of Machine Learning Research*, pages 3434-3452. PMLR, 06-09 Nov 2023.
- [21] N. Pfaff, E. Fu, J. Binagia, P. Isola, and R. Tedrake. Scalable real2sim: Physics-aware asset generation via robotic pick-and-place setups. *arXiv preprint arXiv:2503.00370*, 2025.
- [22] M. T. Villasevil, A. Simeonov, Z. Li, A. Chan, T. Chen, A. Gupta, and P. Agrawal. Reconciling reality through simulation: A real-to-sim-to-real approach for robust manipulation. In *Proceedings of Robotics: Science and Systems*, Delft, Netherlands, July 2024. doi: 10.15607/RSS.2024.XX.015.
- [23] Y. Jiang, C. Wang, R. Zhang, J. Wu, and L. Fei-Fei. Transic: Sim-to-real policy transfer by learning from online correction. In P. Agrawal, O. Kroemer, and W. Burgard, editors, *Proceedings of The 8th Conference on Robot Learning*, volume 270 of *Proceedings of Machine Learning Research*, pages 1691-1729. PMLR, 06-09 Nov 2025. 
- [24] D. Tirumala, M. Wulfmeier, B. Moran, S. Huang, J. Humplik, G. Lever, T. Haarnoja, L. Hasenclever, A. Byravan, N. Batchelor, N. Sreendra, K. Patel, M. Gwira, F. Nori, M. Riedmiller, and N. Heess. Learning robot soccer from egocentric vision with deep reinforcement learning. *arXiv preprint arXiv:2405.02425*, 2024. 
- [25] S. S. Yang, Y. Du, K. Ghasemipour, J. Tompson, L. Kaelbling, D. Schuurmans, and P. Abbeel. Learning interactive real-world simulators. *arXiv preprint arXiv:2310.06114*, 2024. 
- [26] H. Jiang, H.-Y. Hsu, K. Zhang, H.-N. Yu, S. Wang, and Y. Li. Phystwin: Physicsinformed reconstruction and simulation of deformable objects from videos. *arXiv preprint arXiv:2503.17973*, 2025. 
- [27] A. Longhini, M. Büsching, B. P. Duisterhof, J. Lundell, J. Ichnowski, M. Björkman, and D. Kragic. Cloth-splatting: 3d cloth state estimation from RGB supervision. In *8th Annual Conference on Robot Learning*, 2024. URL <https://openreview.net/forum?id=WmWbswjTsi>.
- [28] C. Doersch, Y. Yang, M. Vecerik, D. Gokay, A. Gupta, Y. Aytar, J. Carreira, and A. Zisserman. TAPIR: Tracking any point with per-frame initialization and temporal refinement. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 10061-10072, 2023.
- [29] J. Luiten, G. Kopanas, B. Leibe, and D. Ramanan. Dynamic 3d gaussians: Tracking by persistent dynamic view synthesis. In *3DV*, 2024.
- [30] J. Xu, W. Cheng, Y. Gao, X. Wang, S. Gao, and Y. Shan. Instantmesh: Efficient 3d mesh generation from a single image with sparse-view large reconstruction models. *arXiv preprint arXiv:2404.07191*, 2024.
- [31] Z. Fan, K. Wen, W. Cong, K. Wang, J. Zhang, X. Ding, D. Xu, B. Ivanovic, M. Pavone, G. Pavlakos, Z. Wang, and Y. Wang. Instantplat: Sparse-view gaussian splatting in seconds, 2024.
- [32] L. Berscheid and T. Kröger. Jerk-limited real-time trajectory generation with arbitrary target states. *Robotics: Science and Systems XVII*, 2021.
- [33] S. Caron, Y. De Mont-Marin, R. Budhiraja, S. H. Bang, I. Domrachev, and S. Nedelchev. Pink: Python inverse kinematics based on Pinocchio, 2025. URL <https://github.com/stephane-caron/pink>.
- [34] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.

A 跟隨者配置 vs. 領導者配置

我們提出 Real-is-Sim 框架，該框架採用持續修正的環境數位分身，將行為複製（Behavior Cloning）策略與真實機器人解耦。此框架的核心設計決策是將真實機器人配置為模擬機器人的跟隨者。在這種設定下，當真實機器人連線時，它會直接同步模擬機器人的關節狀態。

This follower design introduces a distinctive characteristic: the real world consistently lags slightly behind the simulated twin. To our knowledge, this temporal asymmetry is unique to Real-is-Sim and implies that the system always possesses a short-horizon preview of future states. While we find this property conceptually interesting, our primary motivation for adopting the follower configuration is practical, it results in a significantly simpler software architecture and reduces the complexity of sim-to-real integration. 🔄

Supplementary Figure 1 illustrates this distinction. In both offline and online modes under the follower configuration (our proposed setup), the system interconnections (blue lines) remain constant. In contrast, the leader configuration-where the real robot dictates state and the simulator reacts-requires dynamic changes to the system architecture. Specifically, three data streams must cross the sim-to-real boundary in the leader case: 🔄

Control inputs from the policy to the real robot, 🔄

Control inputs from the real robot to the simulator, 🔄

從真實機器人到模擬器的觀測值。




圖 9：補充圖 1：比較 Real-is-Sim 框架中建議的 Follower 配置（真實機器人模仿模擬）與另一種 Leader 配置（模擬跟隨真實機器人）。Follower 設定需要較少的 Sim-to-Real 數據流，且在離線與線上模式中保持相同的系統連接，簡化了部署過程。

相比之下，Follower 配置僅需要兩個此類數據流。這種跨邊界通訊的減少簡化了整體系統，也是我們在 Real-is-Sim 中推薦 Follower 配置的原因。

B 使用真實機器人收集示範數據的優點

In real-is-sim, we advocate collecting demonstrations with the real robot attached (online mode). During data collection, the user observes the state of the simulator overlaid with the real world, allowing them to continuously assess synchronization quality. This enables the user to adapt their behavior not only to complete the task but also to maintain alignment between the simulation and the real environment. Practically, this means knowing when to move quickly or slowly, and how much clearance to give during fast motions to accommodate slight mismatches between the two domains. 🔄

Supplementary Figure 2 illustrates an exaggerated case in which demonstrations are collected entirely in sim- 🔄

Tracking Failure Rate (%) by Collection Strategy




Figure 10: Supplementary Figure 2: Tracking failure in two policies, one trained on demonstrations collected with the real robot in the loop, and the other trained entirely in simulation. The left image illustrates a failure case where the simulated physics conflicts with the visual correction required to stay in sync with the real world. Since physics acts as a hard constraint, the correction cannot be applied. Collecting demonstrations in online mode helps avoid such failure modes by encouraging behaviors that maintain alignment between the simulation and reality.

ulation and the resulting policy is deployed on the real robot. Although the task is successfully demonstrated in simulation, it is done with insufficient clearance around objects-causing impacts in the virtual world that do not occur in the real one. The perception system’s correction mechanisms are unable to recover from this divergence, leading to a marked increase in tracking errors during real-world execution.

For this reason, we recommend that at least some demonstrations be collected with the real robot in the loop. This allows both the policy and the demonstrator to implicitly learn behaviors that help keep the simulator and real world in sync.

C Implementation Details

We use an NVIDIA RTX 6000 Ada as our primary compute device. The robot employed is a Franka Emika with 7 degrees of freedom. The high-impedance controller for the real robot utilizes Ruckig [32] to generate joint trajectories with minimal jerk, in conjunction with the Franka Emika’s built-in joint controller. During demonstration collection, the simulated robot is constrained to act within a 2D plane using Pink [33]. Note that this 2D Cartesian controller is only active during demo collection and only controls the simulated robot. The real robot continues to execute a joint impedance controller based on the simulated robot’s joint positions. Interestingly, the policy learns to operate in 2D, even though the joint controller does not impose such a restriction when the policy is deployed.

D Alterations to Embodied Gaussians

Our adaptation of Embodied Gaussians [1] (built using [7]) differs from the original framework in two key aspects. First, we omit shape-matching constraints for deformable objects, modeling all entities as rigid bodies composed of spherical collision primitives. This results in a rigid body simulator rather than a particle-based one, improving performance from 30 Hz to 60 Hz in online mode. Second, we treat the robot as a dynamic entity, simulating mass and inertia for its links and joints, in contrast to the original kinematic formulation, where robot motion was purely kinematic. This change enhances simulation stability and allows the simulated robot to react to the environment. We also found it essential to ensure that the bodies comprising the simulated robot are not affected by gravity. Without this, controlling the simulated robot becomes more difficult, as the controller would need to include a gravity compensation term.

E Future Work

While the always-in-the-loop simulator already corrects itself using observations, its accuracy could be further enhanced by backpropagating into physics parameters or learning a residual physics network, reducing reliance on explicit corrections by making the simulator’s predictions more physically faithful. A more accurate simulator would also enable reinforcement-learning-based finetuning of imitation-learned policies. Additionally, this work focused on offline policy evaluation, but future extensions could incorporate online planning during deployment for real-time adaptability. Finally, Embodied Gaussians could be extended to encode higher-level features such as DINO embeddings [34] or other semantic descriptors. This would enrich policy training and further make use of the simulator’s role as a mediator between the real world and the policy.

¹ 使用四元數是為了簡便，且在我們的任務中並未引入歧義。

