

摘要

Sim2Real 領域轉移 (Domain Transfer) 為開發智慧交通系統 (ITS) 中基於 LiDAR 的感知技術 (如物件偵測、追蹤、分割) 提供了一種具成本效益且可擴展的方法。然而, 由於分佈偏移 (Distributional Shifts), 在模擬環境中訓練的感知模型在現實世界數據上的表現往往不盡理想。為了縮小這一 Sim2Real 差距, 本論文提出了一個高保真數位分身 (HiFi DT) 框架, 該框架整合了現實世界的背景幾何、車道級道路拓撲, 以及特定感測器的規格與配置。我們將 Sim2Real 學習底層的領域自適應 (Domain Adaptation) 挑戰公式化, 並提出一套系統化方法來建構能產生域內 (In-domain) 合成數據的模擬環境。我們使用現成的 3D 物件偵測器在 HiFi DT 生成的合成數據上進行訓練, 並在真實數據上進行評估。實驗結果顯示, 經由數位分身訓練的模型在表現上優於在真實數據上訓練的同等模型達 4.8%。為了探究此增益, 我們在原始輸入與潛在特徵 (Latent Feature) 層級上, 使用多項指標量化合成數據與真實數據之間的分佈對齊程度, 包括 Chamfer Distance (CD)、Maximum Mean Discrepancy (MMD)、Earth Mover's Distance (EMD) 以及 Fréchet Distance (FD)。結果證明, HiFi DT 顯著減少了領域偏移, 並提升了在多種評估場景下的泛化能力。這些發現強調了數位分身實現可靠、基於模擬的 LiDAR 感知以應用於現實世界 ITS 方面的重要作用。

索引詞—數位分身 (Digital Twin)、CARLA 模擬、模擬保真度 (Simulation Fidelity)、Sim2Real、領域轉移 (Domain Transfer)、LiDAR 感知、3D 物件偵測、特徵分析

I. 前言

背景與動機: 光學雷達 (LiDAR) 技術在精確度與不受光照影響的運作方面展現了強大的效能。它正成為推動智慧型運輸系統 (ITS) 感知演算法發展的基石。這些感知演算法執行諸如 3D 物件偵測、追蹤, 以及語義與實例分割等任務。在開發基於 LiDAR 的感知演算法時, 深度神經網路仍處於領先地位。然而, 訓練這些網路的大多數方法都是基於監督式學習, 也就是說, 它們需要標記數據才能從原始點雲數據中學習特徵, 並生成特定任務的預測。例如, 為了訓練深度 3D 物件偵測器, 每個點雲幀中的每個感興趣物件 (自行車、汽車、卡車等) 都需要包含邊界框資訊 (位置、大小和方向) 的標籤。為了實現更高的精確度與泛化能力, 深度神經網路

模型需要大量的標記數據來進行深度感知模型的訓練與測試 [1]。為了滿足這一需求, 業界已策劃了許多高品質的 LiDAR 資料集, 例如用於自動駕駛的 KITTI [2]、Waymo Open [3]、NuScenes [4] 等 [5]-[9]; 用於路側 LiDAR 感知的 IPS300+ [10]、LUMPI [11]、TUMTraf-I [12] 等 [13]-[15]; 以及用於協作感知任務的 DAIR-V2X [16]、V2X-Real [17]、BAAI-VANJEE [18] 等 [19], [20]。然而, 建立與擴展此類資料集仍面臨挑戰, 原因如下: (1) 記錄與標記大量的點雲幀在時間、人力與金錢方面會產生高昂成本; (2) 人工標註可能存在偏見及/或包含錯誤, 導致標籤品質下降; (3) 局部因素如道路使用者類型 (自行車、汽車、卡車等)、環境條件 (天氣與光照) 等在不同地理區域之間差異巨大, 使得某個地點的數據較難應用於其他地點; (4) 交通事故等極端案例情境難以收集; 以及 (5) 感測器特性 (規格及/或安裝設定) 的任何變動, 都會因解析度、點頻率、視角等因素的增加而改變數據分佈。因此, 迫切需要開發具有成本效益的方法, 以快速建立包含接近真實數據分佈的高品質 LiDAR 資料集, 且在特定情境生成與感測器特性變更方面具有高度適應性。

ITS 的 Sim2Real: 模擬到真實 (simulation-to-real) 訓練的概念, 是實現經濟且具擴展性之感知系統的一條可行路徑。對於基於 LiDAR 的 ITS 應用而言, 使用模擬環境生成標註數據, 通常涉及在 3D 環境中對參與者 (例如路口的交通流量) 進行物理模擬。參與者類型主要可分為兩類: 靜態參與者 (周邊建築、樹木、道路等) 與動態參與者 (行人、自行車、汽車、卡車等)。合成的 LiDAR 數據及其相關標註數據, 是透過在這些 3D 參與者的模擬中模擬感測器所生成的。為了實現有效的 Sim2Real 學習, 這些數據在理想情況下應與目標領域數據相似, 即使用真實感測器從真實世界交通場景中擷取的數據。模擬器的限制: 為了建立逼真的模擬, 需要先進的模擬器。在 [21] 中, 作者全面討論了許多用於 ITS 的模擬工具, 包括交通與感測模擬器。其中, 如 CARLA [22]、DeepDrive [23] 與 Vista [24] 等綜合性開源模擬器, 支援自動駕駛系統 (ADS) 的一系列感知、規劃與控制任務。儘管其目標是模擬自動駕駛場景, 但



圖 1: 高真度數位分身 (High-Fidelity Digital-Twin)

圖 1. 真實場景、我們的高保真數位分身 (HiFi DT) 以及通用 CARLA 內建環境之間的定性比較。在我們的建模中，我們仔細構建了周邊建築、場景內植被以及車道級道路拓撲與對齊等多項因素，以實現貼近真實的模擬。原始的 CARLA 模擬則缺乏此類保真度。功能通常也可以擴展，以支援路側與協作式 LiDAR 感知應用的任務。

使用模擬器的核心優勢在於無限的數據生成能力，讓使用者能以極低的成本建立自定義場景、情境、交通流和感測器配置。然而，數據集的實用性並非僅由數量決定，還取決於其對目標任務忠實度 (faithfulness) 的品質。忠實度通常透過數據集的真實性、分佈和多樣性來衡量 [25]。模擬器中的內建資產通常是手工製作的，不夠真實，導致生成的數據不符合真實的點雲分佈。這引入了顯著的 Sim2Real 差距 [26]。因此，在這種合成數據上訓練的模型，在實際部署時往往表現不佳 [27]。利用 HiFi DT 彌合 Sim2Real 差距：為了實現有效的 Sim2Real 學習，合成數據與真實數據必須共享共同的特徵空間與分佈 [28]。然而，建立與真實世界數據一致的感測器模擬是一項極具挑戰性的任務，需要在模擬中忠實呈現目標現實的靜態與動態面向。為了彌合這一差距，本文探討了高保真數位分身 (HiFi DTs) 在訓練基於 LiDAR 的感知模型中的適用性。特別是針對 3D 物件偵測任務進行研究，並利用 HiFi DT 建立用於該目的之訓練集。透過在 HiFi DT 模擬中納入靜態幾何佈局 (周邊建築、樹木、道路等) 與動態情境 (交通類型與流量，以及感測器規格與位置)，使數據與目標現實保持一致。為了正式定義本研究處理的核心挑戰，我們考慮了監督式學習背景下合成數據與真實世界數據之間的分佈差異。透過使用 HiFi DT 最小化此領域差距 (domain gap)，我們的目標是確保在模擬中訓練的模型能良好地泛化到真實世界場景。此目標的詳細數學公式將在第 III 節中呈現。

我們的法利用公開可用的地圖影像 (2D 與 3D 影像)、OpenStreetMap [29] 資訊以及車道級數據 (位置、高度與超高)，來建構背景幾何形狀與道路。接著，雖然是以隨機方式生成交通流，但會與該感興趣區域內物件類別的統計分佈相匹配。最後，利用符合真實感測器規格 (解析度、點頻率、量程等) 與佈置細節 (位置與朝向) 的感測器模擬，生成合成點雲資料集以及 3D 邊界框 (bounding-box) 標籤。我們的方法實現了高度忠實的模擬，如圖 1 所示。生成的資料集隨後用於訓練現成的模型 (SEED [30])，並將該模型的準確度與在真實數據上訓練的相同模型進行比較。在 HiFi DT 上訓練的模型表現優於在真實數據上訓練的對手 4.8%，為有效的 Sim2Real 學習樹立了新標準。

為了證實生成的數據與真實數據屬於同一領域 (in-domain)，本文進一步深入探討了輸入數據與潛在特徵 (latent-feature) 層級的分析。首先，進行統計分佈分析，記錄平均點密度、類別分佈以及物件的大小與數量。此外，計算 Chamfer Distance 以量化幾何相似性。隨後，採用非線性降維技術 t-SNE 與 UMAP [31]，繪製合成數據與真實數據的潛在特徵相似性圖 (源自 SEED 的骨幹網路)。最後，計算兩項領域差異指標：最大平均差異 (Maximum Mean Discrepancy, MMD) 與推土機距離 (Earth Mover's Distance, EMD)，以展示對齊程度。高相似性的趨勢證明了 Sim2Real 差距的縮小。此外，由偵測器骨幹網路生成的潛在特徵呈現高度重疊，顯示合成數據與真實數據在特徵空間中具有相似的分佈，這表明模型在結構與語義上將兩者視為一致。

在評估方面，本文全程使用已建立的真實世界基準數據集——萊布尼茲大學多視角路口 (Leibniz University Multi-perspective Intersection, LUMPI) [11] 數據集。這是一個大規模的路側 LiDAR 數據集，使用 5 個 LiDAR 感測器在德國漢諾威的 Königsworther Platz 路口採集。由於原始數據集包含 90 K+ 幀，為了保持實驗的可行性，本文使用了其中的子集 Measurement4。用於訓練的完整合成數據集 UT-LUMPI [32] 已發佈於我們的 Harvard Dataverse <https://dataverse.harvard.edu/dataverse/ucf-ut>。我們鼓勵研究人員利用我們其他基於 HiFi DT 的數據集，包括 UT-V2X-Real [33] 與 UT-TUMTraf-I [34]，這些數據集分別模擬自原始的 V2X-Real [17] 與 TUMTraf-I [12] 數據集。

A. 貢獻

總結來說，本論文的主要貢獻如下：

據我們所知，這是首項採用 HiFi DT 的研究，該技術同時考慮了真實場景的靜態與動態面向，以生成可直接應用於訓練真實世界 LiDAR 感測模型的 LiDAR 數據。

本研究開發了一套可行且系統化的方法，利用公開資訊為真實地點建立高保真數位分身 (HiFi DT)。

本研究提出了一種在 HiFi DT 之上精確模擬 LiDAR 感測器的技術。

這項研究首次在基於 HiFi-DT (合成) 的資料集上訓練深度 3D 物件偵測器，其表現優於在真實資料上訓練的相同模型。

本研究利用多項既定指標，針對點雲資料在深度偵測器模型的原始輸入與潛在特徵層級進行深入的分佈分析，展示了 Sim2Real 差距的縮減。

在介紹我們的方法論之前，我們首先回顧模擬、領域自適應 (domain adaptation) 以及基於數位分身的感知建模等相關研究工作。

II. 相關工作與研究缺口

多年的研究已證實，不均等的來源會導致效能差異 [35]。就本文脈絡而言，研究 [36]、[37] 指出，在某一地點的真實數據上訓練的模型，在另一地點的數據上表現不佳。Sim2Real 學習提供了解決方案，然而天真的實作會導致巨大的效能下降。例如，Dworak 等人 [38] 在 KITTI [2] 資料集上測試了以 CARLA 模擬訓練的物件偵測器，並注意到 mAP 分數下降了 68%。Fang 等人 [39] 和 Manivasagam 等人 [26] 在其研究中也注意到了這種下降。值得注意的是，物件偵測僅是感知任務的一種，Yue 等人 [40] 和 Spiegel 等人 [41] 的研究則側重於語義分割 (semantic segmentation)，並指出這種差距仍然存在。為了應對這一問題，多個研究方向正被探討，包括改進感測器建模、領域自適應 (domain adaptation) 以及數位分身 (digital-twin) 建模。

感測器模擬研究：綜合模擬器 (如 CARLA [22]) 為自動駕駛應用提供了眾多功能，包括 LiDAR 感測器。然而，其感測器模型缺乏許多真實世界的效應 [42]。諸如 LGSVL Simulator [43] 等模擬器則更強調感測器的保真度。儘管如此，諸如材料反射率、玻璃上的射線掉落 (ray dropout)、多次回波或運動失真等效應仍未被建模。在 [44] 中提出了 GarchingSim，可為自動駕駛生成照片級真實感的場景。Haider 等人 [45] 研究了精確的射線追蹤 (ray-tracing) 以準確模擬 LiDAR。他們開發了一套完整的訊號處理流程，並針對真實世界的測量結果進行了測試。他們展示了必須準確建模感測器的缺陷，如光學損耗、電子

雜訊和多重回波行為，以提高模擬保真度。Manivasagam 等人 [26] 最近的研究結合了精確的射線投射 (ray casting) 來模擬感測器雜訊，產生的點雲比純 CAD 模型更具真實感 [26]。這些研究展示了感測器模擬保真度的提升。然而，值得注意的是，在一個虛構的模擬場景中，僅憑精確的感測器物理特性，不足以解釋真實數據中所見的幾何形狀和動態特性。

網域遷移研究 (Domain Adaptation Studies)：一般而言，網域遷移方法專注於將訓練好的模型從一個網域轉移到另一個網域。在智慧型運輸系統 (ITS) 中，早期的一項工作是 SqueezeSeg [46]，該研究在合成數據上訓練光達 (lidar) 分割網路，並在真實掃描數據上進行微調。其改良版本 SqueezeSegV2 [47] 引入了一套非監督式網域遷移管線，透過學習強度映射 (intensity mapping) 並對齊特徵分佈，以減輕模擬到真實 (simulation-to-real) 之間的差距。研究報告指出，其分割準確度提升了 2 倍。這些研究啟發了後續縮小光達感知任務網域差異的相關研究。Zhao 等人 [48] 提出了一個端到端框架 ePointDA，該框架在合成點雲數據中注入 dropout 雜訊以模擬缺失點。此外，它還執行空間自適應特徵對齊，並避免預先得知真實數據的統計資訊。該模型在 GTAV 模擬器上進行訓練，並在真實的 SemanticKITTI [49] 數據集上獲得了優異的分割表現。在 [50] 中，作者介紹了 CoLiGen，這是一個利用生成對抗網路 (GANs) 將光達數據轉換為深度反射影像 (depth-reflectance images) 的框架，藉此將模擬掃描轉換為更真實的點雲。Yang 等人開發了 ST3D [51]，該方法使用目標網域的虛擬標籤 (pseudo-labels) 和課程增強 (curriculum augmentation)，迭代地優化在來源網域上訓練的偵測器。他們展示了透過精心設計的遷移策略 (例如縮放物件大小以減少來源偏差，接著使用目標虛擬標籤進行過濾與重新訓練)，可以產生強健的跨網域偵測器。

網域遷移方法專注於數據生成後的遷移能力。對這類修正策略的需求凸顯了一個潛在問題：模擬網域本身與現實相比存在缺陷。相比之下，數位分身 (digital-twin) 建模專注於最小化初始的差距。如果模擬器能產生與真實感測器數據幾乎無法區分的光達數據，那麼特徵層級網域遷移的負擔將能大幅減輕。

數位分身研究 (Digital-Twin Studies)：利用數位分身輔助感知任務模擬建模的概念是近期才出現的。Li 等人 [52] 首次建構了高保真數位分身，用以生成帶有標籤的合成影像數據集。他們進一步應用圖形匹配模組來對齊模擬網域與真實網域之間的特徵分佈。透過將此模組與多任務網路 (物件偵測與分割) 結合，並採用多層級網域辨別器，學習到了具遷移性的表示法。在 [53] 中，研究人員提出了一個真實的合成光達數據集，特別專注於複製 KITTI 和 nuScenes 數據集的幾何與分佈特性。他們透過跨數據集泛化實驗發現，在 LUCID 數據集上訓練的模型達到了最佳的跨數據集泛化效能，其平均跨數據集平均精度 (AP-CDP) 增量為 -0.18，平均召回率 (AR-CDP) 增量為 -0.16，表現優於其他真實與合成數據集。

這種數位分身輔助的模擬方法，相較於單純改進感測器物理特性或先前的 UDA 方法，展現出更優異的效能，凸顯了其重要性。然而，數位分身建模可能是一個複雜的過程，特別是因為建構地圖需要大量的數位資產 (如建築物、道路、道路使用者等)。

研究缺口與動機：儘管取得了上述進展，Sim2Real LiDAR 學習中仍存在幾個關鍵缺口：(1) 雖然模擬器納入了改進的 LiDAR 感測器物理與雜訊模型，但其內建環境完全是手工打造的，且在大多數情況下過於簡化，無法用於 Sim2Real 學習；(2) 領域自適應 (Domain adaptation) 方法主要是事後補救方案，需要進一步的處理和特徵層級的領域自適應；(3) 雖然 HiFi DT 建模已出現於基於 LiDAR 的模擬中，但建立 HiFi DT 的過程尚未流線化。本論文受到該領域令人興奮的研究啟發，提出了一種全新且更簡單的系統化方法，僅使用公開資訊即可為任意地點建立 HiFi DT。這些 HiFi DT 成為基於 CARLA 模擬的基礎，該模擬考量了精確的感測器姿勢與規格，以產生幾乎難以辨別的點雲數據。透過加入簡單的高斯雜訊，可以使數據更具泛化性，以便用於目標真實地點。由於生成的點雲從根本上就與真實地點對齊，因此不需要進行後處理。這使得我們的方法與先前的 Sim2Real 學習方法相比更加實用。

III. 問題定義與方法論

A. 問題定義

令 $\mathcal{D}_{\text{real}} = \{(x_i^{\text{real}}, y_i^{\text{real}})\}_{i=1}^N$ 代表真實世界資料集（例如 LUMPI），其中 x_i^{real} 為輸入點雲， y_i^{real} 為相對應的 3D 物件偵測標籤。這些樣本是從真實世界的聯合分佈 $P_{\text{real}}(x, y)$ 中取樣。同樣地，令 $\mathcal{D}_{\text{sim}} = \{(x_j^{\text{sim}}, y_j^{\text{sim}})\}_{j=1}^M$ 代表透過高真度數位分身（HiFi DT）生成的合成資料集，其取樣自基於模擬的分佈 $P_{\text{sim}}(x, y)$ 。

我們的目標是使用 $\mathcal{D}_{\text{sim}}$ 來訓練一個由 θ 參數化的深度 3D 物件偵測模型 $f_{\theta}: \mathcal{X} \rightarrow \mathcal{Y}$ ，使其在未見過的真實世界資料上具有良好的泛化能力。目標是最小化真實世界分佈上的預期偵測損失：

$$\mathcal{E}_{\text{real}}(\theta) = \mathbb{E}_{(x,y) \sim P_{\text{real}}} [\mathcal{L}(f_{\theta}(x), y)],$$

其中 $\mathcal{L}$ 是包含分類、邊界框迴歸（bounding box regression）以及基於 IoU 元件的複合損失函數。

然而，由於 f_{θ} 是在 $\mathcal{D}_{\text{sim}}$ 上進行優化，其泛化誤差 $\mathcal{E}_{\text{real}}(\theta)$ 取決於模擬與真實世界資料分佈之間的差異（divergence）：

$$\Delta(P_{\text{sim}}, P_{\text{real}}) = \text{divergence}(P_{\text{sim}}, P_{\text{real}}).$$

我們的核心假設是，透過利用能忠實複製真實世界幾何形狀、感測器配置和交通模式的高保真數位分身（high-fidelity digital twins），我們可以建構 P_{sim} ，使得：

$$\Delta(P_{\text{sim}}, P_{\text{real}}) \rightarrow 0$$

進而確保：

$$\mathcal{E}_{\text{real}}(\theta) \approx \mathbb{E}_{(x,y) \sim P_{\text{sim}}} [\mathcal{L}(f_{\theta}(x), y)].$$

在本文中，我們使用幾何與潛在特徵（latent-feature）指標來經驗性地估計分佈對齊情況。具體而言，我們計算點雲空間中的 Chamfer Distance (CD)，以及偵測器骨幹網路（backbone）潛在特徵空間中的 Maximum Mean Discrepancy (MMD)、Earth Mover's Distance (EMD) 和 Fréchet Distance (FD)。例如，MMD 的計算方式為：

$$\Delta_{\text{MMD}} = \|\mathbb{E}_{x \sim P_{\text{sim}}} [\phi(x)] - \mathbb{E}_{x \sim P_{\text{real}}} [\phi(x)]\|^2,$$

其中 $\phi(x)$ 代表輸入 x 在偵測器潛在特徵空間中的嵌入（embedding）。較低的 Δ_{MMD} 值表示強大的特徵級別對齊，這顯示偵測器在感知這兩個領域時，認為它們在結構與語義上是相似的。

此公式構成了我們研究的核心前提：透過場景與感測器忠實度高的數位分身（Digital Twins）所產生的高品質合成數據，能有效最小化 Sim2Real 差距，並使深度感知模型在現實世界的 ITS 部署中具備強大的泛化能力。

B. 使用 HiFi DTs 合成趨近真實的數據

為了建立一個逼真的標記式 Lidar 資料集，其逐步方法論如下：(1) 確定目標位置，以及 (2) 使用衛星地圖服務（如 Cesium 3D Tiles）收集目標位置的 3D 影像。衛星 3D 影像通常是 3D 網格（mesh）重建，包含對目標現實結構的估計。它包含低多邊形（low-poly）幾何圖形，這意味著 3D 網格中的表面並不精細。然而，由於真實的 Lidar 數據本質上也是稀疏的，因此在這種應用場景下，低階的表面細節並不重要。衛星 3D 影像的另一個限制是，它通常會包含交通雜點（traffic blobs），因為用於重建網格的原始 2D 影像中存在此類雜訊。另一個雜訊來源可能是重建演算法本身，因為它並不完美，可能會引入額外的幾何圖形，而這些圖形在真實場景中並不存在。此外，感興趣區域（ROI）之外的一些幾何數據也可能存在於擷取的 3D 影像中，基於效率考量需要將其移除。幸運的是，使用任何 3D 建模工具（如 Blender）移除此類雜訊都相當容易。因此，(3) 透過將整個 3D 網格載入 3D 建模工具中，可以將網格切割至感興趣區域，隨後根據定性檢查移除多餘的幾何圖形（交通雜點、半空中的 3D 碎片等）。此外，模型會重新縮放以符合現實世界的單位。作為選配步驟，為了之後的便利性，感測器位置也會在此階段進行標記。一旦 3D 模型準備就緒，下一步 (4) 是建立精確的道路，以便模擬工具使用



圖 2：為現實世界地點建模高保真數位分身（High-Fidelity Digital Twin）的系統化方法。

生成交通流量。為了在感興趣區域（region of interest）內建立精確的道路拓撲，可以從 OpenStreetMaps [29] 等地圖工具匯入道路拓撲。CARLA 支援多種建立道路的方法，例如 SUMO NetEdit [54]（開源）、RoadRunner [55]（付費），或使用 CARLA 的原始碼專案來建立道路。根據偏好，可以使用任何支援的工具集。一旦建立道路拓撲並建構出生成的網格（mesh），衛星影像網格與道路都會被匯入 CARLA，並進行平移或旋轉以相互對齊。至此完成了數位分身的靜態部分。接著，(5) 利用 CARLA 原有的道路使用者目錄生成交通流。道路使用者的類型與分佈可以編寫進交通生成腳本中，以便在統計上符合目標真實地點的分佈。最後，執行結合真實感測器規格與姿態（pose）的資料擷取腳本，以收集點雲與邊界框（bounding-box，即標籤）資料。在我們的 HiFi DT 中，感測器規格包括通道數、水平解析度、水平與垂直視野（fields of view）、量測範圍以及點率（point rate）。至於感測器姿態，則考慮了中心位置與傾斜度。合成資料集以 OpenPCDet [56] 格式儲存。整個流程的概覽總結於圖 2。

直觀上，由於數位分身建模的緣故，生成的模擬結果非常接近現實，因為其 3D 空間表示與交通動態與真實世界中所觀察到的現象具有高度的一致性，如圖 3 所示。這種方法提供了一種具成本效益且運算效率高的方式。




圖 3：合成與真實 LiDAR 資料集的影響級統計比較：由於精確的感測器建模，點密度呈現出一致性。場景複雜度與邊界框體積則是隨機道路使用者生成過程的函數。歸一化比較中的高度重疊證明了合成資料集與真實資料集之間的高度相似性。

高效的近似方法，為預期應用提供足夠的保真度。請注意，HiFi DT 的規格既可以與現有數據對齊以進行數據增強，也可以根據特定的實驗場景進行客製化，以開發無風險的極端情況 LiDAR 資料集。在本論文中，我們的模擬模型旨在複製 LUMPI 資料集（德國漢諾威 Königsworther Platz 路口）。感測器模擬細節：由於感測器模擬會高度影響數據品質，此處提供了達成最佳品質的說明。首先，確定目標感測器。這相對容易，因為感測器在任何部署中通常都是預先確定的。記錄感測器的規格並轉換為模擬比例。例如，CARLA 中的模擬比例為 100 單位比 1 公尺，這意味著 CARLA 中的 100 個長度單位等於現實世界中的 1 公尺。這些規格被用於建立虛擬感測器。我們所採用的基準資料集 LUMPI 的感測器規格如表 1 所示。其次，將感測器放置在 HiFi-DT 中，其姿態（pose）與真實感測器完全相同。姿態包括感測器的中心和高度屬性。在我們的研究中，我們參考了 LUMPI 資料集中的單個真實 LiDAR 幀，並利用點雲中存在的視覺線索（例如，旋轉雷射從地面反射形成的同心點圓）來估計感測器的位置。這種做法是可行的，因為不需要標記，只需單個點雲就足以獲得感測器位置的足夠近似值。第三，生成交通流量並模擬虛擬感測器以獲取帶有標籤的 LiDAR 數據。在我們的實驗中，我們使用 CARLA 模擬器在 LUMPI 的數位分身中透過感測器模擬收集了 10,000 幀數據。

表 1: TABLE I
虛擬感測器規格

參數	Hesai Pandar 64	Velodyne HDL-64E	Hesai PandarQT	Velodyne 2× VLP-16
通道	64	64	64	16
上垂直視野 (°)	15	1.9	52.1	15
下垂直視野 (°)	-25	-24.6	-52.1	-15
每秒點數	2.60 M	4.97 M	0.87 M	0.68 M
最大範圍 (m)	200	120	20	100

IV. 實驗與結果

訓練深度物件偵測器：為了測試基於 HiFi DT 模擬的適用性，我們將生成的資料集用於 3D 物件偵測任務。為此，我們採用了現成的深度學習 3D 物件偵測器 SEED [30]。利用基於 HiFi DT 的 CARLA 模擬，共生成了 10,000 個標記影格，而作為基準的資料集（LUMPI 資料集 [11] 的 Measurement4 子集）則包含 8,120 個樣本。我們刻意讓合成資料集的規模略大，以強調在具備足夠規模的情況下，高品質的合成資料在實現有效的 Sim2Real 學習方面，可以達到甚至超越真實資料的效果。資料集按 80/20 的比例劃分為訓練集與測試集，模型訓練 12 個 epoch，並使用

OpenPCDet [56] 框架。超參數配置詳見表 II。

表 2: TABLE II
深度物件偵測器訓練所使用的超參數

組件	設定
模型大小	SEED [30] (大型)
資料集	訓練: UT-LUMPI [32] (合成) 測試: Measurement4, LUMPI [11] (真實)
物件類別	汽車
點雲範圍 (m) (感興趣區域)	$x_{\min} = -40.0, x_{\max} = 40.0$ $y_{\min} = -40.0, y_{\max} = 40.0$ $z_{\min} = -8.0, z_{\max} = 2.0$
3D Backbone	VoxelNeXt [57] (5 階段, 256 輸出通道)
優化演算法	AdamW 搭配 OneCycle LR
初始學習率 (Initial Learning Rate)	0.002
訓練輪數 (Number of Epochs)	12
評估指標 (Evaluation Metric)	KITTI (AP @ 0.5)

深度物件偵測器評估：為了確保公平比較，我們在相同的條件下，利用相同的超參數與資料集配置，從頭開始訓練另一個 SEED 模型，但使用的是真實的 LUMPI 訓練集而非合成數據。此設定確保了任何效能差異皆可歸因於訓練數據的本質，而非實驗配置的差異。

圖 4 顯示，在訓練過程中，合成資料集與真實資料集的損失 (loss) 趨勢一致，這表明兩個資料集在 3D 物件偵測任務中具有相似的底層分佈。我們觀察到各個關鍵損失組件的收斂行為保持一致。這些組件包括：(a) 衡量邊界框位置與比例差異的邊界框迴歸損失 (bounding box regression loss)；(b) 計算物件類別交叉熵的分類損失 (classification loss)；(c) 評估徑向距離的旋轉角度迴歸損失 (rotation angle regression loss)；(d) 針對邊界框重疊與對齊進行懲罰的廣義 IOU (GIOU) 損失；以及 (e) 用於信心分數修正的預測 IOU 迴歸損失。此外，圖中也呈現了 (f) 總體損失趨勢，以總結捕捉所有個別損失組件綜合影響的整體優化行為。我們使用以中心為準、跨度 100 個步驟的滾動平均值繪製趨勢線，以平滑波動，從而更清晰地比較合成數據與真實數據的訓練動態。這種一致性表明，透過我們的 HiFi DT 流程生成的合成數據，捕捉到了與真實數據相當的任務相關結構與語義特徵。由於訓練損失反映了模型從輸入數據中提取有意義模式以最小化預測誤差的能力，相似的損失軌跡意味著模型在統計與功能上將這兩個領域視為相似。因此，我們將損失趨勢的相似性視為強而有力的經驗證據，證明合成資料集相對於真實資料集具有表現保真度 (representational fidelity) 與分佈接近性。

在分析訓練損失行為之後，我們評估了兩個模型在真實 (LUMPI) 資料集測試拆分上的偵測效能。如圖 5 所示，與在真實數據上訓練的模型 (42.70%) 相比，在合成數據上訓練的 SEED 模型達到了更高的汽車偵測 $AP@IoU = 0.5$ (44.74%)。這種微幅的效能提升可以歸因於




圖 4: 真實 (LUMPI [11]) 與合成 (UT-LUMPI [32]) 資料集的訓練損失 (Training loss) 比較。圖表展示了 SEED [30] 在真實資料集 (藍色) 及其高真度合成對應版本 (橘色) 訓練期間, 主要損失組件的行為。合成資料的損失趨勢與真實資料密切貼合, 顯示了合成資料集的高真度。值得注意的是, 合成資料集包含略多一些的訓練樣本, 進而帶來更好的收斂行為, 這也使得在合成資料上訓練的模型展現出更優異的效能。

歸功於合成資料集中可用的訓練樣本略多, 可能因此實現了更好的泛化能力。此外, 在合成資料中觀察到更優異的訓練損失收斂情況也反映在下游評估中, 進一步驗證了基於高真度數位分身 (Digital Twin) 的模擬在現實世界 3D 物件偵測中的實用性。




圖 5: 在真實與合成資料集上訓練的 SEED [30] 模型, 於真實資料集測試時的偵測準確度比較。在合成資料集上訓練的模型優於在真實資料集上訓練的相同模型, 證明了合成資料集具有更高品質的標註。

原始數據與潛在特徵分析: 為了經驗性地估計第三節中定義的分歧 (Divergence) $\Delta(P_{\text{sim}}, P_{\text{real}})$, 我們計算了多個幾何與潛在特徵對齊 (Latent-feature alignment) 指標包括 Chamfer Distance (CD)、Maximum Mean Discrepancy (MMD)、Earth Mover's Distance (EMD) 以及 Fréchet Distance (FD)。

首先, 重點在於統計相似性。為此, 我們針對合成資料集與基準資料集的所有影格, 計算了點數 (點雲密度)、物件數量 (場景複雜度) 以及框體大小 (物件形狀分佈)。接著計算影格層級的平均值, 以展示合成數據與真實數據在統計上的對齊情況。這些統計數據如圖 3 所示。如第一個面板所示, 兩個資料集展現出相當的 LiDAR 點雲密度, 顯示出相似的空間覆蓋

範圍。在場景複雜度方面，LUMPI 的每影格平均 3D 邊界框 (bounding boxes) 數量 (49.3) 略高於 UT-LUMPI (44.2)，但其分佈仍保持在重疊的變異範圍內。第三個面板顯示了平均物件體積，真實世界的框體平均體積為 12.2 m^3 ，而合成資料集則為 10.1 m^3 。在右側，雷達圖提供了所有指標的正規化概覽，揭示了兩個領域在點雲密度、物件計數和空間結構方面具有強大的對齊性。

其次，為了建立原始結構相似性，我們計算了 Chamfer Distance (CD)。CD 是一種常用於量化兩組點集之間相似性的指標。其計算方式僅需加總一組點集中的每個點與另一組點集中最近鄰點之間的距離。

第三，為了對結構分佈進行更深入的分析，我們針對合成與真實資料的潛在特徵 (latent features)




圖 6：SEED 骨幹網路特徵的 t-SNE 視覺化圖，比較了基於高保真數位分身的合成資料集 (UT-LUMPI) 與目標資料集 (LUMPI) 以及另外兩個真實世界資料集。每個子圖顯示了從 SEED 骨幹網路提取的 UT-LUMPI 特徵與真實資料集的 2D t-SNE 投影對比：LUMPI (左)、V2X-Real (中) 和 A9 (右)。綠色點代表重疊 (相似) 區域，而紅色點則表示非重疊的特徵區域。與目標資料集 LUMPI 的高度重疊，顯示出數位分身建模方法所產生的強大分佈對齊，而與 V2X-Real 和 A9 顯著較低的重疊則顯示了領域不匹配 (domain mismatch)。




圖 7：基於 UMAP 的 HiFi-DT 資料集與三個真實世界資料集 (LUMPI，即 HiFi-DT 建模的目標位置；V2X-Real；以及 A9) 之間的特徵分佈比較。與圖 6 類似，與 LUMPI 的集中對齊強調了合成資料的表徵保真度，而與 V2X-Real 和 A9 的重疊減少則說明了在無關資料集之間常見的領域差異 (domain divergence)。

分析了多個資料集。具體而言，原始點雲資料通過 SEED 的骨幹網路，提取出富含上下文資訊的高維潛在特徵 (latent features)。這些特徵透過 t-SNE 和 UMAP 降維技術以 2D 圖表進行分析。此外，還計算了最大平均差異 (Maximum Mean Discrepancy, MMD)、推土機距離 (Earth Mover's Distance, EMD) 和 Fréchet 距離 (Fréchet Distance, FD)，以量化真實資料與合成資料之間的對齊程度。

本研究採用 t-SNE (t-分佈隨機鄰域嵌入) 和 UMAP (均勻流形近似與投影) 作為非線性降維技術，以視覺化並分析從點雲資料中提取的高維潛在特徵空間。t-SNE 專注於保留局部鄰域結構，使其在捕捉資料點之間的細微關係方面特別有效；而 UMAP 則強調同時保留局部和全域結構，在詳細分群與更廣泛的資料分佈模式之間取得平衡。透過將高維特徵投影到二維空間，這些方法有助於定性評估合成數據集與真實數據集之間在結構與上下文對齊 (contextual alignment) 方面的表現。圖 6 展示了基於 HiFi-DT 的合成數據集 (UT-LUMPI) 與真實數據集 (包括目標數據集 LUMPI、V2X-Real 及 A9) 在 SEED 骨幹網路 (backbone) 特徵上的 t-SNE 投影。基於 HiFi-DT 的合成數據集特徵在嵌入空間中與目標位置數據表現出強烈的重疊，大多數合成點與真實點都佔據了相似的區域。這種高度重疊證明了 HiFi-DT 方法實現了極高的分佈相似性，使在合成數據上訓練的模型能夠很好地泛化到真實數據。相比之下，與 V2X-Real 和 A9 的有限重疊則凸顯了不同數據集之間通常存在的領域偏移 (domain shift)，即使是在看似相似的路側條件下採集的數據也是如此。雖然領域自適應 (domain adaptation) 技術試圖減輕這種不匹配，但 HiFi-DT 方法提供了一種簡單且具擴展性的方式來合成數據，使其




圖 8：使用幾何與潛在特徵指標，對基於 HiFi-DT 的數據與真實數據特徵進行分佈相似性的定量比較。圖中報告了四項指標：倒角距離（Chamfer Distance, CD）、最大平均差異（Maximum Mean Discrepancy, MMD）、推土機距離（Earth Mover's Distance, EMD）以及 Fréchet 距離，涵蓋了點雲幾何與 SEED 骨幹網路潛在特徵嵌入兩個空間。比較對象為合成數據與三種真實數據特徵：LUMPI（目標）、V2X-Real 及 A9。在所有指標與兩個空間中，UT-LUMPI 均顯示出與其目標 LUMPI 最接近的對齊程度，驗證了其在特定領域訓練中的適用性。

自然地與目標部署環境對齊。此外，圖 7 展示了 SEED 骨幹網路的均勻流形近似與投影（UMAP）維度縮減比較。UMAP 在保留局部與全域結構方面表現更好。與圖 6 類似，基於 HiFi-DT 數據的潛在特徵與 LUMPI 數據集呈現出密集且內聚的重疊，再次反映了我們的方法所實現的強大分佈對齊。相比之下，與 V2X-Real 和 A9 的特徵重疊仍然稀疏，揭示了跨數據集遷移學習所面臨的顯著領域差異。

為了對基於 HiFi-DT 的數據進行分佈相似性的定量分析，我們計算了一系列跨越原始點雲和深度特徵空間的標準領域對齊指標。首先，報告了倒角距離（Chamfer Distance, CD），用以評估原始空間域中點雲之間的幾何相似性。與潛在特徵空間指標不同，CD 直接測量兩個點集之間的平均最近鄰距離，提供了點雲對齊程度的首個定量衡量標準。最大平均差異（Maximum Mean Discrepancy, MMD）和推土機距離（Earth Mover's Distance, EMD）則被用於評估深度潛在特徵空間。MMD 是一種基於核的統計檢定，測量再生核希爾伯特空間中兩個分佈均值之間的距離，為兩個數據集在分佈層面的對齊程度提供了嚴謹的指標。EMD（又稱為 Wasserstein 距離）量化了將一個分佈轉換為另一個分佈所需的最小成本，捕捉了數據分佈之間的局部和全局差異。此外，Fréchet 距離（FD）比較了特徵空間中兩個分佈的均值和協方差，用於評估嵌入域中的生成品質。MMD 對高階統計特性的差異較為敏感，EMD 捕捉分佈的幾何結構，而 FD 則總結了一階和二階分佈特徵，從而能夠全面評估合成數據對真實數據的保真度。CD、MMD、EMD 和 FD 的評分如圖 8 所示。

基於 HiFi-DT 的數據在所有四項指標中——倒角距離 (0.32)、MMD (1.05e-5)、EMD (0.988) 和 Fréchet 距離 (0.210)——始終與其目標數據集 (LUMPI) 表現出最低的距離。相比之下，當將合成數據與無關數據集（如 V2X-Real 和 A9）進行比較時，觀察到了顯著較高的距離。這些結果證實了 HiFi 數位分身方法所產生的數據，不僅在視覺上對齊，而且在幾何和學習表徵空間中也具有統計上的接近性。

V. 結論

本文提出了一套系統化的方法論，透過開發與部署高保真數位分身（HiFi DTs），來彌合基於 LiDAR 感測任務中的 Sim2Real 學習差距。藉由整合真實的靜態場景幾何、車道級道路拓撲、動態交通分佈以及精確的感測器建模，此方法能夠生成在結構與統計上皆與真實數據一致的合成 LiDAR 資料集。在標準 3D 物件偵測任務的實驗評估顯示，僅在基於 HiFi-DT 的合成數據上訓練的模型，不僅達到了具競爭力的性能，且準確度更超越了在真實數據上訓練的模型達 4.8%。

此外，透過在原始輸入與潛在特徵層級進行詳細的統計與結構分析，並利用 Chamfer Distance、Maximum Mean Discrepancy (MMD)、Earth Mover's Distance (EMD)、t-SNE 與 UMAP 等指標，證實了合成數據與真實數據在分佈上的一致性。這些研究結果凸顯了 HiFi DTs 在減輕領域偏移（domain shift）方面的成效，而這種偏移傳統上阻礙了模擬訓練模型轉移至真實環境的遷移能力。

與需要事後修正或微調的傳統領域自適應（domain adaptation）技術不同，所提出的 HiFi DT 架構本質上就能生成域內（in-domain）數據，因此無需複雜的自適應流程。這使得針對特定地點與場景（包括難以捕捉的罕見與極端案例）開發 LiDAR 資料集變得快速、具可擴展性且更具成本效益。

這項工作強調了高保真數位分身在推進智慧型運輸系統（ITS）模擬訓練範式中的關鍵角色，並為生成高品質、任務相關的合成數據提供了一條實用的路徑。未來的研究將擴展此架構以支援更廣泛的感測任務，並納入更大規模的數位分身與更多感測器模型，以應用於自動駕駛領域。探索從公開地理空間數據構建數位分身的全自動化流程。

參考文獻

- [1] C. Zhai, K. Li, R. Zhang, T. Peng, and C. Zong, "Phase diagram in multi-phase heterogeneous traffic flow model integrating the perceptual range difference under human-driven and connected vehicles environment," *Chaos, Solitons & Fractals*, vol. 182, p. 114791, 2024.
- [2] A. Geiger, P. Lenz, C. Stiller, and R. Urtasun, "Vision meets robotics: The kitti dataset," *The international journal of robotics research*, vol. 32, no. 11, pp. 12311237, 2013.
- [3] P. Sun, H. Kretschmar, X. Dotiwalla, et al., "Scalability in perception for autonomous driving: Waymo open dataset," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 2446-2454.
- [4] H. Caesar, V. Bankiti, A. H. Lang, et al., "Nuscenes: A multimodal dataset for autonomous driving," 發表於

- Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020, pp. 11621-11631.
- [5] M.-F. Chang, J. Lambert, P. Sangkloy, et al., "Argoverse: 3d tracking and forecasting with rich maps," 發表於 Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019, pp. 8748-8757.
- [6] J. Geyer, Y. Kassahun, M. Mahmudi, et al., "A2d2: Audi autonomous driving dataset," arXiv 預印本 arXiv:2004.06320, 2020.
- [7] A. Patil, S. Malla, H. Gang, and Y.-T. Chen, "The h3d dataset for full-surround 3d multi-object detection and tracking in crowded urban scenes," 發表於 2019 International Conference on Robotics and Automation (ICRA), IEEE, 2019, pp. 9552-9557.
- [8] J. Mao, M. Niu, C. Jiang, et al., "One million scenes for autonomous driving: Once dataset," arXiv preprint arXiv:2106.11037, 2021.
- [9] P. Xiao, Z. Shao, S. Hao, et al., "Pandaset: Advanced sensor suite dataset for autonomous driving," in 2021 IEEE international intelligent transportation systems conference (ITSC), IEEE, 2021, pp. 3095-3101.
- [10] H. Wang, X. Zhang, Z. Li, et al., "Ips300+: A challenging multi-modal data sets for intersection perception system," in 2022 International Conference on Robotics and Automation (ICRA), IEEE, 2022, pp. 2539-2545.
- [11] S. Busch, C. Koetsier, J. Axmann, and C. Brenner, "Lumpi: The leibniz university multi-perspective intersection dataset," in 2022 IEEE Intelligent Vehicles Symposium (IV), IEEE, 2022, pp. 1127-1134.
- [12] W. Zimmer, C. Creß, H. T. Nguyen, and A. C. Knoll, "Tumtraf intersection dataset: All you need for urban 3d camera-lidar roadside perception," 於 2023 IEEE 26th International Conference on Intelligent Transportation Systems (ITSC), IEEE, 2023, pp. 1030-1037.
- [13] J. Mirlach, L. Wan, A. Wiedholz, H. E. Keen, and A. Eich, "R-livit: A lidar-visual-thermal dataset enabling vulnerable road user focused roadside perception," arXiv 預印本 arXiv:2503.17122, 2025.
- [14] C. Creß, W. Zimmer, L. Strand, et al., "A9-dataset: Multi-sensor infrastructure-based dataset for mobility research," 於 2022 IEEE Intelligent Vehicles Symposium (IV), IEEE, 2022, pp. 965-970.
- [15] X. Ye, M. Shu, H. Li, et al., "Rope3d: The roadside perception dataset for autonomous driving and monocular 3d object detection task," 於 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 21 341-21 350.
- [16] H. Yu, Y. Luo, M. Shu, et al., "Dair-v2x: A large-scale dataset for vehicle-infrastructure cooperative 3d object detection," 發表於 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 21361-21 370.
- [17] H. Xiang, Z. Zheng, X. Xia, et al., "V2x-real: A largesscale dataset for vehicle-to-everything cooperative perception," 發表於 European Conference on Computer Vision, Springer, 2024, pp. 455-470.
- [18] D. Yongqiang, W. Dengjiang, C. Gang, et al., "Baaivanjee roadside dataset: Towards the connected automated vehicle highway technologies in challenging environments of china," arXiv 預印本 arXiv:2105.14370, 2021.
- [19] R. Xu, X. Xia, J. Li, et al., "V2v4real: A real-world large-scale dataset for vehicle-to-vehicle cooperative perception," 發表於 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023, pp. 13712-13722.
- [20] R. Krajewski, J. Bock, L. Kloeker, and L. Eckstein, "The highd dataset: A drone dataset of naturalistic vehicle trajectories on german highways for validation of highly automated driving systems," in 2018 21st international conference on intelligent transportation systems (ITSC), IEEE, 2018, pp. 2118-2125.
- [21] Y. Li, W. Yuan, S. Zhang, et al., "Choose your simulator wisely: A review on open-source simulators for autonomous driving," IEEE Transactions on Intelligent Vehicles, 2024.
- [22] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun, "Carla: An open urban driving simulator," in Conference on robot learning, PMLR, 2017, pp. 1-16.
- [23] D. Team, Deepdrive: A simulator that allows anyone with a pc to push the state-of-the-art in self-driving, 2020.
- [24] A. Amini, T.-H. Wang, I. Gilitschenski, et al., "Vista 2.0: An open, data-driven simulator for multimodal sensing and policy learning for autonomous vehicles," 於 2022 International Conference on Robotics and Automation (ICRA), IEEE, 2022, pp. 2419-2426.
- [25] F. E. Nowruzi, P. Kapoor, D. Kolhatkar, F. A. Hassanat, R. Laganieri, and J. Rebut, "How much real data do we actually need: Analyzing object detection performance using synthetic and real data," arXiv 預印本 arXiv:1907.07061, 2019.
- [26] S. Manivasagam, S. Wang, K. Wong, et al., "Lidarsim: Realistic lidar simulation by leveraging the real world," 於 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020, pp. 11167-11 176.
- [27] D. Dworak, F. Ciepila, J. Derbis, I. Izzat, M. Komorkiewicz, and M. Wójcik, "Performance of lidar object detection deep learning architectures based on artificially generated point cloud data from carla simulator," 於 2019 24th International Conference on Methods and Models in Automation and Robotics (MMAR), 2019, pp. 600-605. DOI: 10.1109/MMAR.2019.8864642.
- [28] L. T. Triess, M. Dreissig, C. B. Rist, and J. M. Zöllner, "A survey on deep domain adaptation for lidar perception," in 2021 IEEE intelligent vehicles symposium workshops (IV workshops), IEEE, 2021, pp. 350-357.
- [29] OpenStreetMap contributors, Planet dump retrieved from <https://planet.osm.org>, <https://www.openstreetmap.org>, 2017.
- [30] Z. Liu, J. Hou, X. Ye, T. Wang, J. Wang, and X. Bai, "Seed: A simple and effective 3d detr in point clouds," in European Conference on Computer Vision, Springer, 2024, pp. 110-126.
- [31] L. McInnes, J. Healy, and J. Melville, "Umap: Uniform manifold approximation and projection for dimension reduction," arXiv preprint arXiv:1802.03426, 2018.
- [32] M. Shahbaz and S. Agarwal, UT-LUMPI, 版本 V1, 2025. doi: 10.7910/DVN/D9SSWD. [線上]. 取得來源:

<https://doi.org/10.7910/DVN/D9SSWD>.

[33] M. Shahbaz and S. Agarwal, UT-V2X-Real-IC, 版本 V2, 2025. doi: 10.7910/DVN/N6N4UR. [線上]. 取得來源: <https://doi.org/10.7910/DVN/N6N4UR>.

[34] M. Shahbaz and S. Agarwal, UT-TUMTraf-I, 版本 V2, 2025. dor: 10.7910/DVN/D21HNZ. [線上]. 取得來源: <https://doi.org/10.7910/DVN/D21HNZ>.

[35] S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, and J. W. Vaughan, "A theory of learning from different domains," *Machine learning*, vol. 79, pp. 151175, 2010.

[36] Y. Wang, X. Chen, Y. You, et al., "Train in germany, test in the usa: Making 3d object detectors generalize," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 11713-11723.

[37] D. Tsai, J. S. Berrio, M. Shan, S. Worrall, and E. Nebot, "See eye to eye: A lidar-agnostic 3d detection framework for unsupervised multi-target domain adaptation," *IEEE Robotics and Automation Letters*, vol. 7, no. 3, pp. 7904-7911, 2022.

[38] D. Dworak, F. Ciepiela, J. Derbis, I. Izzat, M. Komorkiewicz, and M. Wójcik, "Performance of lidar object detection deep learning architectures based on artificially generated point cloud data from carla simulator," in *2019 24th International Conference on Methods and Models in Automation and Robotics (MMAR)*, IEEE, 2019, pp. 600-605.

[39] J. Fang, D. Zhou, F. Yan, et al., "Augmented lidar simulator for autonomous driving," *IEEE Robotics and Automation Letters*, vol. 5, no. 2, pp. 1931-1938, 2020.

[40] X. Yue, B. Wu, S. A. Seshia, K. Keutzer, and A. L. Sangiovanni-Vincentelli, "A lidar point cloud generator: From a virtual world to autonomous driving," in *Proceedings of the 2018 ACM on international conference on multimedia retrieval*, 2018, pp. 458-464.

[41] S. Spiegel and J. Chen, "Using simulation data from gaming environments for training a deep learning algorithm on 3d point clouds," *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. 8, pp. 67-74, 2021.

[42] B. Guillard, S. Vemprala, J. K. Gupta, et al., "Learning to simulate realistic lidars," in *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE, 2022, pp. 8173-8180.

[43] G. Rong, B. H. Shin, H. Tabatabaee, et al., "Lgsvl simulator: A high fidelity simulator for autonomous driving," in *2020 IEEE 23rd International conference on intelligent transportation systems (ITSC)*, IEEE, 2020, pp. 1-6.

[44] L. Zhou, Y. Song, Y. Gao, et al., "Garchingsim: An autonomous driving simulator with photorealistic scenes and minimalist workflow," 於 *2023 IEEE 26th International Conference on Intelligent Transportation Systems (ITSC)*, IEEE, 2023, pp. 4227-4232.

[45] A. Haider, M. Pigniczki, M. H. Köhler, et al., "Development of high-fidelity automotive lidar sensor model with standardized interfaces," *Sensors*, vol. 22, no. 19, p. 7556, 2022. doi: 10.3390/s22197556.

[46] B. Wu, A. Wan, X. Yue, and K. Keutzer, "Squeezeseg: Convolutional neural nets with recurrent crf for real-time road-object segmentation from 3d lidar point cloud," 於 *2018 IEEE international conference on robotics and automation (ICRA)*, IEEE, 2018, pp. 18871893.

[47] B. Wu, X. Zhou, S. Zhao, X. Yue, and K. Keutzer, "Squeezesegv2: Improved model structure and unsupervised domain adaptation for road-object segmentation from a lidar point cloud," 於 *2019 international conference on robotics and automation (ICRA)*, IEEE, 2019, pp. 4376-4382.

[48] S. Zhao, Y. Wang, B. Li, et al., "Epointda: An end-to-end simulation-to-real domain adaptation framework for lidar point cloud segmentation," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, 2021, pp. 3500-3509.

[49] J. Behley, M. Garbade, A. Milioto, et al., "Semantickitti: A dataset for semantic scene understanding of lidar sequences," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2019, pp. 9297-9307.

[50] H. Haghighi, M. Dianati, V. Donzella, and K. Debattista, "CoLiGen: A unified generative framework for realistic lidar simulation in autonomous driving," *IEEE Trans. Intell. Vehicles*, 2024.

[51] J. Yang, S. Shi, Z. Wang, H. Li, and X. Qi, "St3d: Self-training for unsupervised domain adaptation on 3d object detection," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2021, pp. 10368-10378.

[52] M. Li, C. Liu, X. Pan, and Z. Li, "Digital twin-assisted graph matching multi-task object detection method in complex traffic scenarios," *Scientific Reports*, vol. 15, no. 1, p. 10847, 2025.

[53] M. Strunz, R. Protzmann, and I. Radusch, "Crossdataset generalization: Bridging the gap between real and synthetic lidar data," in *International Conference on Simulation Tools and Techniques*, Springer, 2024, pp. 202-217.

[54] P. A. Lopez, M. Behrisch, L. Bieker-Walz, et al., "Microscopic traffic simulation using sumo," in *The 21st IEEE International Conference on Intelligent Transportation Systems*, IEEE, 2018. [Online]. Available:

<https://elib.dlr.de/124092/>.

[55] I. The MathWorks, Roadrunner version: R2024b, Natick, Massachusetts, United States, 2024. [Online]. Available: <https://www.mathworks.com/products/roadrunner.html>.

[56] O. D. Team, Openpcdet: An open-source toolbox for 3d object detection from point clouds, <https://github.com/openmmlab/OpenPCDet>, 2020.

[57] Y. Chen, J. Liu, X. Zhang, X. Qi, and J. Jia, "Voxelnext: Fully sparse voxelnet for 3d object detection and tracking," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 21674-21683.



Muhammad Shahbaz 熱衷於進階電腦視覺 (Advanced Computer Vision) 與人工智慧 (AI) 的跨領域研究，及其在智慧型運輸系統 (ITS) 與智慧機器人領域的應用。他於巴基斯坦拉瓦爾品第的 Pir Mehr Ali Shah Arid Agriculture University 獲得電腦科學學士學位，並於伊斯蘭馬巴德的 Pakistan Institute of Engineering and Applied Sciences 獲得電腦科學碩士學位。自 2021 年起，他在美國中佛羅里達大學 (University of Central Florida) 攻讀土木工程博士學位。他在博士期間的研究重點在於利用高真度模擬 (high-fidelity simulation) 與多模態感測器融合 (multimodal sensor fusion)，為智慧型運輸系統開發高效且有效的 3D 感知系統。

SHAURYA AGARWAL (IEEE 高級會員)



目前擔任 University of Central Florida 土木、環境與建築工程系的副教授。他是城市智慧與智慧城市 (URBANITY) 實驗室的創始主任、UCF 未來城市倡議 (Future City Initiative) 的主任，並擔任 UCF 智慧城市碩士學程的協調人。他先前 (2016-18 年) 曾擔任 California State University, Los Angeles 電機與電腦工程系的助理教授。他在 New York University 完成博士後研究 (2016 年)，並於 University of Nevada, Las Vegas 取得電機工程博士學位 (2015 年)。他的學士學位 (B.Tech.) 畢業於 Indian Institute of Technology (IIT), Guwahati 的電機與通訊工程系 (ECE)。他的研究專注於網路實體系統 (cyber-physical systems)、智慧聯網交通以及聯網與自動駕駛車輛等跨領域領域。他熱衷於跨學科研究，在工作中整合了控制理論、資訊科學、數據驅動技術和數學建模。截至 2025 年 5 月，他已出版一本書籍、發表超過 37 篇經同儕審查的期刊論文以及多篇會議論文。他的研究工作獲得了多個私人 and 政府機構的資助。他是 IEEE 資深會員，並擔任 IEEE Transactions on Intelligent Transportation Systems 的副主編。

本論文由 IEEE 出版技術小組 (IEEE Publication Technology Group) 製作。該小組位於紐澤西州皮斯卡特維 (Piscataway, NJ)。

稿件收到日期：2021 年 4 月 19 日；修訂日期：2021 年 8 月 16 日。

Muhammad Shahbaz 與 Shaurya Agarwal 任職於 University of Central Florida 土木、環境與建築工程系，地址：Orlando, FL 32816, USA。