

克服模擬與現實的差距：利用模擬學習探索以實現現實世界的強化學習

Andrew Wagenmaker¹ Kevin Huang² Liyiming Ke²

Byron Boots²

Kevin Jamieson² Abhishek Gupta²

¹ 加州大學柏克萊分校 ² 華盛頓大學

ajwagen@berkeley.edu,

{kehuang,kayke,bboots,jamieson,abhgupta}@cs.washington.edu

摘要

為了降低現實世界強化學習 (reinforcement learning) 的樣本複雜度 (sample complexity)，常見的做法是先在樣本成本較低的模擬器中訓練策略 (policy)，然後將此策略部署到現實世界中，並期望其能有效泛化。然而，這種直接的 sim2real 轉移並不保證成功，且在失敗的情況下，目前尚不清楚如何最有效地利用模擬器。在這項工作中，我們展示了在許多情況下，雖然直接的 sim2real 轉移可能會失敗，但我們可以利用模擬器學習一組探索性策略 (exploratory policies)，從而實現現實世界中的高效探索。特別是在低秩 MDP (low-rank MDPs) 的設定下，我們證明將這些探索性策略與簡單且實用的方法 (最小平方法回歸 oracle 和樸素隨機探索) 相結合，可以在現實世界中產生多項式級別的樣本複雜度。與直接的 sim2real 轉移或在沒有模擬器的情況下進行學習相比，這是一個指數級的進步。據我們所知，這是首個證明在直接 sim2real 轉移失敗的情況下，模擬轉移仍能在強化學習中產生可證明的增益之證據。我們在多個真實的機器人模擬器以及現實世界的機器人 sim2real 任務上驗證了我們的理論結果，證明了轉移探索性策略在實踐中也能帶來顯著的增益。

1 導論

在過去十年間，強化學習 (RL) 技術已被部署於解決各種現實世界的難題，應用範圍涵蓋機器人學、自然科學及其他領域 (Kober et al., 2013; Silver et al., 2016; Rajeswaran et al., 2017; Kiran et al., 2021; Ouyang et al., 2022; Kaufmann et al., 2023)。儘管前景看好，但 RL 方法的廣泛應用一直受到其龐大樣本複雜度 (sample complexity) 的嚴重限制，即演算法為學習解決目標任務而必須與環境進行互動的次數。在受關注的應用中，收集樣本通常成本極高，而 RL 演算法所需的樣本數量往往昂貴到令人望而卻步。

在許多領域中，雖然在目標部署環境中收集樣本可能非常昂貴，但我們通常可以使用模擬器 (simulator)，其樣本成本幾乎可以忽略不計。舉一個具體的例子，在以現實世界部署為目標的機器人應用中，直接在現實世界進行訓練通常需要多到不可行的樣本數量。然而，通常可以獲得一個模擬器——源自第一性原理或對機器人驅動機制的瞭解——它提供了現實部署環境的近似模型。有了這樣的模擬器，常見的做法是先在模擬器中訓練一個策略 (policy) 來完成目標任務，然後再將其部署到現實世界中，並期望該策略能有效地從模擬器泛化 (generalize) 到目標部署環境。




圖 1：左側：在推冰球 (puck pushing) 任務中，我們的方法與標準 sim2real 遷移的概覽對比。標準 sim2real 遷移先在模擬環境中訓練一個策略來解決目標任務，然後將此策略遷移到現實環境。由於 sim2real 差距 (sim2real gap)，該策略可能無法在現實中解決任務，此外，它可能無法提供足夠的數據覆蓋率 (data coverage)，以在現實中成功學習到能解決目標任務的策略。相比之下，我們的方法在模擬環境中訓練一組探索性策略，這些策略在現實中部署時能獲得高覆蓋率的數據，即使它們無法在零樣本 (0-shot) 情況下解決任務。這些高覆蓋率數據隨後可用於成功學習一個能在現實中解決目標任務的策略。右側：在左側所示的推冰球任務上運行我們方法與標準 sim2real 遷移的量化結果對比。在 6 次現實世界實驗中，我們的方法解決了任務 6/6 次，而標準 sim2real 遷移解決了任務 0/6 次。

事實上，這種「sim2real」遷移已成為 RL 應用於機器人場景以及自然科學等許多其他感興趣領域 (Degraeve et al., 2022; Ghugare et al., 2023) 的關鍵環節，並且是降低 RL 在現實世界部署中樣本複雜度的一種極具前景的方法 (James et al.,

2018; Akkaya et al., 2019; Höfer et al., 2021)。

然而，有效的 sim2real 轉移可能具有挑戰性，因為模擬環境與真實環境之間通常存在不小的落差。現實世界難以完美建模，某些差異是不可避免的。因此，直接將在模擬器中訓練的策略 (policy) 轉移到現實世界通常會失敗，模擬與現實之間的落差會導致在模擬環境中能完美解決任務的策略，在現實中卻完全無法達成任務。雖然已有研究嘗試解決此問題——例如，利用領域隨機化 (domain randomization) 來擴展模擬器涵蓋的環境空間 (Tobin et al., 2017; Peng et al., 2018)，或是在現實世界中對模擬學習到的策略進行微調 (finetuning) (Peng et al., 2020; Zhang et al., 2023) ——但這些方法並不保證成功。在這些方法失效的情境下，我們是否仍能利用模擬器來加速現實世界的 RL？

在這項工作中，我們朝著開發具備理論基礎的 sim2real 轉移方法邁進，以解決這個問題。我們的核心直覺是：學習「探索」通常比學習「解決目標任務」更容易。雖然解決目標任務可能需要非常精確的動作，但收集高品質的探索數據所需的精度則顯著較低。例如，成功解決複雜的機器人操作任務需要特定的動作序列，但若只是要取得一個能以某種方式與目標物體互動、並提供其行為相關有用探索數據的策略，所需的精度則低得多。

正式地說，我們證明了在 low-rank MDPs 的設定下，當「模擬」與「現實」環境之間的動態 (dynamics) 存在落差時，即使這種落差導致直接的 sim2real 轉移失敗，在特定條件下，我們仍能有效地將一組探索策略從模擬環境轉移到現實環境。特別是，我們證明了獲取這些探索策略，結合隨機探索 (random exploration) 與最小平方方法迴歸 oracle (least-squares regression oracle) ——這些方法本身不足以實現高效學習，但因其簡單性在實務中仍常被採用——能夠在現實環境中實現可證明的 (provably) 高效學習。因此，我們的結果顯示，若能謹慎應用，模擬器可以產生相對於單純 sim2real 轉移以及無模擬器學習的可證明指數級增益 (exponential gain)，並使實務中常用的演算法能夠高效學習。

此外，我們的結果提出了一個簡單且易於實作的演算法原則：與其訓練並轉移一個在模擬器中解決任務的策略，不如利用模擬器訓練一組探索性策略 (exploratory policies)，並將這些策略結合隨機探索轉移到現實世界，以在現實中生成高品質的探索數據。我們透過逼真的機器人模擬器以及在 Franka 機器人平台上的真實 sim2real 轉移問題進行實驗證明，這種將探索性策略從模擬轉移到現實的原則，在樣本效率上帶來了顯著的實際提升，通常能在天真轉移 (naive transfer) 完全失敗的設定下實現高效學習 (見圖 1)。

2 相關工作

強化學習 (RL) 中的可證明轉移。或許 RL 轉移領域的第一個理論結果是「模擬引理」 (simulation lemma)，它將動態系統之間全變分距離 (total-variation distance) 的界限轉換為策略價值的界限 (Kearns & Koller, 1999; Kearns & Singh, 2002; Brafman & Tennenholtz, 2002; Kakade et al., 2003) ——我們在後文將其列為命題 2，並論證透過探索轉移可以取得顯著更好的結果。較近期的研究考慮了區塊 MDP (block MDPs) 設定下的轉移 (Liu et al., 2022)，但這需要對來源與目標 MDP 之間的相似性有較強的假設，且未提供相對於真實最佳策略的次優性 (suboptimality) 保證；或是考慮元強化學習 (meta-RL) 設定 (Ye et al., 2023)，但僅限於表格型 MDP，並假設目標 MDP 被訓練分佈所覆蓋，這比我們的任務簡單得多。與本研究最相關的或許是 Malik et al. (2021) 的工作，該研究提出了幾個下界，顯示在一般情況下 RL 中的高效轉移是不可行的。相對於該研究，我們的工作可以被視為提供了一組確實能實現高效轉移的充分條件；Malik et al. (2021) 提出的下界並不適用於我們所考慮的低秩 MDP (low-rank MDP) 設定。雖然還有其他幾項研究存在，但若非考慮與我們不同的轉移類型 (例如：觀測空間不匹配)，就是僅學習到其次優性受限於 sim2real 錯配程度的策略 (Mann & Choe, 2013; Song et al., 2020; Sun et al., 2022)。另一類與我們略有相關的研究考慮了 RL 中的表示轉移 (representation transfer)，其中假設來源與目標任務共享共同的表示 (Lu et al., 2021; Cheng et al., 2022; Agarwal et al., 2023)。我們也注意到，我們所考慮的形式化 sim2real 設定與 Silva et al. (2023) 的 MF-MDP 設定密切相關 (事實上，它是該設定的一個特例)。

模擬器與低秩 MDP。在強化學習 (RL) 理論社群中，「模擬器」通常被用來指代一個可以根據需求重設 (reset) 到任何指定狀態的環境。現有的多項研究顯示，與僅允許線上展開 (online rollouts) 的標準 RL 設定相比，在這種設定下進行訓練具有可證明的優勢 (Weisz et al., 2021; Li et al., 2021; Amortila et al., 2022; Weisz et al., 2022; Yin et al., 2022; Mhammedi et al., 2024b)。然而，這些研究並未考慮遷移問題 (transfer problem)，此外，它們所要求的模擬器重設模型比我們在本研究中考慮的更為強大。

我們所考慮的線性與低秩 MDP 設定在過去幾年中受到了極大的關注，且已存在許多可證明的效率演算法 (Jin et al., 2020; Agarwal et al., 2020; Uehara et al., 2021; Wagenmaker & Jamieson, 2022; Modi et al., 2024; Mhammedi et al., 2024a)。與本研究相比，為了實現高效學習，這些研究大多假設可以存取強大的運算 oracle，而這在實務中往往難以取得；我們則僅考慮存取簡單的最小平方方法迴歸 (least-squares regression) oracle。除了理論文獻之外，近期的研究也顯示低秩 MDP 在實務上能有效模擬各種標準的 RL 設定 (Zhang et al., 2022)。

Sim2Real 轉移的實務應用。關於 Sim2Real 轉移實務應用的文獻非常廣泛，我們在此僅列舉特別相關的作品；完整綜述請參閱 Zhao et al. (2020)。為了減輕模擬器與現實世界物理參數及建模之間的不一致性，一種常用的方法是領域隨機化 (Domain Randomization)，其在具有隨機屬性的多種模擬環境中訓練策略，希望學習到的策略能對底層參數的變化具有強健性 (Tobin et al., 2017; Peng et al., 2018; Muratore et al., 2019; Chebotar et al., 2019; Mehta et al., 2020)。相比之下，領域適應 (Domain Adaptation) 則是建構部署條件 (例如物理條件或過去歷史) 的編碼，並透過匹配編碼來適應部署環境 (Kumar et al., 2021; Chen et al., 2023; Wang et al., 2016; Sinha et al., 2022; Margolis et al., 2023; Memmel et al., 2024)。而我們的工作則假設存在根本性的 Sim2Real 錯配，即我們不預期現實系統在任何參數設置下都能與模擬器

匹配，因此領域隨機化和適應不太可能成功。另一支相關的研究路線是尋求在現實環境部署時，直接對在模擬環境中訓練的策略進行微調（Finetune）（Julian et al., 2021; Smith et al., 2022）；我們的工作與這些研究互補，因為我們的目標不是直接轉移一個能在新環境中解決任務的策略，而是探索環境。最後，我們提到雖然所考慮的設定與我們略有不同，但強健式強化學習（Robust RL）文獻中的研究已表明，訓練探索性策略可以提高對環境不確定性的強健性（Eysenbach & Levine, 2021; Jiang et al., 2023）。

3 預備知識

我們令 $\triangle_{\mathcal{X}}$ 表示集合 $\mathcal{X}, [H] := \{1, 2, \dots, H\}$ 上的分佈集合， $\|P - Q\|_{\text{TV}}$ 表示分佈 P 與 Q 之間的總變異距離（Total-variation distance）。我們令 $\mathbb{E}^{\mathcal{M}}[\cdot]$ 表示在 MDP $\mathcal{M}$ 上的期望值，並令 $\mathbb{E}^{\mathcal{M}, \pi}[\cdot]$ 表示在 $\mathcal{M}$ 上執行策略 π 的期望值。

馬可夫決策過程（Markov Decision Processes）。我們考慮情節式馬可夫決策過程（Episodic MDPs）的設定。一個 MDP 由元組 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \{P_h\}_{h=1}^H, \{r_h\}_{h=1}^H, s_1, H)$ 表示，其中 $\mathcal{S}$ 表示狀態集合， $\mathcal{A}$ 表示動作集合， $P_h: \mathcal{S} \times \mathcal{A} \rightarrow \triangle_{\mathcal{S}}$ 為轉移函數， $r_h: \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$ 為獎勵（我們假設其為確定性且已知）， s_1 為初始狀態，而 H 為時域（Horizon）。我們假設 $\mathcal{A}$ 是有限的並記作 $A := |\mathcal{A}|$ 。與 MDP 的互動從狀態 s_1 開始，代理人採取某個動作 a_1 ，轉移到狀態 $s_2 \sim P_1(\cdot | s_1, a_1)$ ，並獲得獎勵 $r_1(s_1, a_1)$ 。此過程持續 H 個步驟，屆時情節終止，過程重置。

學習者的目標是找到一個能獲得最大獎勵的策略 $\pi = \{\pi_h\}_{h=1}^H, \pi_h: \mathcal{S} \rightarrow \triangle_{\mathcal{A}}$ 。我們可以透過價值（Value）函數與 Q 價值函數來量化某個策略 π 所獲得的獎勵。 Q 價值函數的定義如下：

$$Q_h^\pi(s, a) := \mathbb{E}^\pi \left[\sum_{h'=h}^H r_{h'}(s_{h'}, a_{h'}) \mid s_h = s, a_h = a \right]$$

策略 π 在第 h 步處於狀態 s 時，執行動作 a ，並在隨後所有剩餘步驟中執行 π 所獲得的預期獎勵。價值函數根據 Q 價值函數定義為 $V_h^\pi(s) := \mathbb{E}_{a \sim \pi_h(\cdot | s)} [Q_h^\pi(s, a)]$ 。策略 π 的價值（即其預期獎勵）記為 $V_0^\pi := V_1^\pi(s_1)$ ，而最佳策略的價值（即最高可達成獎勵）則記為 $V_0^* := \sup_{\pi} V_0^\pi$ 。

在本研究中，我們感興趣的情境是：我們希望解決「真實」環境（以 MDP 表示）中的某項任務，且我們可以存取一個在某種程度上近似真實環境的模擬器。我們將真實 MDP 記為 $\mathcal{M}^{\text{real}}$ ，模擬器記為 $\mathcal{M}^{\text{sim}}$ 。我們假設 $\mathcal{M}^{\text{real}}$ 與 $\mathcal{M}^{\text{sim}}$ 具有相同的狀態與動作空間、獎勵函數以及初始狀態，但具有不同的轉移函數 P^{real} 與 P^{sim} ¹。我們分別將 $\mathcal{M}^{\text{real}}$ 與 $\mathcal{M}^{\text{sim}}$ 中的價值函數記為 $V_h^{\text{real}, \pi}(s)$ 與 $V_h^{\text{sim}, \pi}(s)$ 。我們對 $\mathcal{M}^{\text{real}}$ 與 $\mathcal{M}^{\text{sim}}$ 之間的關係做出以下假設。

假設 1。對於所有 $(s, a, h) \in \mathcal{S} \times \mathcal{A} \times [H]$ 及某些 $\epsilon_{\text{sim}} > 0$ ，我們有：

$$\|P_h^{\text{real}}(\cdot | s, a) - P_h^{\text{sim}}(\cdot | s, a)\|_{\text{TV}} \leq \epsilon_{\text{sim}}.$$

我們並不假設 ϵ_{sim} 的值是已知，僅假設存在某個這樣的 ϵ_{sim} 。

函數逼近（Function Approximation）。為了實現高效學習，需要對感興趣的 MDP 具備某些結構。我們將假設 $\mathcal{M}^{\text{real}}$ 與 $\mathcal{M}^{\text{sim}}$ 為低秩 MDP（low-rank MDPs），定義如下。

定義 3.1（低秩 MDP）。若存在某種特徵化（featurization） $\phi: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}^d$ 與測度（measure） $\mu: [H] \times \mathcal{S} \rightarrow \mathbb{R}^d$ 使得：，則我們稱該 MDP 為維度 d 的低秩 MDP。

$$P_h(\cdot | s, a) = \langle \phi(s, a), \mu_h(\cdot) \rangle, \quad \forall s, a, h.$$

我們假設對於所有的 (s, a) 與所有的 h ， $\|\mu_h(\mathcal{S})\|_2 = \left\| \int_{s \in \mathcal{S}} d\mu_h(s) \right\|_2 \leq \sqrt{d}$ ， $\|\phi(s, a)\|_2 \leq 1$ 皆成立。形式上，我們對 $\mathcal{M}^{\text{sim}}$ 與 $\mathcal{M}^{\text{real}}$ 的結構做出以下假設。

假設 2。 $\mathcal{M}^{\text{sim}}$ 與 $\mathcal{M}^{\text{real}}$ 皆符合定義 3.1，其特徵映射（feature maps）與測度（measures）分別為 (ϕ^s, μ^s) 與 (ϕ^r, μ^r) 。此外， ϕ^s 為已知，但 μ^s, ϕ^r 與 μ^r 皆為未知。

在文獻中，符合定義 3.1 且 ϕ 為已知的 MDP 通常被稱為「線性（linear）」MDP；而符合定義 3.1 但 ϕ 為未知的 MDP 則通常被稱為「低秩（low-rank）」MDP。根據此術語， $\mathcal{M}^{\text{sim}}$ 為線性 MDP²，而 $\mathcal{M}^{\text{real}}$ 則為低秩 MDP。我們對 $\mathcal{M}^{\text{sim}}$ 做出以下可達性（reachability）條件假設。

假設 3。存在某個 $\lambda_{\min}^* > 0$ ，使得在 $\mathcal{M}^{\text{sim}}$ 中我們有

$$\min_h \sup_{\pi} \lambda_{\min} \left(\mathbb{E}^{\mathcal{M}^{\text{sim}, \pi}} \left[\phi^s(s_h, a_h) \phi^s(s_h, a_h)^\top \right] \right) \geq \lambda_{\min}^*$$

假設 3 斷定我們模擬器中特徵空間的每個方向都可以被某些策略激活，這可以被視為衡量每個方向可達性難易程度的一種指標。類似的假設先前曾出現在關於線性與低秩 MDP 的文獻中 (Zanette

et al., 2020; Agarwal et al., 2021, 2023)。請注意，我們僅在 $\mathcal{M}^{\text{sim}}$ 中需要此可達性假設，且不需要知道 $\lambda_{\min}^*$ 的值。

我們還假設可以存取函數類別 $\mathcal{F}_h : \mathcal{S} \times \mathcal{A} \rightarrow [0, H]$ 並令 $\mathcal{F} := \mathcal{F}_1 \times \mathcal{F}_2 \times \dots \times \mathcal{F}_H$ 。由於在第 $(H + 1)$ 步中沒有收集到獎勵，我們取 $f_{H+1} = 0$ 。對於任何 $f : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ ，我們令 $\pi_h^f(s) := \arg \max_{a \in \mathcal{A}} f_h(s, a)$ 。我們將 Bellman 算子定義在某個函數 $f_{h+1} : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 上，如下所示：

$$\mathcal{T}f_{h+1}(s, a) := r_h(s, a) + \mathbb{E}_{s' \sim P_h(\cdot | s, a)} \left[\max_{a'} f(s', a') \right]$$

我們對 $\mathcal{F}$ 做出以下標準假設。

假設 4 (Bellman 完備性)。對於所有 $f_{h+1} \in \mathcal{F}_{h+1}$ ，我們有

$$\mathcal{T}^{\text{real}} f_{h+1} \in \mathcal{F}_h \quad \text{and} \quad \mathcal{T}^{\text{sim}} f_{h+1} \in \mathcal{F}_h$$

其中 $\mathcal{T}^{\text{real}}$ 與 $\mathcal{T}^{\text{sim}}$ 分別代表在 $\mathcal{M}^{\text{real}}$ 與 $\mathcal{M}^{\text{sim}}$ 上的 Bellman 算子。

PAC 強化學習。我們的目標是找到一個能在 $\mathcal{M}^{\text{real}}$ 中獲得最大獎勵的策略 $\hat{\pi}$ 。正式而言，我們考慮 PAC (Probably-Approximately-Correct) RL 設定。

定義 3.2 (PAC 強化學習)。給定某些 $\epsilon > 0$ 與 $\delta > 0$ ，以至少 $1 - \delta$ 的機率識別出某個策略 $\hat{\pi}$ ，使得：

$$V_0^{\text{real}, \hat{\pi}} \geq V_0^{\text{real}, \star} - \epsilon$$

我們將特別專注於在模擬器的輔助下解決 PAC RL 問題，並如後文所述，盡可能使用來自 $\mathcal{M}^{\text{real}}$ 的最少樣本。誠如我們將看到的，雖然在 $\epsilon = \mathcal{O}(\epsilon_{\text{sim}})$ 的情況下，使用 $\mathcal{M}^{\text{sim}}$ 可以輕易達成此目標，但如果 $\epsilon \ll \epsilon_{\text{sim}}$ ，單純的轉移方法 (naive transfer methods) 可能完全無法達成此目標。因此，我們的主要重點將放在開發此機制下高效的 sim2real 方法。

4 理論結果

在本節中，我們提供主要的理論結果。我們首先呈現兩個負面結果：在第 4.1 節中，我們展示「單純探索 (naive exploration)」——僅利用最小平方方法回歸 oracle 以及隨機探索方法（如 ζ -greedy³）——在證明上是低效的；在第 4.2 節中，我們展示直接將最佳策略從 $\mathcal{M}^{\text{sim}}$ 轉移到 $\mathcal{M}^{\text{real}}$ ，無法在真實環境中高效地獲得次優性 (suboptimality) 優於 $\mathcal{O}(\epsilon_{\text{sim}})$ 的策略。接著在第 4.3 節中，我們呈現主要的正面結果，展示透過利用與第 4.1 節和第 4.2 節相同的 oracle ——最小平方方法回歸 oracle、模擬器存取權限以及隨機採取動作的能力——我們可以藉由謹慎地利用模擬器來學習探索策略，進而在 $\mathcal{M}^{\text{real}}$ 內高效地為 $\epsilon \ll \epsilon_{\text{sim}}$ 學習到一個 ϵ -最佳策略。

4.1 單純探索在證明上是低效的

雖然已有許多研究開發出在低秩 MDP (low-rank MDPs) 中解決 PAC RL 且可證明其效率的方法 (Agarwal et al., 2020; Uehara et al., 2021; Modi et al., 2024; Mhammedi et al., 2024a)，但這些作品通常依賴於複雜的計算 Oracle 或精心設計的探索策略，而這些在實務中鮮少被使用。相比之下，實務中使用的 RL 方法通常依賴於「簡單」的計算 Oracle 和探索策略。在考慮 sim2real 設定之前，我們首先證明這類「簡單」策略不足以實現高效的 PAC RL。為了實例化這些策略，我們考慮一個在實務中經常可用的最小平方方法迴歸 (least-squares regression) Oracle。

Oracle 4.1 (最小平方方法迴歸 Oracle)。我們假設可以存取一個最小平方方法迴歸 Oracle，使得對於任何 h 和資料集 $\mathcal{D} = \{(s^t, a^t, y^t)\}_{t=1}^T$ ，我們可以計算：

$$\arg \min_{f \in \mathcal{F}_h} \sum_{t=1}^T (f(s^t, a^t) - y^t)^2.$$

我們將此 Oracle 與「天真探索 (naive exploration)」結合，此處我們指代任何不刻意選擇動作進行探索，而是透過隨機擾動當前估計之最佳策略所建議的動作來進行探索的方法。雖然存在多種天真探索的實例化方式 (例如參見 Dann et al. (2022))，但我們考慮一種特別常見的形式： ζ -greedy 探索。

Protocol 4.1 (ζ -Greedy 探索)。給定最小平方方法迴歸 Oracle 的存取權限、任何 $\zeta \in [0, 1]$ 以及時間範圍 (time horizon) T ，考慮以下協定：

與 $\mathcal{M}^{\text{real}}$ 互動 T 個回合 (episode)。在第 $t + 1$ 回合的每一步中，以機率 $1 - \zeta$ 執行 $\pi_h^{f^t}(s)$ ，否則執行 $a \sim \text{unif}(\mathcal{A})$ ，其中：

$$f_h^t = \arg \min_{f \in \mathcal{F}_h} \sum_{t'=1}^t \left(f(s_h^{t'}, a_h^{t'}) - r_h^{t'} - \max_{a'} f_{h+1}^t(s_{h+1}^{t'}, a') \right)^2$$

針對 $\mathcal{D}_t = \{(s_h^{t'}, a_h^{t'}, r_h^{t'}, s_{h+1}^{t'})\}_{t'=1}^t$ ，使用截至第 t 回合所收集的數據。

2. 以任何期望的方式使用收集到的數據，提出一個策略 $\hat{\pi}$ 。

Protocol 4.1 構成了許多實務中常用演算法的骨幹。儘管其應用廣泛，但如現有研究 (Dann et al., 2022) 以及下列結果所示，它在證明上是低效率的。

命題 1。對於任何 $H > 1, \zeta \in [0, 1]$ 與 $c \leq 1/6$ ，存在某些 $\mathcal{M}^{\text{real}, 1}$ 與 $\mathcal{M}^{\text{real}, 2}$ ，使得 $\mathcal{M}^{\text{real}, 1}$ 與 $\mathcal{M}^{\text{real}, 2}$ 皆滿足假設 2 與 4，且除非 $T \geq \Omega(2^{H/2})$ ，否則在執行協定 4.1 時，我們有：

$$\sup_{\mathcal{M}^{\text{real}} \in \{\mathcal{M}^{\text{real}, 1}, \mathcal{M}^{\text{real}, 2}\}} \mathbb{E}^{\mathcal{M}^{\text{real}}} \left[V_0^{\mathcal{M}^{\text{real}}, \star} - V_0^{\mathcal{M}^{\text{real}}, \hat{\pi}} \right] \geq c/32.$$

命題 1 表明，在極小化極大 (minimax) 的意義下， ζ -greedy 探索不足以實現可證明的效率強化學習：在 $\mathcal{M}^{\text{real}, 1}$ 與 $\mathcal{M}^{\text{real}, 2}, \zeta$ 之一中，除非我們採取指數級數量的樣本，否則 ζ -greedy 探索將只能找到一個次優 (suboptimal) 常數因子的策略。雖然我們在命題 1 中專注於 ζ -greedy 探索，但此結果可擴展到其他類型的樸素探索 (naive exploration)，例如 Dann 等人 (2022) 中提出的方法。有關命題 1 構建方式的進一步討論，請參見第 5.2 節。

4.2 理解直接 sim2real 轉移的限制

命題 1 顯示，一般而言，利用最小二乘迴歸 (least-squares regression) 算式配合 ζ -greedy 探索，不足以實現可證明的效率強化學習。在擁有模擬器 $\mathcal{M}^{\text{sim}}$ 的情況下，這是否能變得有效率？

在實務上，標準的 sim2real 方法論通常會在 $\mathcal{M}^{\text{sim}}$ 中訓練策略以完成目標任務，然後將此策略轉移到 $\mathcal{M}^{\text{real}}$ 。我們將此方法論稱為直接 sim2real 轉移 (direct sim2real transfer)。以下這項經典結果通常被稱為「模擬引理」 (simulation lemma) (Kearns & Koller, 1999; Kearns & Singh, 2002; Brafman & Tennenholtz, 2002; Kakade et al., 2003)，它為直接 sim2real 轉移在假設 1 下的成功提供了充分的保證。

命題 2 (模擬引理)。令 $\pi^{\text{sim}, \star}$ 代表 $\mathcal{M}^{\text{sim}}$ 中的最佳策略。則在假設 1 下：

$$V_0^{\text{real}, \pi^{\text{sim}, \star}} \geq V_0^{\text{real}, \star} - 2H^2 \epsilon_{\text{sim}}.$$

命題 2 顯示，只要 $\epsilon \geq 2H^2 \epsilon_{\text{sim}}$ ，直接 sim2real 轉移就能成功在 $\mathcal{M}^{\text{real}}$ 中獲得一個 ϵ -最佳策略。雖然這證明了在 $\mathcal{M}^{\text{sim}}$ 與 $\mathcal{M}^{\text{real}}$ 足夠接近的設定下，直接 sim2real 轉移是合理的，但我們接下來將展示，若僅能存取 $\pi^{\text{sim}, \star}$ 和最小平方迴歸 oracle (即使配合隨機探索)，我們也無法指望透過單純探索 (naive exploration) 在 $\mathcal{M}^{\text{real}}$ 上高效地獲得次佳度 (suboptimality) 小於 $\mathcal{O}(\epsilon_{\text{sim}})$ 的策略。為了將此形式化，我們考慮以下互動協定。

協定 4.2 (配合單純探索的直接 sim2real 轉移)。給定可存取的 $\pi^{\text{sim}, \star}$ 、 $\mathcal{M}^{\text{sim}}$ 中的最佳策略、任何 $\zeta \in [0, 1]$ 以及時間範圍 T ，考慮以下協定：

與 $\mathcal{M}^{\text{real}}$ 互動 T 個回合 (episodes)，且在每一步 h 與狀態 s 下，以機率 $1 - \zeta$ 執行 $\pi_h^{\text{sim}, \star}(\cdot | s)$ ，並以機率 ζ 執行 $a \sim \text{unif}(\mathcal{A})$ 。

以任何期望的方式使用收集到的數據，提出一個策略 $\hat{\pi}$ 。

Protocol 4.2 是文獻中常見的直接 sim2real 轉移 (direct sim2real transfer) 的標準實例，並將執行來自 $\mathcal{M}^{\text{sim}}$ 的最佳策略與原生探索 (naive exploration) 相結合。我們得到以下結果。

Proposition 3。採用與 Proposition 1 相同的 $\mathcal{M}^{\text{real}, 1}$ 與 $\mathcal{M}^{\text{real}, 2}$ 選擇，存在某個 $\mathcal{M}^{\text{sim}}$ 使得 $\mathcal{M}^{\text{real}, 1}$ 與 $\mathcal{M}^{\text{real}, 2}$ 皆滿足 Assumption 1 且針對 $\epsilon_{\text{sim}} \leftarrow c$ 其 $\mathcal{M}^{\text{sim}}$ ，且滿足 Assumptions 2 至 4，並且除非 $T \geq \Omega(2^H)$ ，否則在執行 Protocol 4.2 時，我們得到：

$$\sup_{\mathcal{M}^{\text{real}} \in \{\mathcal{M}^{\text{real}, 1}, \mathcal{M}^{\text{real}, 2}\}} \mathbb{E}^{\mathcal{M}^{\text{real}}} \left[V_0^{\mathcal{M}^{\text{real}}, \star} - V_0^{\mathcal{M}^{\text{real}}, \hat{\pi}} \right] \geq \epsilon_{\text{sim}} / 32.$$

命題 3 顯示，在某些設定下，存在兩個滿足假設 1 且 $\mathcal{M}^{\text{sim}}$ 的可能 $\mathcal{M}^{\text{real}}$ ，在此情況下，除非我們與 $\mathcal{M}^{\text{real}}$ 進行指數級次數 (相對於 H) 的片段互動，否則我們無法針對最差情況的 $\mathcal{M}^{\text{real}}$ 確定一個優於 $\Omega(\epsilon_{\text{sim}})$ -optimal 的策略。綜合命題 2 與 3 顯示，雖然我們可以利用直接的 sim2real 轉移來學習一個在 $\mathcal{M}^{\text{real}}$ 中為 $\mathcal{O}(\epsilon_{\text{sim}})$ -optimal 的策略，但如果我們的目標是為 $\epsilon \ll \epsilon_{\text{sim}}$ 學習一個 ϵ -optimal 的策略，直接的 sim2real 轉移將無法有效地達成此目標。

4.3 透過探索策略轉移實現高效的 sim2real 轉移

前述章節的結果顯示，一般而言，若 $\epsilon \ll \epsilon_{\text{sim}}$ ，直接策略轉移將無法成功；且使用最小平方方法回歸 oracle 搭配天真的探索方法，也會導致指數級的樣本複雜度。然而，這並不排除存在某種方式，能夠利用 $\mathcal{M}^{\text{sim}}$ 與最小平方方法回歸 oracle，在 $\mathcal{M}^{\text{real}}$ 中實現高效學習，即使在 $\epsilon \ll \epsilon_{\text{sim}}$ 的情況下亦然。

我們的核心見解是：與其轉移在 $\mathcal{M}^{\text{sim}}$ 中能最佳化解決任務的策略，我們應該轉移能在 $\mathcal{M}^{\text{sim}}$ 中有效進行探索的策略。雖然學習解決一項任務可能需要非常精確的動作，但我們通常可以透過相對不精確的動作來獲得足夠豐富的數據——學習探索比學習解決任務更容易。在這種設定下，由於模擬器的不精確性，直接轉移解決任務的策略很可能會失敗，但轉移一個能產生探索性數據的策略仍是可能的。

為了將其形式化，我們考慮以下對 $\mathcal{M}^{\text{sim}}$ 的存取模型。

Oracle 4.2 ($\mathcal{M}^{\text{sim}}$ 存取)。我們可以透過以下任一方式與 $\mathcal{M}^{\text{sim}}$ 互動：

(軌跡採樣) 對於任何策略 π ，採樣一個透過在 $\mathcal{M}^{\text{sim}}$ 上執行 π 所產生的軌跡 $\{(s_h, a_h, r_h, s_{h+1})\}_{h=1}^H$ 。

(策略最佳化) 對於任何獎勵 $\tilde{r}$ ，計算一個在 $\mathcal{M}^{\text{sim}}$ 上使 $\tilde{r}$ 最大化的策略 $\pi^{\text{sim}}(\tilde{r})$ 。

雖然在 $\mathcal{M}^{\text{real}}$ 中，獲取此類策略優化 Oracle 是不切實際的（因為我們的目標是最小化收集的樣本數），但鑑於在 $\mathcal{M}^{\text{sim}}$ 中獲取樣本的成本低廉，在實務上通常可以（近似地）實現此類 Oracle⁴。請注意，在 Oracle 4.2 下，我們僅假設對模擬器具有黑箱存取權限——我們並非被允許在任意狀態下查詢模擬器的行為，而僅是被允許在 $\mathcal{M}^{\text{sim}}$ 上執行策略（roll out）並計算最佳策略。

給定 Oracle 4.2 以及我們的最小平方方法迴歸 Oracle（Oracle 4.1），我們提出以下演算法。

Algorithm 1 sim2real Exploration Policy Transfer

```
input: budget  $\backslash(T\backslash)$ , confidence  $\backslash(\delta\backslash)$ , simulator  $\backslash(\mathcal{M}^{\text{sim}}\backslash)$ 
// Learn policies  $\backslash(\pi_{\text{exp}}^h\backslash)$  which cover feature space in  $\backslash(\mathcal{M}^{\text{sim}}\backslash)$ 
 $\backslash(\pi_{\text{exp}}^h \leftarrow \text{LearnExpPolicies}(\mathcal{M}^{\text{sim}}, \pi_{\text{exp}}^h)\backslash)$ 
// Explore in  $\backslash(\mathcal{M}^{\text{real}}\backslash)$  via  $\backslash(\tilde{\pi}_{\text{exp}}^h\backslash)$ 
Play  $\backslash(\pi_{\text{exp}}^h \sim \text{unif} \leftarrow \text{unif} \leftarrow \text{unif} \leftarrow \text{unif}\backslash)$ 
// Estimate optimal policy on collected data
for  $\backslash(h=H, H-1, \dots, 1\backslash)$  do
     $\backslash(\widehat{f}_h \leftarrow \arg \min_{f \in \mathcal{F}} \sum_{\pi \in \Pi_{\text{exp}}^h} \left( \sum_{h=1}^H \left( s_h, a_h, r_h, s_{h+1} \right) \cdot f(s_h, a_h) \right) \backslash)$ 
    Compute  $\backslash(\pi^{\text{sim}}, \star\backslash)$  via Oracle 4.2
    Play  $\backslash(\pi^{\text{sim}}, \star\backslash)$  for  $\backslash(T / 4\backslash)$  episodes in real, compute average
    Play  $\backslash(\widehat{f}_h\backslash)$  for  $\backslash(T / 4\backslash)$  episodes in real, compute average return  $\backslash$ 
    return  $\backslash(\widehat{\pi} \leftarrow \arg \max_{\pi \in \Pi_{\text{exp}}^h} \left( \sum_{h=1}^H \left( s_h, a_h, r_h, s_{h+1} \right) \cdot \pi(s_h, a_h) \right) \backslash)$ 
```

Algorithm 1 首先呼叫一個名為 LearnExpPolicies 的子程序，該程序會學習一組在 $\mathcal{M}^{\text{sim}}$ 上提供豐富數據覆蓋範圍的策略——準確來說，LearnExpPolicies 會回傳策略 $\{\Pi_{\text{exp}}^h\}_{h \in [H]}$ ，這些策略在 $\mathcal{M}^{\text{sim}}$ 上產生的共變量（covariates）具有下界最小特徵值，滿足：

$$\lambda_{\min} \left(\frac{1}{|\Pi_{\text{exp}}^h|} \sum_{\pi \in \Pi_{\text{exp}}^h} \mathbb{E}^{\mathcal{M}^{\text{sim}}, \pi} \left[\phi^s(s_h, a_h) \phi^s(s_h, a_h)^\top \right] \right) \gtrsim \lambda_{\min}^*$$

且僅依賴於 Oracle 4.2（以及對 $\mathcal{M}^{\text{sim}}$ ， ϕ^s 線性特徵化的了解）來尋找這些策略。接著，Algorithm 1 僅需在 $\mathcal{M}^{\text{real}}$ 中執行這些探索策略並配合隨機探索，並對收集到的數據應用迴歸 Oracle。最後，它會評估由迴歸 Oracle 與 $\pi^{\text{sim}, \star}$ 所學習到的策略價值，並回傳其中表現最佳者。

我們得到以下結果。

定理 1。若假設 1 至 4 成立且

$$\epsilon_{\text{sim}} \leq \frac{\lambda_{\min}^*}{64dHA^3},$$

則只要

$$T \geq c \cdot \frac{d^2 H^{16}}{\epsilon^8} \cdot \log \frac{H|\mathcal{F}|}{\delta}$$

以至少 $1 - \delta$ 的機率，Algorithm 1 會回傳一個策略 $\hat{\pi}$ 使得 $V_0^{\text{real},*} - V_0^{\text{real},\hat{\pi}} \leq \epsilon$ ，且 Oracle 4.1 的最小平方法迴歸 oracle 與 Oracle 4.2 的模擬器存取 oracle 最多被調用 $\text{poly}(d, H, \epsilon^{-1}, \log \frac{1}{\delta})$ 次。

定理 1 表明，只要 ϵ_{sim} 符合 (4.2)，利用模擬器與最小平方法迴歸 Oracle (Oracle 4.1 與 4.2)，即可在 $\mathcal{M}^{\text{real}}$ 中實現高效學習，其複雜度隨問題參數呈多項式級別增長。相較於不使用模擬器的原生探索 (naive exploration) 或直接的 sim2real 轉移，這帶來了指數級的提升——命題 1 與 3 顯示，儘管使用相同的實用計算 Oracle，上述方法的複雜度仍隨時間步 (horizon) 呈指數級增長。就我們所知，此結果提供了首個理論證據，證明在直接轉移可行的簡單情境之外，sim2real 轉移能在 RL 中能產生可證明的收益。

請注意，(4.2) 中的條件與 ϵ 無關——不同於需要 $\epsilon = \mathcal{O}(\epsilon_{\text{sim}})$ 的直接 sim2real 轉移，我們僅需假設 ϵ_{sim} 足夠小以使 (4.2) 成立，而定理 1 顯示，對於任何 $\epsilon > 0$ ，我們都能在 $\mathcal{M}^{\text{real}}$ 中高效學習到一個 ϵ -最佳策略。在附錄 B.4 中，我們還提出了定理 1 的擴展版本 (定理 3)，該版本利用來自 $\mathcal{M}^{\text{sim}}$ 的數據來減少對 $\log |\mathcal{F}|$ 的依賴。特別是，其複雜度不再隨 $\log |\mathcal{F}|$ 縮放，而是僅隨在 $\mathcal{M}^{\text{sim}}$ 上 (近似) 符合 Bellman 一致性的函數之對數基數 (log-cardinality) 縮放。

為了說明定理 1 的有效性，我們回到命題 1 與 3 的實例，即原生探索與直接 sim2real 轉移失敗的情境。我們得到以下結果。

命題 4。在命題 1 與 3 的設定下，並假設 $\epsilon_{\text{sim}} \leq \frac{1}{8192} \cdot \frac{1}{H}$ ，執行演算法 1 將需要來自 $\mathcal{M}^{\text{real}}$ 的 $\text{poly}(H, \epsilon^{-1}) \cdot \log \frac{1}{\delta}$ 個樣本，以便在機率至少為 $1 - \delta$ 的情況下，為任何 $\epsilon > 0$ 識別出 $\mathcal{M}^{\text{real}}$ 中的一個 ϵ -最佳策略。

請注意，命題 4 所要求的條件僅為 $\epsilon_{\text{sim}} \lesssim 1/H$ ——只要我們的模擬器滿足此條件，我們就能有效地轉移探索策略，以學習任何 $\epsilon > 0$ 的 ϵ -最佳策略，而原始方法將僅限於獲得 $\Omega(1/H)$ -最佳策略 (或面臨指數級的樣本複雜度)。

隨機探索的必要性。演算法 1 在 $\mathcal{M}^{\text{real}}$ 中實現有效探索的方式，是先在 $\mathcal{M}^{\text{sim}}$ 中學習一組涵蓋 $\mathcal{M}^{\text{sim}}$ 特徵空間的策略集 Π_{exp}^h (第 2 行)，然後在 $\mathcal{M}^{\text{real}}$ 中執行這些策略，並配合隨機探索 (第 4 行)。特別是，演算法 1 執行來自 $\tilde{\Pi}_{\text{exp}}^h$ 的策略，其中每個 $\tilde{\pi}_{\text{exp}} \in \tilde{\Pi}_{\text{exp}}^h$ 被定義為在第 h 步之前執行某個 $\pi_{\text{exp}} \in \Pi_{\text{exp}}^h$ ，然後在第 $h' = h + 1, \dots, H$ 步隨機均勻地選擇動作。這種隨機探索的使用對於獲得定理 1 至關重要。事實上，在假設 1 下，定理 1 的條件 (4.2) 並不足以確保滿足 (4.1) 的策略在 $\mathcal{M}^{\text{real}}$ 中收集到足夠豐富的數據，以學習近乎最佳的策略。雖然 (4.2) 足以保證在 $\mathcal{M}^{\text{real}}$ 上執行 Π_{exp}^h 所收集的數據涵蓋了 $\mathcal{M}^{\text{sim}}$ 的特徵空間——也就是說，滿足 (4.1)，但將對 $\mathcal{M}^{\text{sim}}$ 的期望替換為對 $\mathcal{M}^{\text{real}}$ 的期望——但這對於學習來說是不夠的，如下列結果所示。

命題 5。對於任何 $\epsilon_{\text{sim}} \leq 1/2$ ，存在某些 $\mathcal{M}^{\text{sim}}, \mathcal{M}^{\text{real},1}$ 與 $\mathcal{M}^{\text{real},2}$ 使得：

$\mathcal{M}^{\text{real},1}$ 與 $\mathcal{M}^{\text{real},2}$ 皆滿足假設 1 且參數為 $\mathcal{M}^{\text{sim}}$ ，並且假設 2 至 4 成立。

存在某個策略 π_{exp} ，使得 $\lambda_{\min} \left(\mathbb{E}^{\mathcal{M}^{\text{sim}}, \pi_{\text{exp}}} \left[\phi^s(s_h, a_h) \phi^s(s_h, a_h)^\top \right] \right) = 1/2, \forall h \in [H]$ ，且對於任何 $T \geq 0$ ，若我們在 $\mathcal{M}^{\text{real}}$ 上執行 π_{exp} 共 T 個步驟，則：

$$\inf_{\hat{\pi}} \sup_{\mathcal{M}^{\text{real}} \in \{\mathcal{M}^{\text{real},1}, \mathcal{M}^{\text{real},2}\}} \mathbb{E}^{\mathcal{M}^{\text{real}}, \pi_{\text{exp}}} \left[V_0^{\mathcal{M}^{\text{real}},*} - V_0^{\mathcal{M}^{\text{real}},\hat{\pi}} \right] \geq \epsilon_{\text{sim}}.$$

命題 5 成立的原因在於，兩個 MDP 在假設 1 的意義上可能很「接近」，但卻具有截然不同的特徵表示 (feature representations)。因此，轉移一個涵蓋 $\mathcal{M}^{\text{sim}}$ 特徵空間的策略，並不一定足以涵蓋 $\mathcal{M}^{\text{real}}$ 的特徵空間，這最終意味著從 π_{exp} 收集的數據無法識別出 $\mathcal{M}^{\text{real}}$ 中的最佳策略。

然而，我們關鍵的技術結果引理 B.4 顯示，在假設 1 和 (4.2) 下，在 $\mathcal{M}^{\text{sim}}$ 中實現高覆蓋率 (即滿足 (4.1)) 的策略，能夠在對數步數內到達 $\mathcal{M}^{\text{real}}$ 中的相關狀態。雖然隨機探索的樣本複雜度通常隨時間步 (horizon) 呈指數級增長，但如果我們必須探索的時間步僅為對數級別，則總複雜度僅為多項式級別。定理 1 關鍵地依賴於這些事實——透過在 Π_{exp}^h 中執行策略直到第 h 步，然後進行隨機探索，並對每個 $h \in [H]$ 重複此過程，我們證明了在 $\mathcal{M}^{\text{real}}$ 中收集到了足夠豐富的數據，可用於學習 ϵ 最佳策略。

備註 4.1 (計算效率)。演算法 1 及其主要子程序 LearnExpPolicies 僅依賴於對 Oracle 4.1 和 Oracle 4.2 的呼叫。因此，假設我們能夠高效地實作這些 Oracle (這在感興趣的問題設定中通常是可行的)，演算法 1 就能以具備計算效率的方式執

行。

5 實用演算法與實驗

我們接著在實務中驗證提案的有效性：從模擬中獲得的一組多樣化探索策略，是否能提高現實世界強化學習的效率？我們首先在 5.2 節中，透過一個簡單、具教學意義的表格化環境證明這一點。接著，我們考慮幾個更真實的任務領域：受現實世界機器人操作任務啟發的模擬器 (sim2sim 遷移, 5.3 節)；以及在 Franka 機器人平台上進行的實際現實世界 sim2real 實驗 (sim2real 遷移, 5.4 節)。所有實驗的進一步細節，包括額外的基準測試，都可以在附錄 E 中找到。在陳述實驗結果之前，我們首先提供 Algorithm 1 的實務實作版本，使其能應用於真實機器人系統和神經網路函數近似器。

5.1 探索策略遷移的實務實作

Algorithm 1 背後的核心概念非常簡單：在 $\mathcal{M}^{\text{sim}}$ 中學習一組探索策略——這些策略在 $\mathcal{M}^{\text{sim}}$ 中提供豐富的數據覆蓋範圍——並將這些策略遷移到 $\mathcal{M}^{\text{real}}$ ，配合隨機探索，利用收集到的數據來確定 $\mathcal{M}^{\text{real}}$ 的近乎最佳策略。Algorithm 1 提供了這一原則的特定實作，透過 LearnExpPolicies 子程序在 $\mathcal{M}^{\text{sim}}$ 中學習探索策略，旨在覆蓋 $\mathcal{M}^{\text{sim}}$ 的特徵空間，並利用最小平方迴歸 oracle，根據在 $\mathcal{M}^{\text{real}}$ 中收集的數據計算最佳策略。然而在實務中，這一原則的其他實作也是可能的，只需將 LearnExpPolicies 替換為任何能在 $\mathcal{M}^{\text{sim}}$ 中生成探索策略的程序，並將迴歸 oracle 替換為任何能夠從離群政策 (off-policy) 數據中學習的 RL 演算法。我們在 Algorithm 2 中考慮了實作此概念的通用元演算法 (meta-algorithm)。

Algorithm 2 Practical sim2real Exploration Policy Transfer Meta-Algorithm

```
Input: Simulator  $\mathcal{M}^{\text{sim}}$ , real environment  $\mathcal{M}^{\text{real}}$  to generate exploratory policies in  $\mathcal{M}^{\text{sim}}$ , algorithm  $\mathcal{A}_{\text{exp}}$  to generate exploratory policies in  $\mathcal{M}^{\text{sim}}$ , algorithm  $\mathcal{A}_{\text{po}}$  to generate policies in  $\mathcal{M}^{\text{real}}$ 
// Learn exploratory policies in  $\mathcal{M}^{\text{sim}}$ 
Run  $\mathcal{A}_{\text{exp}}$  for  $T_{\text{sim}}$  steps in  $\mathcal{M}^{\text{sim}}$ 
// Deploy exploratory policies in  $\mathcal{M}^{\text{real}}$ 
for  $t=1, 2, \dots, T/2$  do
    Draw  $\pi_{\text{exp}} \sim \text{unif}(\Pi_{\text{exp}})$ , play in  $\mathcal{M}^{\text{real}}$ 
    Run  $\mathcal{A}_{\text{po}}$  for one episode // optional if  $\mathcal{A}_{\text{po}}$  is off-policy
```

在實務中， $\mathcal{A}_{\text{exp}}$ 和 $\mathcal{A}_{\text{po}}$ 可以使用多種演算法來實作。例如，我們可以將 $\mathcal{A}_{\text{exp}}$ 設為 RND (Burda et al., 2018) 或自助式 (bootstrapped) Q-learning 風格 (Osband et al., 2016; Lee et al., 2021) 的演算法，或是任何無監督 RL 程序 (Pathak et al., 2017; Eysenbach et al., 2018; Lee et al., 2019; Park et al., 2023)；並將 $\mathcal{A}_{\text{po}}$ 設為離群政策優化演算法，例如軟性演員-評論家 (SAC) (Haarnoja et al., 2018) 或隱式 Q 學習 (IQL) (Kostrikov et al., 2021)。

在接下來的實驗中，我們透過將 $\mathcal{A}_{\text{exp}}$ 設定為受近期誘導強化學習 (RL) 多樣化行為研究 (Eysenbach et al., 2018; Kumar et al., 2020) 啟發的演算法，並將 $\mathcal{A}_{\text{po}}$ 設定為 SAC，來實例化 Algorithm 2。具體而言， $\mathcal{A}_{\text{exp}}$ 同時訓練一組策略系集 $\Pi_{\text{exp}} = \{\pi_{\text{exp}}^i\}_{i=1}^n$ 與一個判別器 $d_{\theta} : \mathcal{S} \times [n] \rightarrow \mathbb{R}$ ，其中 d_{θ} 被訓練用來辨別每個策略 π_{exp}^i 的行為，而 π_{exp}^i 則根據真實任務獎勵與判別器所誘導的探索獎勵 $r_e(s, i) := \log \frac{\exp(d_{\theta}(s, i))}{\sum_{j \in [n]} \exp(d_{\theta}(s, j))}$ 之加權進行優化。如現有研究 (Eysenbach et al., 2018; Kumar et al., 2020) 所示，這種簡單的訓練目標利用標準優化技術，能有效誘導出具有時間相關探索性的多樣化行為，同時保持在最佳策略的鄰域內。請注意，在此處選擇特定演算法的重要性，次於遵循元演算法 (Algorithm 2) 所制定的方案。我們在實驗中執行的具體實例化細節請參閱 Algorithm 6 以及附錄 E.2。

5.2 啟發式組合鎖 (Combination Lock) 實驗

我們首先考慮一種用於證明命題 1 和 3 的變體結構，其本身是經典組合鎖實例的一種變體。我們在圖 2 中展示了此實例。除非另有說明，否則所有轉移的發生機率均為 1，且獎勵為 0。在此，在 $\mathcal{M}^{\text{sim}}$ 中，最佳策略 $\pi^{\text{sim},*}$ 在所有步驟 $h < H - 1$ 中執行動作 a_2 ；而在 $\mathcal{M}^{\text{real}}$ 中，最佳策略在每一步執行動作 a_1 。

哪一個策略是最佳策略，取決於第 $(H - 1)$ 步從 s_1 出發的轉移；因此，為了識別最佳策略，任何演算法都必須在第 $(H - 1)$ 步到達 s_1 。由於只有連續執行 $H - 1$ 次 a_1 才能在第 $H - 1$ 步到達 s_1 ，任何依賴樸素探索 (naive exploration) 的演算法都需要耗費指數級的時間才能識別出最佳策略。




圖 2：教學範例說明（命題 3）

策略。此外，執行 $\pi^{\text{sim},*}$ 配合隨機探索同樣需要指數級的集數 (episodes)，因為 $\pi^{\text{sim},*}$ 總是執行 a_2 。因此，直接的 sim2real 策略轉移以及配合原生探索的 Q -learning (協定 4.1) 都無法在 $\mathcal{M}^{\text{real}}$ 中找到最佳策略。然而，如果我們從 $\mathcal{M}^{\text{sim}}$ 轉移探索策略，由於 $\mathcal{M}^{\text{sim}}$ 和 $\mathcal{M}^{\text{real}}$ 在第 $H-1$ 步之前的行為完全相同，這些策略可以有效地遍歷 $\mathcal{M}^{\text{real}}$ ，在第 $H-1$ 步到達 s_1 ，並識別出最佳策略。我們將探索策略轉移的方法與這些基準方法進行比較，並在圖 5 中展示各自的效能。由於這是一個簡單的表格實例，我們在此直接實作演算法 1。如圖 5 所示，上述直覺在實務中帶來了實質增益——探索策略轉移能迅速識別出最佳策略，而較原生的方法在我們考慮的時間範圍內則完全失敗。

5.3 現實機器人 sim2sim 實驗

為了測試我們提出的方法擴展到更複雜問題的能力，我們接著在兩個現實機器人模擬器的 sim2sim 轉移設定下進行實驗。在這裡，我們試圖透過考慮一個初始模擬器 ($\mathcal{M}^{\text{sim}}$ ，模擬 sim2real 中的「sim」) 以及該模擬器的修改版本 ($\mathcal{M}^{\text{real}}$ ，模擬 sim2real 中的「real」)，在受控設定下模擬 sim2real 轉移。

Tycho 機器人平台的 sim2sim 轉移。我們首先考慮 TychoEnv，這是由 Zhang 等人 (2023) 提出的一個 7 自由度 (7DOF) Tycho 機器人平台模擬器，如圖 3 所示。我們在一个抵達任務 (reaching task) 上測試 sim2sim 轉移，該任務的目標是用筷子末端執行器的尖端觸碰懸掛在空中的小球。代理程式感知球體及其自身的末端執行器位姿，並輸出其目標末端執行器位姿的增量 (delta) 作為指令。我們將 $\mathcal{M}^{\text{sim}}$ 和 $\mathcal{M}^{\text{real}}$ 設定為兩個 TychoEnv 實例，並具有稍微不同的




圖 3：TychoEnv 抵達任務設定

參數，以模擬現實世界的 sim2real 轉移。準確地說，我們更改了從 $\mathcal{M}^{\text{sim}}$ 到 $\mathcal{M}^{\text{real}}$ 的動作邊界 (action bounds) 和控制頻率。

我們旨在將我們的探索策略轉移方法與直接的 sim2real 策略轉移進行比較。為此，我們首先在 $\mathcal{M}^{\text{sim}}$ 中訓練一個能解決 $\mathcal{M}^{\text{sim}}$, $\pi^{\text{sim},*}$ 中任務的策略，然後在演算法 2 中使用該策略取代 Π_{exp} 。我們按照上述方式實例化我們的探索策略轉移方法。本實驗的目的是說明直接策略轉移與探索策略轉移所提供的數據品質如何影響學習。因此，對於這兩種方法，我們只需從頭開始初始化我們在 $\mathcal{M}^{\text{real}}$, $\mathcal{A}_{\text{po}}$ 中的 SAC 代理程式，並將 $\mathcal{M}^{\text{real}}$ 中的獎勵設定為稀疏獎勵：代理程式只有在成功觸

碰球時才會收到非零獎勵。對於每種方法，我們在 $\mathcal{M}^{\text{sim}}$ 中重複四次訓練過程，並且對於每一次訓練，在 $\mathcal{M}^{\text{real}}$ 中進行兩次試驗。






圖 4：圖 5：sim2sim 密碼鎖範例之結果

圖 6：TychoEnv 模擬器中 sim2sim 轉移之結果

圖 7：Franka 模擬器中 sim2sim 轉移之結果

我們在圖 6 中展示了結果。如圖所示，直接策略轉移（direct policy transfer）完全無法學習，而探索策略轉移（exploration policy transfer）則成功解決了任務。研究各方法的行為後，我們發現透過探索策略轉移所轉移的策略，雖然無法以完美的準確度解決任務，但在配合原生探索（naive exploration）時，偶爾能夠成功接觸到球。這為 SAC 提供了足夠豐富的數據，使其最終學會解決任務。相比之下，直接策略轉移在 $\mathcal{M}^{\text{real}}$ 中執行時無法獲得任何獎勵，且鑑於該任務具有稀疏獎勵（sparse reward）的特性，SAC 無法定位任何獎勵並進行學習。

Franka Emika Panda 機械手臂上的 sim2sim 遷移。我們接著轉向 Franka Emika Panda 機械手臂（Haddadin et al., 2022），並使用以 MuJoCo 模擬引擎（Todorov et al., 2012）構建的高擬真自定義模擬器。我們考慮一個釘釘子任務，Franka 手臂握住一把錘子，目標是將釘子釘入木板（見圖 4）。當釘子完全嵌入時即視為成功。我們透過將 $\mathcal{M}^{\text{real}}$ 設定為模擬器的一個版本來模擬 sim2real 遷移，其中釘子的位置和剛度顯著超出了 $\mathcal{M}^{\text{sim}}$ 訓練期間所見的範圍。

我們將探索策略遷移與直接的 sim2real 策略遷移進行比較。與 Tycho 實驗不同（在該實驗中，我們在 $\mathcal{M}^{\text{real}}$ 中從頭開始訓練策略，並僅使用在 $\mathcal{M}^{\text{sim}}$ 中訓練的策略進行探索），在這裡我們將




圖 5：圖 4：Franka 釘釘子任務設置

$\mathcal{M}^{\text{real}}$ 中的任務策略初始化為 $\pi^{\text{sim},*}$ ，然後透過執行 SAC，利用在 $\mathcal{M}^{\text{real}}$ 中收集的數據進行微調。對於直接的 sim2real 遷移，我們透過直接執行 $\pi^{\text{sim},*}$ 在 $\mathcal{M}^{\text{real}}$ 中收集數據，並將這些數據輸入 SAC 的重播緩衝區（replay buffer）。對於探索策略遷移，我們在 $\mathcal{M}^{\text{sim}}$ 中訓練一組 $n = 10$ 探索策略，並在 $\mathcal{M}^{\text{real}}$ 中執行這些策略，同樣將這些數據輸入 SAC 的重播緩衝區以微調 $\pi^{\text{sim},*}$ 。在 $\mathcal{M}^{\text{sim}}$ 的訓練過程中，我們對兩種方法都使用了領域隨機化（domain randomization），隨機化釘子的剛度、位置、半徑、質量、木板尺寸和阻尼。

本實驗的結果如圖 7 所示。我們觀察到，雖然直接策略轉移（direct policy transfer）能夠進行學習，但其學習速率明顯慢於我們的探索策略轉移（exploration policy transfer）方法，且最終成功率也低得多。

5.4 真實世界機器人 sim2real 實驗

最後，我們展示了將演算法應用於真實世界 sim2real 策略轉移的成果，任務是在配備平行夾爪的真實 Franka Emika Panda 機器手臂上進行操作任務。如圖 1 所示，我們的任務是將一個直徑 75 mm 的圓柱形「圓盤 (puck)」從表面中心推向邊緣，其中

手臂初始化於隨機位置。觀測狀態 $s = [\mathbf{p}_{ee}, \mathbf{p}_{obj}] \in \mathbb{R}^4$ 包含末端效應器 (end effector) 的平面笛卡兒座標 $\mathbf{p}_{ee}$ 以及圓盤的質心 $\mathbf{p}_{obj}$ 。我們的策略以 8 Hz 的頻率輸出平面末端效應器位置增量 $a = \Delta \mathbf{p}_{ee} \in \mathbb{R}^2$ ，並將其傳遞至以 1000 Hz 運行的底層關節位置 PID 控制器。我們使用 Intel Realsense D435 深度攝影機來追蹤圓盤的位置。我們的獎勵函數 (reward function) 是成功指標 (表示圓盤何時被推到表面邊緣) 與其他項的總和，若末端效應器與圓盤之間的距離、或圓盤與目標之間的距離過大，則會給予負獎勵 (見 (E.1))；特別是，獎勵大於 0 即表示成功。

我們執行上述演算法 2 的實例化。具體而言，我們訓練了一組包含 $n = 15$ 個探索策略的集成 (ensemble)，並在 $\mathcal{M}^{\text{sim}}$ 中進行了 2,000 萬步的訓練。此外，我們還訓練了一個能在 $\mathcal{M}^{\text{sim}}, \pi^{\text{sim},*}$ 中完成任務的策略。我們使用自定義的機械手臂模擬器，在訓練過程中，桌面的摩擦力會進行隨機化處理，並在觀測值 (observations) 中加入雜訊。

我們觀察到模擬器與真實機器人之間存在顯著的 sim2real 差距，即使在經過領域隨機化 (domain randomization) 訓練的情況下，在模擬環境中訓練的策略仍無法在真實環境中以零樣本 (zero-shot) 方式完成推移任務。我們將直接的 sim2real 策略轉移與我們轉移探索策略的方法進行比較。對於直接策略轉移，我們僅運行 SAC 來微調 $\pi^{\text{sim},*}$ 於




圖 6: 圖 8: Franka sim2real 圓盤推移任務結果

我們的結果顯示在圖 1 的右側，並重複呈現於圖 8。統計數據是針對每種方法進行 6 次執行後計算得出。帶有微調的直接策略轉移，在 6 次執行中均無法在真實環境中解決任務，且收斂至次優解。然而，我們的方法每次都能成功解決任務，並獲得顯著較高的獎勵。從定性分析來看，效能提升源於探索過程比直接轉移更能成功推動圓盤，收集了更多與任務相關的數據，從而在面臨探索挑戰時實現更快速的學習。

6 討論

在此研究中，我們證明了如果將模擬器用於訓練一組探索策略 (exploration policies)，即使在直接的模擬轉真實 (sim2real) 遷移失敗的情況下，模擬遷移也能讓簡單且實用的強化學習 (RL) 方法發揮效用。我們相信這項工作為許多具有實際影響力的重要問題開啟了大門，我們將在下方重點說明：

我們純粹專注於動力學偏移 (dynamics shift) ——即模擬與現實之間的動力學特性有所不同，但其餘環境條件皆相同的情況。雖然動力學偏移在許多情境中都很常見，但也可能存在其他類型的偏移，例如視覺偏移 (visual shift)。我們該如何處理模擬與現實之間如此多樣的差異類型？

如果我們可以任意重設模擬器，而不僅僅是假設，那我們該如何最有效地利用它？

正如我們在此處所假設的，僅具備黑箱存取權限是否足夠？近期的研究顯示，重設 (resets) 能在原本被認為難以處理的強

化學習 (RL) 場景中實現高效學習，但尚未在本文所考慮的動態偏移 (dynamics shift) 場景中提供結果 (Mhammedi et al., 2024b)。重設模擬器的能力是否能讓我們進一步提升樣本效率？

在技術層面，定理 1 (4.2) 中對 ϵ_{sim} 的條件對於成功的探索轉移 (exploration transfer) 是必要的嗎？我們能否證明探索策略轉移在更複雜的設定中（例如雙線性類別，Bilinear classes, Du et al., 2021）能產生可證明的收益？

致謝

AW 與 KJ 的研究工作獲得美國國家科學基金會 (NSF) 透過華盛頓大學材料研究科學與工程中心 (DMR-2308979)、CCF 2007036 以及 CAREER 2141511 獎項的部分資助。LK 的研究工作獲得 Toyota Research Institute URP 的部分資助。

參考文獻

- Agarwal, A., Kakade, S., Krishnamurthy, A., and Sun, W. Flambe: Structural complexity and representation learning of low rank mdps. *Advances in neural information processing systems*, 33: 20095-20107, 2020.
- Agarwal, A., Song, Y., Sun, W., Wang, K., Wang, M., and Zhang, X. Provable benefits of representational transfer in reinforcement learning. In *The Thirty Sixth Annual Conference on Learning Theory*, pp. 2114-2187. PMLR, 2023.
- Agarwal, N., Chaudhuri, S., Jain, P., Nagaraj, D., and Netrapalli, P. Online target q-learning with reverse experience replay: Efficiently finding the optimal policy for linear mdps. *arXiv preprint arXiv:2110.08440*, 2021.
- Akkaya, I., Andrychowicz, M., Chociej, M., Litwin, M., McGrew, B., Petron, A., Paino, A., Plappert, M., Powell, G., Ribas, R., et al. Solving rubik’s cube with a robot hand. *arXiv preprint arXiv:1910.07113*, 2019.
- Amortila, P., Jiang, N., Madeka, D., and Foster, D. P. A few expert queries suffices for sampleefficient rl with resets and linear value approximation. *Advances in Neural Information Processing Systems*, 35:29637-29648, 2022.
- Brafman, R. I. and Tennenholtz, M. R-max-a general polynomial time algorithm for near-optimal reinforcement learning. *Journal of Machine Learning Research*, 3(Oct):213-231, 2002.
- Burda, Y., Edwards, H., Storkey, A., and Klimov, O. Exploration by random network distillation. *arXiv preprint arXiv:1810.12894*, 2018.
- Chebatar, Y., Handa, A., Makoviychuk, V., Macklin, M., Issac, J., Ratliff, N., and Fox, D. Closing the sim-to-real loop: Adapting simulation randomization with real world experience. In *ICRA*, 2019.
- Chen, T., Tippur, M., Wu, S., Kumar, V., Adelson, E., and Agrawal, P. Visual dexterity: In-hand reorientation of novel and complex object shapes. *Science Robotics*, 8(84):eadc9244, 2023.
- Cheng, Y., Feng, S., Yang, J., Zhang, H., and Liang, Y. Provable benefit of multitask representation learning in reinforcement learning. *Advances in Neural Information Processing Systems*, 35: 31741-31754, 2022.
- Dann, C., Mansour, Y., Mohri, M., Sekhari, A., and Sridharan, K. Guarantees for epsilon-greedy reinforcement learning with function approximation. In *International conference on machine learning*, pp. 4666-4689. PMLR, 2022.
- Degrave, J., Felici, F., Buchli, J., Neunert, M., Tracey, B., Carpanese, F., Ewalds, T., Hafner, R., Abdolmaleki, A., de Las Casas, D., et al. Magnetic control of tokamak plasmas through deep reinforcement learning. *Nature*, 602(7897):414-419, 2022.
- Du, S., Kakade, S., Lee, J., Lovett, S., Mahajan, G., Sun, W., and Wang, R. Bilinear classes: A structural framework for provable generalization in rl. In *International Conference on Machine Learning*, pp. 2826-2836. PMLR, 2021.
- Eysenbach, B. and Levine, S. Maximum entropy rl (provably) solves some robust rl problems. *arXiv preprint arXiv:2103.06257*, 2021.
- Eysenbach, B., Gupta, A., Ibarz, J., and Levine, S. Diversity is all you need: Learning skills without a reward function. *arXiv preprint arXiv:1802.06070*, 2018.
- Ghugare, R., Miret, S., Hugessen, A., Phielipp, M., and Berseth, G. Searching for high-value molecules using reinforcement learning and transformers. *arXiv preprint arXiv:2310.02902*, 2023.
- Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pp. 1861-1870. PMLR, 2018.
- Haddadin, S., Parusel, S., Johannsmeier, L., Golz, S., Gabl, S., Walch, F., Sabaghian, M., Jähne, C., Hausperger, L., and Haddadin, S. The franka emika robot: A reference platform for robotics research and education. *IEEE Robotics & Automation Magazine*, 29(2):46-64, 2022. doi: 10.1109/ MRA.2021.3138382.
- Höfer, S., Bekris, K., Handa, A., Gamboa, J. C., Mozifian, M., Golemo, F., Atkeson, C., Fox, D., Goldberg, K., Leonard, J., et al. Sim2real in robotics and automation: Applications and challenges. *IEEE transactions on automation science and engineering*, 18(2):398-400, 2021.

James, S., Wohlhart, P., Kalakrishnan, M., Kalashnikov, D., Irpan, A., Ibarz, J., Levine, S., Hadsell, R., and Bousmalis, K. Sim-to-real via sim-to-sim: Data-efficient robotic grasping via randomized-to-canonical adaptation networks. arXiv e-prints, page. arXiv preprint arXiv:1812.07252, 2018.

Jiang, Y., Kolter, J. Z., and Raileanu, R. On the importance of exploration for generalization in reinforcement learning. arXiv preprint arXiv:2306.05483, 2023.

Jin, C., Yang, Z., Wang, Z., and Jordan, M. I. Provably efficient reinforcement learning with linear function approximation. In Conference on Learning Theory, pp. 2137-2143. PMLR, 2020.

Julian, R., Swanson, B., Sukhatme, G., Levine, S., Finn, C., and Hausman, K. Never stop learning: The effectiveness of fine-tuning in robotic reinforcement learning. In CoRL, 2021.

Kakade, S., Kearns, M. J., and Langford, J. Exploration in metric state spaces. In Proceedings of the 20th International Conference on Machine Learning (ICML-03), pp. 306-312, 2003.

Kaufmann, E., Bauersfeld, L., Loquercio, A., Müller, M., Koltun, V., and Scaramuzza, D. Championlevel drone racing using deep reinforcement learning. Nature, 620(7976):982-987, 2023.

Kearns, M. and Koller, D. Efficient reinforcement learning in factored mdps. In IJCAI, volume 16, pp. 740-747, 1999.

Kearns, M. and Singh, S. Near-optimal reinforcement learning in polynomial time. Machine learning, 49:209-232, 2002.

Kiran, B. R., Sobh, I., Talpaert, V., Mannion, P., Al Sallab, A. A., Yogamani, S., and Pérez, P. Deep reinforcement learning for autonomous driving: A survey. IEEE Transactions on Intelligent Transportation Systems, 23(6):4909-4926, 2021.

Kober, J., Bagnell, J. A., and Peters, J. Reinforcement learning in robotics: A survey. The International Journal of Robotics Research, 32(11):1238-1274, 2013.

Kostrikov, I., Nair, A., and Levine, S. Offline reinforcement learning with implicit q-learning. arXiv preprint arXiv:2110.06169, 2021.

Kumar, A., Fu, Z., Pathak, D., and Malik, J. Rma: Rapid motor adaptation for legged robots. arXiv preprint arXiv:2107.04034, 2021.

Kumar, S., Kumar, A., Levine, S., and Finn, C. One solution is not all you need: Few-shot extrapolation via structured maxent rl. Advances in Neural Information Processing Systems, 33: 8198-8210, 2020.

Lee, K., Laskin, M., Srinivas, A., and Abbeel, P. Sunrise: A simple unified framework for ensemble learning in deep reinforcement learning. In International Conference on Machine Learning, pp. 6131-6141. PMLR, 2021.

Lee, L., Eysenbach, B., Parisotto, E., Xing, E., Levine, S., and Salakhutdinov, R. Efficient exploration via state marginal matching. arXiv preprint arXiv:1906.05274, 2019.

Li, G., Chen, Y., Chi, Y., Gu, Y., and Wei, Y. Sample-efficient reinforcement learning is feasible for linearly realizable mdps with limited revisiting. Advances in Neural Information Processing Systems, 34:16671-16685, 2021.

Liu, Y., Misra, D., Dudík, M., and Schapire, R. E. Provably sample-efficient rl with side information about latent dynamics. Advances in Neural Information Processing Systems, 35:33482-33493, 2022.

Lu, R., Huang, G., and Du, S. S. On the power of multitask representation learning in linear mdp. arXiv preprint arXiv:2106.08053, 2021.

Malik, D., Li, Y., and Ravikumar, P. When is generalizable reinforcement learning tractable? Advances in Neural Information Processing Systems, 34:8032-8045, 2021.

Mann, T. A. and Choe, Y. Directed exploration in reinforcement learning with transferred knowledge. In European Workshop on Reinforcement Learning, pp. 59-76. PMLR, 2013.

Margolis, G. B., Fu, X., Ji, Y., and Agrawal, P. Learning physically grounded robot vision with active sensing motor policies. In CoRL, 2023.

Mehta, B., Diaz, M., Golemo, F., Pal, C. J., and Paull, L. Active domain randomization. In CoRL, 2020.

Memmel, M., Wagenmaker, A., Zhu, C., Yin, P., Fox, D., and Gupta, A. Asid: Active exploration for system identification in robotic manipulation. arXiv preprint arXiv:2404.12308, 2024.

Mhammedi, Z., Block, A., Foster, D. J., and Rakhlin, A. Efficient model-free exploration in low-rank mdps. Advances in Neural Information Processing Systems, 36, 2024a.

Mhammedi, Z., Foster, D. J., and Rakhlin, A. The power of resets in online reinforcement learning. arXiv preprint arXiv:2404.15417, 2024b.

Modi, A., Chen, J., Krishnamurthy, A., Jiang, N., and Agarwal, A. Model-free representation learning and exploration in low-rank mdps. *Journal of Machine Learning Research*, 25(6):1-76, 2024.

Muratore, F., Gienger, M., and Peters, J. Assessing transferability from simulation to reality for reinforcement learning. *IEEE transactions on pattern analysis and machine intelligence*, 2019.

Osband, I., Blundell, C., Pritzel, A., and Van Roy, B. Deep exploration via bootstrapped dqn. *Advances in neural information processing systems*, 29, 2016.

Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., et al. Training language models to follow instructions with human feedback. *Advances in neural information processing systems*, 35:27730-27744, 2022.

Park, S., Rybkin, O., and Levine, S. Metra: Scalable unsupervised rl with metric-aware abstraction. *arXiv preprint arXiv:2310.08887*, 2023.

Pathak, D., Agrawal, P., Efros, A. A., and Darrell, T. Curiosity-driven exploration by self-supervised prediction. In *International conference on machine learning*, pp. 2778-2787. PMLR, 2017.

Peng, X. B., Andrychowicz, M., Zaremba, W., and Abbeel, P. Sim-to-real transfer of robotic control with dynamics randomization. In *2018 IEEE international conference on robotics and automation (ICRA)*, pp. 3803-3810. IEEE, 2018.

Peng, X. B., Coumans, E., Zhang, T., Lee, T.-W., Tan, J., and Levine, S. Learning agile robotic locomotion skills by imitating animals. *arXiv preprint arXiv:2004.00784*, 2020.

Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., and Dormann, N. Stable-baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268): 1-8, 2021.

Rajeswaran, A., Kumar, V., Gupta, A., Vezzani, G., Schulman, J., Todorov, E., and Levine, S. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. *arXiv preprint arXiv:1709.10087*, 2017.

Silva, F., Yang, J., Landajuela, M., Goncalves, A., Ladd, A., Faissol, D., and Petersen, B. Toward multi-fidelity reinforcement learning for symbolic optimization. Technical report, Lawrence Livermore National Laboratory (LLNL), Livermore, CA (United States), 2023.

Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., Van Den Driessche, G., Schrittwieser, J., Antonoglou, I., Panneershelvam, V., Lanctot, M., et al. Mastering the game of go with deep neural networks and tree search. *nature*, 529(7587):484-489, 2016.

Sinha, R., Harrison, J., Richards, S. M., and Pavone, M. Adaptive robust model predictive control with matched and unmatched uncertainty. In *2022 American Control Conference (ACC)*, 2022.

Smith, L., Kew, J. C., Peng, X. B., Ha, S., Tan, J., and Levine, S. Legged robots that keep on learning: Fine-tuning locomotion policies in the real world. In *2022 International Conference on Robotics and Automation (ICRA)*, pp. 1593-1599. IEEE, 2022.

Song, Y., Mavalankar, A., Sun, W., and Gao, S. Provably efficient model-based policy adaptation. *arXiv preprint arXiv:2006.08051*, 2020.

Song, Y., Zhou, Y., Sekhari, A., Bagnell, J. A., Krishnamurthy, A., and Sun, W. Hybrid rl: Using both offline and online data can make rl efficient. *arXiv preprint arXiv:2210.06718*, 2022.

Sun, Y., Zheng, R., Wang, X., Cohen, A., and Huang, F. Transfer rl across observation feature spaces via model-based regularization. *arXiv preprint arXiv:2201.00248*, 2022.

Tirinzoni, A., Pirotta, M., and Lazaric, A. A fully problem-dependent regret lower bound for finite-horizon mdps. *arXiv preprint arXiv:2106.13013*, 2021.

Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., and Abbeel, P. Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ international conference on intelligent robots and systems (IROS)*, pp. 23-30. IEEE, 2017.

Todorov, E., Erez, T., and Tassa, Y. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pp. 5026-5033, 2012. doi: 10.1109/IROS.2012.6386109.

Uehara, M., Zhang, X., and Sun, W. Representation learning for online and offline rl in low-rank mdps. *arXiv preprint arXiv:2110.04652*, 2021.

Wagenmaker, A. and Jamieson, K. G. Instance-dependent near-optimal policy identification in linear mdps via online experiment design. *Advances in Neural Information Processing Systems*, 35:5968-5981, 2022.

Wagenmaker, A., Shi, G., and Jamieson, K. Optimal exploration for model-based rl in nonlinear systems. *arXiv preprint arXiv:2306.09210*, 2023.

Wagenmaker, A. J., Chen, Y., Simchowitz, M., Du, S., and Jamieson, K. Reward-free rl is no harder than reward-aware rl in linear markov decision processes. In International Conference on Machine Learning, pp. 22430-22456. PMLR, 2022.

Wang, J. X., Kurth-Nelson, Z., Tirumala, D., Soyer, H., Leibo, J. Z., Munos, R., Blundell, C., Kumaran, D., and Botvinick, M. Learning to reinforcement learn. arXiv preprint arXiv:1611.05763, 2016.

Weisz, G., Amortila, P., Janzer, B., Abbasi-Yadkori, Y., Jiang, N., and Szepesvári, C. On queryefficient planning in mdps under linear realizability of the optimal state-value function. In Conference on Learning Theory, pp. 4355-4385. PMLR, 2021.

Weisz, G., György, A., Kozuno, T., and Szepesvári, C. Confident approximate policy iteration for efficient local planning in q^π -realizable mdps. Advances in Neural Information Processing Systems, 35:25547-25559, 2022.

Ye, H., Chen, X., Wang, L., and Du, S. S. On the power of pre-training for generalization in rl: provable benefits and hardness. In International Conference on Machine Learning, pp. 39770-39800. PMLR, 2023.

Yin, D., Hao, B., Abbasi-Yadkori, Y., Lazić, N., and Szepesvári, C. Efficient local planning with linear function approximation. In International Conference on Algorithmic Learning Theory, pp. 1165-1192. PMLR, 2022.

Zanette, A., Lazaric, A., Kochenderfer, M. J., and Brunskill, E. Provably efficient reward-agnostic navigation with linear value iteration. Advances in Neural Information Processing Systems, 33: 11756-11766, 2020.

Zhang, T., Ren, T., Yang, M., Gonzalez, J., Schuurmans, D., and Dai, B. Making linear mdps practical via contrastive representation learning. In International Conference on Machine Learning, pp. 26447-26466. PMLR, 2022.

Zhang, Y., Ke, L., Deshpande, A., Gupta, A., and Srinivasa, S. Cherry-picking with reinforcement learning. arXiv preprint arXiv:2303.05508, 15, 2023.

Zhao, W., Queralta, J. P., and Westerlund, T. Sim-to-real transfer in deep reinforcement learning for robotics: a survey. In 2020 IEEE symposium series on computational intelligence (SSCI), pp. 737-744. IEEE, 2020.

A 技術結果

我們將某個策略 π 的狀態拜訪次數 (state-visitations) 表示為 $w_h^\pi(s, a) := \mathbb{P}^\pi[(s_h, a_h) = (s, a)]$, $w_h^\pi(\mathcal{Z}) := \mathbb{P}^\pi[(s_h, a_h) \in \mathcal{Z}]$, 其中 $\mathcal{Z} \subseteq \mathcal{S} \times \mathcal{A}$ 。對於 $\mathcal{X} \subseteq \mathbb{R}^d$, 我們將環境的特徵化 (featurization) 表示為 $w_h^\pi(\mathcal{X}) := \mathbb{P}^\pi[\phi(s_h, a_h) \in \mathcal{X}]$, 其中 ϕ 。

引理 A.1. 考慮 MDPs M 與 $\widetilde{M}$, 其轉移核心 (transition kernels) 分別為 P 與 $\widetilde{P}$ 。假設 M 與 $\widetilde{M}$ 皆從相同的狀態 s_0 開始, 且對於每個 (s, a, h) :

$$\|P_h(\cdot | s, a) - \widetilde{P}_h(\cdot | s, a)\|_{\text{TV}} \leq \epsilon_{\text{sim}}$$

考慮某個獎勵函數 r , 使得對於所有可能的序列 $\{(s_h, a_h)\}_{h=1}^H$, $\sum_{h=1}^H r_h(s_h, a_h) \leq R$ 皆成立。則對於任何 π 與 (s, a, h) , 可得出以下結論:

$$|Q_h^{M,\pi}(s, a) - Q_h^{\widetilde{M},\pi}(s, a)| \leq HR \cdot \epsilon_{\text{sim}}$$

證明。我們透過歸納法來證明。首先, 假設對於某些 h 以及所有的 s, a , 我們得到 $|Q_{h+1}^{M,\pi}(s, a) - Q_{h+1}^{\widetilde{M},\pi}(s, a)| \leq \epsilon_{h+1}$ 。根據定義, 我們有

$$Q_h^{M,\pi}(s, a) = r_h(s, a) + \mathbb{E}^{M,\pi} \left[Q_{h+1}^{M,\pi}(s_{h+1}, a_{h+1}) | s_h = s, a_h = a \right]$$

對於 $Q_{h+1}^{\widetilde{M},\pi}(s, a)$ 也是如此。因此:

$$|Q_h^{M,\pi}(s, a) - Q_h^{\widetilde{M},\pi}(s, a)|$$

$$\stackrel{(a)}{\leq} \left| \mathbb{E}^{M,\pi} \left[Q_{h+1}^{M,\pi}(s_{h+1}, a_{h+1}) | s_h = s, a_h = a \right] - \mathbb{E}^{\widetilde{M},\pi} \left[Q_{h+1}^{M,\pi}(s_{h+1}, a_{h+1}) | s_h = s, a_h = a \right] \right|$$

$$+ \mathbb{E}^{\widetilde{M},\pi} \left[\left| Q_{h+1}^{M,\pi}(s_{h+1}, a_{h+1}) - Q_{h+1}^{\widetilde{M},\pi}(s_{h+1}, a_{h+1}) \right| | s_h = s, a_h = a \right]$$

$$\stackrel{(b)}{\leq} \left| \mathbb{E}^{M,\pi} \left[Q_{h+1}^{M,\pi}(s_{h+1}, a_{h+1}) | s_h = s, a_h = a \right] - \mathbb{E}^{\widetilde{M},\pi} \left[Q_{h+1}^{M,\pi}(s_{h+1}, a_{h+1}) | s_h = s, a_h = a \right] \right| + \epsilon_{h+1}$$

其中 (a) 遵循三角不等式, 而 (b) 遵循歸納假設。在 (A.1) 之下, 我們可以限制

$$\left| \mathbb{E}^{M,\pi} \left[Q_{h+1}^{M,\pi}(s_{h+1}, a_{h+1}) \mid s_h = s, a_h = a \right] - \mathbb{E}^{\widetilde{M},\pi} \left[Q_{h+1}^{M,\pi}(s_{h+1}, a_{h+1}) \mid s_h = s, a_h = a \right] \right| \leq \epsilon_{\text{sim}} \cdot R$$

由此可知，對於任何 (s, a) ， $\left| Q_h^{M,\pi}(s, a) - Q_h^{\widetilde{M},\pi}(s, a) \right| \leq \epsilon_h =: \epsilon_{\text{sim}} R + \epsilon_{h+1}$ 。

基礎情況在 $\epsilon_H = 0$ 時顯而易見，因為對於任何 MDP，我們都有 $Q_H^{M,\pi}(s, a) = r_H(s, a) = Q_H^{\widetilde{M},\pi}(s, a)$ 。

引理 A.2。在與引理 A.1 相同的設定下，且對於任何 h 、 π 與 $\mathcal{Z} \subseteq \mathcal{S} \times \mathcal{A}$ ，我們有

$$\left| w_h^{M,\pi}(\mathcal{Z}) - w_h^{\widetilde{M},\pi}(\mathcal{Z}) \right| \leq H \epsilon_{\text{sim}}$$

證明。這是引理 A.1 的直接結果，因為設定獎勵 $r_{h'}(s, a) = \mathbb{I}\{(s, a) \in \mathcal{Z}, h' = h\}$ ，我們可以設定 $R = 1$ 並得到 $V_0^{M,\pi} = w_h^{M,\pi}(\mathcal{Z})$ 。

引理 A.3 (命題 2)。在假設 1 之下，我們有

$$V_0^{\text{real},*} - V_0^{\text{real},\pi^{\text{sim},*}} \leq 2H^2 \epsilon_{\text{sim}} \text{ and } V_0^{\text{sim},*} - V_0^{\text{sim},\pi^{\text{real},*}} \leq 2H^2 \epsilon_{\text{sim}}$$

證明。我們證明 real 的結果，sim 的結果可以類推得出。我們得到

$$\begin{aligned} V_0^{\text{real},*} - V_0^{\text{real},\pi^{\text{sim},*}} &= V_0^{\text{real},\pi^{\text{real},*}} - V_0^{\text{sim},\pi^{\text{real},*}} + \underbrace{V_0^{\text{sim},\pi^{\text{real},*}} - V_0^{\text{sim},\pi^{\text{sim},*}}}_{\leq 0} + V_0^{\text{sim},\pi^{\text{sim},*}} - V_0^{\text{real},\pi^{\text{sim},*}} \\ &\leq \left| V_0^{\text{real},\pi^{\text{real},*}} - V_0^{\text{sim},\pi^{\text{real},*}} \right| + \left| V_0^{\text{sim},\pi^{\text{sim},*}} - V_0^{\text{real},\pi^{\text{sim},*}} \right|. \end{aligned}$$

接著應用 Lemma A. 1 將這些項分別限制在 $H^2 \epsilon_{\text{sim}}$ 以內，即可得出結果。

Lemma A.4. 對於任何 $f \in \mathcal{F}$ ，

$$V_0^* - V_0^{\pi^f} \leq \max_{\pi \in \{\pi^f, \pi^*\}} \sum_{h=0}^{H-1} 2 \left| \mathbb{E}^\pi [f_h(s_h, a_h) - \mathcal{T} f_{h+1}(s_h, a_h)] \right|$$

證明。我們寫下

$$V_0^* - V_0^{\pi^f} = \underbrace{V_0^* - \max_a f_0(s_0, a)}_{(a)} + \underbrace{\max_a f_0(s_0, a) - V_0^{\pi^f}}_{(b)}$$

然後分別限制這些項的範圍。根據 Song et al. (2022) 的 Lemma 5，我們得到

$$\begin{aligned} (a) &\leq \sum_{h=0}^H \left| \mathbb{E}^{\pi^*} \left[f_h(s_h, a_h) - r_h - \max_{a'} f_{h+1}(s_{h+1}, a') \right] \right| \\ &= \sum_{h=0}^{H-1} \left| \mathbb{E}^{\pi^*} \left[f_h(s_h, a_h) - \mathbb{E} \left[r_h + \max_{a'} f_{h+1}(s_{h+1}, a') \mid s_h, a_h \right] \right] \right| \end{aligned}$$

同樣地，根據 Song et al. (2022) 的 Lemma 4，我們得到

$$\begin{aligned} (b) &\leq \sum_{h=0}^{H-1} \left| \mathbb{E}^{\pi^f} \left[f_h(s_h, a_h) - r_h - \max_{a'} f_{h+1}(s_{h+1}, a') \right] \right| \\ &= \sum_{h=0}^{H-1} \left| \mathbb{E}^{\pi^f} \left[f_h(s_h, a_h) - \mathbb{E} \left[r_h + \max_{a'} f_{h+1}(s_{h+1}, a') \mid s_h, a_h \right] \right] \right| \end{aligned}$$

B 主要結果之證明

在附錄 B.1 中，我們首先提供一個在給定特定覆蓋假設下，透過一組固定的探索策略收集數據並在真實環境中進行學習的一般性結果。接著在附錄 B.2 中，我們證明透過執行一組在模擬環境中產生滿秩（full-rank）共變量的策略，這些策略能為真實環境中的學習提供足夠的覆蓋率。最後在附錄 B.3 與 B.4 中，我們利用這些結果來證明定理 1 與定理 3。在整個附錄中，我們為更具一般性的結果（定理 3）開發了支持性引理，該定理除了利用模擬器輔助探索外，還利用模擬器來限制版本空間（version space，即對 $|\mathcal{F}|$ 的依賴性）。

在本節及後續章節中，我們假設假設 4 成立。我們亦假設 $f_h \in [0, V_{\max}]$ 而非 $f_h \in [0, H]$ ，其中 $V_{\max} > 0$ 。對於任何 $f \in \mathcal{F}$ ，我們將 Bellman 殘差 (Bellman residual) 表示為

$$\mathcal{E}_h(f)(s, a) := \mathcal{T}f_{h+1}(s, a) - f_h(s, a)$$

請注意，根據對 $\mathcal{F}$ 的假設，我們得到 $\mathcal{E}_h(f)(s, a) \in [-V_{\max}, V_{\max}]$ 。

對於任何策略 π ，我們表示 $\mathbf{\Lambda}_{\pi, h}^s := \mathbb{E}^{\text{sim}, \pi} \left[\phi^s(s_h, a_h) \phi^s(s_h, a_h)^\top \right]$ 與 $\mathbf{\Lambda}_{\pi, h}^r := \mathbb{E}^{\text{real}, \pi} \left[\phi^r(s_h, a_h) \phi^r(s_h, a_h)^\top \right]$ 。

B.1 使用固定探索策略進行實體環境學習

Algorithm 3 sim2real transfer with fixed exploration policies (ExploreReal)



```
input: exploration policies  $\{\pi_{\exp}^h\}_{h=1}^H$ , budget  $B$ 
Play  $\pi_{\exp} = \text{unif}(\pi_{\exp}^h)_{h=1}^H$ 
for  $h=H, H-1, \dots, 1$  do
     $\tilde{f}_h \leftarrow \underset{f \in \mathcal{F}}{\arg \min} \sum_{(s,a) \in \mathcal{D}^{\text{sim}}_h} \|\tilde{f}_h(s,a) - \mathcal{T}f_{h+1}(s,a)\|^2$ 
     $\widehat{f}_h \leftarrow \underset{f \in \mathcal{F}}{\arg \min} \sum_{(s,a) \in \mathcal{D}^{\text{real}}_h} \|\widehat{f}_h(s,a) - \mathcal{T}f_{h+1}(s,a)\|^2$ 
    s.t.  $\frac{1}{|\mathcal{D}^{\text{sim}}_h|} \sum_{(s,a) \in \mathcal{D}^{\text{sim}}_h} \|\tilde{f}_h(s,a) - \mathcal{T}f_{h+1}(s,a)\|^2 \leq \frac{1}{|\mathcal{D}^{\text{real}}_h|} \sum_{(s,a) \in \mathcal{D}^{\text{real}}_h} \|\widehat{f}_h(s,a) - \mathcal{T}f_{h+1}(s,a)\|^2$ 
return  $\pi^{\widehat{f}}$ 
```

引理 B.1. 考慮執行演算法 3。假設 $\mathcal{D}_{\text{sim}}$ 是根據假設 5，透過引理 C.3 的程序並使用某些參數 β 所生成，且 γ 滿足

$$2V_{\max}^2 \epsilon_{\text{sim}}^2 + \frac{43V_{\max}^2 \beta^2}{dH} \cdot \log \frac{8H|\mathcal{F}_h|}{\delta} + 6V_{\max}^2 \beta \sqrt{\frac{\log \frac{8H|\mathcal{F}_h|}{\delta}}{dH}} \leq \gamma.$$

此外，假設存在某些 $\mathfrak{C}, \epsilon > 0$ ，使得對於任何 $\pi, h \in [H]$ 與 $\mathcal{Z}' \subseteq \mathcal{S} \times \mathcal{A}$ ，我們有：

$$w_h^{\text{real}, \pi}(\mathcal{Z}') \leq \mathfrak{C} \cdot w_h^{\text{real}, \pi_{\exp}}(\mathcal{Z}') + \epsilon$$

則至少有 $1 - 2\delta$ 的機率，由演算法 3 生成的策略 $\pi^{\widehat{f}}$ 滿足

$$V_0^* - V_0^{\pi^{\widehat{f}}} \leq 4\mathfrak{C}H \sqrt{\frac{256V_{\max}^2 \log(4H|\tilde{\mathcal{F}}(\pi_{\exp}^{\text{sim}})|/\delta)}{T}} + 4HV_{\max}\epsilon$$

對於

$$\tilde{\mathcal{F}}(\pi_{\exp}^{\text{sim}}) := \left\{ f \in \mathcal{F} : \mathbb{E}^{\text{sim}, \pi_{\exp}^{\text{sim}}} \left[(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h))^2 \right] \leq 2\gamma, \forall h \in [H] \right\}$$

證明。令 $\mathcal{E}$ 代表引理 B.2 中的良性事件 (good event)，其發生機率至少為 $1 - 2\delta$ 。根據引理 A.4，我們可得

$$V_0^{\text{real}, *} - V_0^{\text{real}, \pi^{\widehat{f}}} \leq \max_{\pi \in \{\pi^{\widehat{f}}, \pi^{\text{real}, *}\}} \sum_{h=0}^{H-1} 2 \left| \mathbb{E}^{\text{real}, \pi} \left[\widehat{f}_h(s_h, a_h) - \mathcal{T}^{\text{real}} \widehat{f}_{h+1}(s_h, a_h) \right] \right|$$

$$\leq \max_{\pi} \sum_{h=0}^{H-1} 2 \mathbb{E}^{\text{real}, \pi} \left[\left| \mathcal{E}_h^{\text{real}}(\widehat{f})(s_h, a_h) \right| \right]$$

假設

$$\mathcal{Z}_{h,i} := \left\{ (s, a) : \left| \mathcal{E}_h^{\text{real}}(\widehat{f})(s, a) \right| \in [V_{\max} \cdot 2^{-i}, V_{\max} \cdot 2^{-i+1}) \right\}$$

那麼，對於任何 π ，我們有：

$$\begin{aligned}
\mathbb{E}^{\text{real}, \pi} \left[\left| \mathcal{E}_h^{\text{real}}(\hat{f})(s_h, a_h) \right| \right] &\leq \sum_{i=1}^{\infty} w_h^{\text{real}, \pi}(\mathcal{Z}_{h,i}) \cdot V_{\max} 2^{-i+1} \\
&\leq \mathfrak{C} \cdot \sum_{i=1}^{\infty} w_h^{\text{real}, \pi_{\exp}}(\mathcal{Z}_{h,i}) \cdot V_{\max} 2^{-i+1} + 2V_{\max} \epsilon \\
&\leq 2\mathfrak{C} \cdot \mathbb{E}^{\text{real}, \pi_{\exp}} \left[\left| \mathcal{E}_h^{\text{real}}(\hat{f})(s_h, a_h) \right| \right] + 2V_{\max} \epsilon
\end{aligned}$$

其中第二個不等式由 (B.2) 得出。在 $\mathcal{E}$ 上，根據 Lemma B.2 與 Jensen' s inequality，我們可得

$$\mathbb{E}^{\text{real}, \pi_{\exp}} \left[\left| \mathcal{E}_h^{\text{real}}(\hat{f})(s_h, a_h) \right| \right] \leq \sqrt{\mathbb{E}^{\text{real}, \pi_{\exp}} \left[\mathcal{E}_h^{\text{real}}(\hat{f})(s_h, a_h)^2 \right]} \leq \sqrt{\frac{1}{T} \cdot 256V_{\max}^2 \log \frac{2H |\tilde{\mathcal{F}}_h(\pi_{\exp}^{\text{sim}})|}{\delta}}$$

由於這對每個 h 與 π 皆成立，因此我們已證明

$$\begin{aligned}
V_0^{\text{real}, \star} - V_0^{\text{real}, \pi^{\hat{f}}} &\leq 4\mathfrak{C} \cdot \sum_{h=0}^{H-1} \sqrt{\frac{1}{T} \cdot 256V_{\max}^2 \log \frac{2H |\tilde{\mathcal{F}}_h(\pi_{\exp}^{\text{sim}})|}{\delta}} + 4HV_{\max} \epsilon \\
&\leq 4\mathfrak{C}H \sqrt{\frac{1}{T} \cdot 256V_{\max}^2 \log \frac{2H |\tilde{\mathcal{F}}(\pi_{\exp}^{\text{sim}})|}{\delta}} + 4HV_{\max} \epsilon
\end{aligned}$$

這證明了該結果。

引理 B.2。機率至少為 $1 - 2\delta$ ，對於每個同時存在的 $h \in [H]$ ，只要引理 B.3 中給出的 γ 條件成立，我們便有

$$\mathbb{E}^{\text{real}, \pi_{\exp}} \left[\left(\hat{f}_h(s_h, a_h) - \mathcal{T}^{\text{real}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \leq \frac{1}{T} \cdot 256V_{\max}^2 \log \left(2H |\tilde{\mathcal{F}}_h(\pi_{\exp}^{\text{sim}})| / \delta \right)$$

且對所有 $h \in [H]$ 而言 $\hat{f}_h \in \tilde{\mathcal{F}}_h(\pi_{\exp}^{\text{sim}})$ ，其中

$$\tilde{\mathcal{F}}_h(\pi_{\exp}^{\text{sim}}) := \left\{ f_h \in \mathcal{F}_h : \exists f_{h+1} \in \mathcal{F}_{h+1} \text{ s.t. } \mathbb{E}^{\text{sim}, \pi_{\exp}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h) \right)^2 \right] \leq 2\gamma \right\}$$

證明。令 $\hat{\mathcal{F}}_h$ 表示步驟 h 時 (B.1) 的可行解集合。根據引理 B.3，機率至少為 $1 - \delta$ ， $\hat{\mathcal{F}}_h^t \subseteq \tilde{\mathcal{F}}_h$ ，且進一步得出 $\mathcal{T}^{\text{real}} \hat{f}_{h+1}$ 是可行的。由於回歸問題的限制條件縮減了版本空間 (version space)，因此結果遵循 Song et al. (2022) 的引理 3。

引理 B.3。假設 $\mathcal{D}_{\text{sim}}$ 中的資料是根據假設 5，透過引理 C.3 的程序並使用某些參數 β 所生成，且 γ 滿足

$$2V_{\max}^2 \epsilon_{\text{sim}}^2 + \frac{43V_{\max}^2 \beta^2}{dH} \cdot \log \frac{8H |\mathcal{F}_h|}{\delta} + 6V_{\max}^2 \beta \sqrt{\frac{\log \frac{8H |\mathcal{F}_h|}{\delta}}{dH}} \leq \gamma$$

則機率至少為 $1 - \delta$ ，對於每個 $h \in [H]$ ，我們有：

$\mathcal{T}^{\text{real}} \hat{f}_{h+1}$ 對於 (B.1) 是可行的。
(B.1) 的可行 f 集合為其子集

$$\left\{ f \in \mathcal{F} : \mathbb{E}^{\text{sim}, \pi_{\exp}^{\text{sim}}} \left[\left(f(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \leq 2\gamma \right\}$$

證明。根據引理 C.1，我們得到機率至少為 $1 - \delta/2H$ ，

$$\frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(\mathcal{T}^{\text{real}} \hat{f}_{h+1}(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2 \leq 2V_{\max}^2 \epsilon_{\text{sim}}^2 + \frac{512V_{\max}^2}{T_{\text{sim}}} \cdot \log \frac{8H |\mathcal{F}_h|}{\delta} + V_{\max}^2 \sqrt{\frac{2 \log \frac{4H |\mathcal{F}_h|}{\delta}}{T_{\text{sim}}}}$$

根據引理 C.3，我們得到 $\frac{12dH}{\beta^2} \leq T_{\text{sim}}$ ，這意味著

$$\frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(\mathcal{T}^{\text{real}} \hat{f}_{h+1}(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2 \leq 2V_{\text{max}}^2 \epsilon_{\text{sim}}^2 + \frac{43V_{\text{max}}^2 \beta^2}{dH} \cdot \log \frac{8H |\mathcal{F}_h|}{\delta} + V_{\text{max}}^2 \beta \sqrt{\frac{\log \frac{4H |\mathcal{F}_h|}{\delta}}{6dH}}$$

根據我們對 γ 的假設，第一部分隨之成立。

為了限制 (B.1) 的可行解集合（feasible set），我們引用引理 C.2，該引理指出機率至少為 $1 - \delta/2H$ 時，(B.1) 的可行解集合為以下集合的子集：

$$\left\{ f_h \in \mathcal{F}_h : \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \leq \gamma + 18V_{\text{max}}^2 \beta \sqrt{\frac{\log \frac{8H |\mathcal{F}_h|}{\delta}}{T_{\text{sim}}}} \right\}$$

再次使用 $\frac{12dH}{\beta^2} \leq T_{\text{sim}}$ ，我們得到這是其子集：

$$\begin{aligned} & \left\{ f_h \in \mathcal{F}_h : \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \leq \gamma + 18V_{\text{max}}^2 \beta \sqrt{\frac{\log \frac{8H |\mathcal{F}_h|}{\delta}}{12dH}} \right\} \\ & \subseteq \left\{ f_h \in \mathcal{F}_h : \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \leq 2\gamma \right\} \end{aligned}$$

其中包含關係源自我們對 γ 的假設。接著根據 Union Bound 即可得出結果。

B.2 全秩（Full-Rank）sim 策略在 real 環境中的效能

引理 B.4. 考慮策略 $\{\pi_{\text{exp}}^h\}_{h=1}^H$ ，並假設

$$\lambda_{\min}(\Lambda_{\pi_{\text{exp}}^h, h}^s) \geq \bar{\lambda}_{\min}, \quad \forall h \in [H]$$

且 π_{exp}^h 在 $h' > h$ 期間以均勻隨機的方式執行動作。令 $\pi_{\text{exp}} = \text{unif}(\{\pi_{\text{exp}}^h\}_{h=1}^H)$ 。則對於任何 $\pi, \kappa > 0, \gamma > 0, h \in [H]$ 與 $\mathcal{Z}' \subseteq \mathcal{S} \times \mathcal{A}$ ，我們得到

$$w_h^{\text{real}, \pi}(\mathcal{Z}') \leq \frac{4H\gamma A^{k^*-2}}{\kappa} \cdot w_h^{\text{real}, \pi_{\text{exp}}}(\mathcal{Z}') + 4\kappa$$

其中

$$\xi := 2\sqrt{\frac{A}{\bar{\lambda}_{\min}} \left(\frac{d}{\gamma} + H\epsilon_{\text{sim}} \right)} \quad \text{and} \quad k^* := \left\lceil \frac{\log 1/\kappa}{\log 1/\xi} \right\rceil.$$

證明。令

$$\tilde{\mathcal{Z}}_{h+1} := \left\{ (s, a) : \phi^{\text{r}}(s, a)^{\top} \left(\Lambda_{\pi_{\text{exp}}^h, h+1}^{\text{r}} \right)^{-1} \phi^{\text{r}}(s, a) > \gamma \right\}$$

對於某些 $\gamma > 0$ 。我們得到

$$\begin{aligned}
w_{h+1}^{\text{real}, \pi_{\text{exp}}^h}(\tilde{\mathcal{Z}}_{h+1}) &= \mathbb{E}^{\text{real}, \pi_{\text{exp}}^h} \left[\mathbb{I} \left\{ (s_{h+1}, a_{h+1}) \in \tilde{\mathcal{Z}}_{h+1} \right\} \right] \\
&\stackrel{(a)}{\leq} \mathbb{E}^{\text{real}, \pi_{\text{exp}}^h} \left[\frac{\phi^r(s_{h+1}, a_{h+1})^\top \left(\Lambda_{\pi_{\text{exp}}^h, h+1}^r \right)^{-1} \phi^r(s_{h+1}, a_{h+1})}{\gamma} \cdot \mathbb{I} \left\{ (s_{h+1}, a_{h+1}) \in \tilde{\mathcal{Z}}_{h+1} \right\} \right] \\
&\leq \mathbb{E}^{\text{real}, \pi_{\text{exp}}^h} \left[\frac{\phi^r(s_{h+1}, a_{h+1})^\top \left(\Lambda_{\pi_{\text{exp}}^h, h+1}^r \right)^{-1} \phi^r(s_{h+1}, a_{h+1})}{\gamma} \right] \\
&= \frac{1}{\gamma} \cdot \text{tr} \left(\mathbb{E}^{\text{real}, \pi_{\text{exp}}^h} \left[\phi^r(s_{h+1}, a_{h+1}) \phi^{r\top}(s_{h+1}, a_{h+1}) \right] \left(\Lambda_{\pi_{\text{exp}}^h, h+1}^r \right)^{-1} \right) \\
&= \frac{d}{\gamma}
\end{aligned}$$

其中 (a) 成立，是因為對於所有 $(s, a) \in \tilde{\mathcal{Z}}_{h+1}$ ，我們都有 $1 < \phi^r(s, a)^\top \left(\Lambda_{\pi_{\text{exp}}^h, h+1}^r \right)^{-1} \phi^r(s, a) / \gamma$ 。根據 Lemma A.2，我們接著可得

$$w_{h+1}^{\text{sim}, \pi_{\text{exp}}^h}(\tilde{\mathcal{Z}}_{h+1}) \leq \frac{d}{\gamma} + H\epsilon_{\text{sim}}$$

令 $\tilde{\mathcal{S}}_{h+1} := \{s : \exists a \text{ 使得 } (s, a) \in \tilde{\mathcal{Z}}_{h+1}\}$ ，並注意

$$\begin{aligned}
w_{h+1}^{\text{sim}, \pi_{\text{exp}}^h}(\tilde{\mathcal{Z}}_{h+1}) &= \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^h} \left[\int_{\tilde{\mathcal{S}}_{h+1}} \sum_{a: (s, a) \in \tilde{\mathcal{Z}}_{h+1}} \pi_{\text{exp}}^h(a | s, h+1) dP_h^{\text{sim}}(s | s_h, a_h) \right] \\
&\geq \frac{1}{A} \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^h} \left[\int_{\tilde{\mathcal{S}}_{h+1}} d\mu_h^s(s)^\top \phi^s(s_h, a_h) \right] \\
&= \frac{1}{A} \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^h} \left[P_h^{\text{sim}}(\tilde{\mathcal{S}}_{h+1} | s_h, a_h) \right] \\
&\geq \frac{1}{A} \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^h} \left[P_h^{\text{sim}}(\tilde{\mathcal{S}}_{h+1} | s_h, a_h)^2 \right]
\end{aligned}$$

其中我們使用了假設中對於所有 (s, a) ， $\pi_{\text{exp}}^h(a | s, h+1) = 1/A$ 皆成立的事實，並定義 $P_h^{\text{sim}}(\tilde{\mathcal{S}}_{h+1} | s, a) := \mathbb{P}^{\text{sim}}[s_{h+1} \in \tilde{\mathcal{S}}_{h+1} | s_h = s, a_h = a] = \int_{\tilde{\mathcal{S}}_{h+1}} d\mu_h^s(s)^\top \phi^s(s, a)$ ，其中最後一個等式源於 linear MDP 的定義。令 $\mu_h^s(\tilde{\mathcal{S}}_{h+1}) := \int_{\tilde{\mathcal{S}}_{h+1}} d\mu_h^s(s)$ ，注意：

$$\begin{aligned}
\frac{1}{A} \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^h} \left[P_h^{\text{sim}}(\tilde{\mathcal{S}}_{h+1} | s_h, a_h)^2 \right] &= \frac{1}{A} \mu_h^s(\tilde{\mathcal{S}}_{h+1})^\top \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^h} \left[\phi^s(s_h, a_h) \phi^{s\top}(s_h, a_h) \right] \mu_h^s(\tilde{\mathcal{S}}_{h+1}) \\
&= \frac{1}{A} \mu_h^s(\tilde{\mathcal{S}}_{h+1})^\top \Lambda_{\pi_{\text{exp}}^h, h}^s \mu_h^s(\tilde{\mathcal{S}}_{h+1}) \\
&\geq \frac{\bar{\lambda}_{\min}}{A} \left\| \mu_h^s(\tilde{\mathcal{S}}_{h+1}) \right\|_2^2
\end{aligned}$$

其中最後一個不等式源於 (B.3)。將此與 (B.4) 結合，我們得到

$$\frac{d}{\gamma} + H\epsilon_{\text{sim}} \geq \frac{\bar{\lambda}_{\min}}{A} \left\| \mu_h^s(\tilde{\mathcal{S}}_{h+1}) \right\|_2^2$$

現在請注意，對於任何 $z \in \mathcal{S} \times \mathcal{A}$ ：

$$P_h^{\text{sim}}(\tilde{\mathcal{S}}_{h+1} | z) = \int_{\tilde{\mathcal{S}}_{h+1}} dP_h^{\text{sim}}(s | z) = \left(\int_{\tilde{\mathcal{S}}_{h+1}} d\mu_h^s(s) \right)^\top \phi^s(z) \leq \left\| \mu_h^s(\tilde{\mathcal{S}}_{h+1}) \right\|_2$$

且在假設 1 (Assumption 1) 之下，我們也得到 $P_h^{\text{sim}}(\tilde{\mathcal{S}}_{h+1} | z) \geq P_h^{\text{real}}(\tilde{\mathcal{S}}_{h+1} | z) - \epsilon_{\text{sim}}$ 。綜合以上結果，對於所有 $z \in \mathcal{S} \times \mathcal{A}$ ：

$$P_h^{\text{real}}(\tilde{\mathcal{S}}_{h+1} | z) \leq \sqrt{\frac{A}{\bar{\lambda}_{\min}} \left(\frac{d}{\gamma} + H\epsilon_{\text{sim}} \right)} + \epsilon_{\text{sim}}$$

注意我們總是可以取 $\epsilon_{\text{sim}} \leq 1$ ，且總會得到 $\bar{\lambda}_{\min} \leq 1$ 。這意味著 $\epsilon_{\text{sim}} \leq \sqrt{\frac{A}{\bar{\lambda}_{\min}} \left(\frac{d}{\gamma} + H\epsilon_{\text{sim}} \right)}$ 。因此，

$$P_h^{\text{real}}(\tilde{\mathcal{S}}_{h+1} | z) \leq 2\sqrt{\frac{A}{\bar{\lambda}_{\min}} \left(\frac{d}{\gamma} + H\epsilon_{\text{sim}} \right)} =: \xi.$$

π_{exp} 在真實環境中的覆蓋範圍 (Coverage)。令 $k^* := \left\lceil \frac{\log 1/\kappa}{\log 1/\xi} \right\rceil$ ，使得 $\xi^{k^*} \leq \kappa$ 。令 $\bar{\mathcal{Z}}_h := (\mathcal{S} \times \mathcal{A}) \setminus \tilde{\mathcal{Z}}_h$ 。固定某個 $\mathcal{Z}' \subseteq (\mathcal{S} \times \mathcal{A})$, $h \in [H]$ 與策略 (policy) π 。

考慮一些 $z \in \bar{\mathcal{Z}}_h$ 以及一些 $\mathcal{S}' \subseteq \mathcal{S}$ 。接著請注意⁵

$$\begin{aligned} P_h^{\text{real}}(\mathcal{S}' | z) &= \boldsymbol{\mu}_h^r(\mathcal{S}')^\top \boldsymbol{\phi}^r(z) = \boldsymbol{\mu}_h^r(\mathcal{S}')^\top \left(\boldsymbol{\Lambda}_{\pi_{\text{exp}}^{h-1}, h}^r \right)^{1/2} \left(\boldsymbol{\Lambda}_{\pi_{\text{exp}}^{h-1}, h}^r \right)^{-1/2} \boldsymbol{\phi}^r(z) \\ &\leq \left\| \boldsymbol{\mu}_h^r(\mathcal{S}') \right\|_{\boldsymbol{\Lambda}_{\pi_{\text{exp}}^{h-1}, h}^r} \left\| \boldsymbol{\phi}^r(z) \right\| \left(\boldsymbol{\Lambda}_{\pi_{\text{exp}}^{h-1}, h}^r \right)^{-1} \\ &\leq \sqrt{\gamma} \left\| \boldsymbol{\mu}_h^r(\mathcal{S}') \right\|_{\boldsymbol{\Lambda}_{\pi_{\text{exp}}^{h-1}, h}^r} \end{aligned}$$

其中最後一個不等式遵循 $\bar{\mathcal{Z}}_h$ 的定義。但請注意，

$$\left\| \boldsymbol{\mu}_h^r(\mathcal{S}') \right\|_{\boldsymbol{\Lambda}_{\pi_{\text{exp}}^{h-1}, h}^r}^2 = \mathbb{E}^{\text{real}, \pi_{\text{exp}}^{h-1}} \left[\left(\boldsymbol{\mu}_h^r(\mathcal{S}')^\top \boldsymbol{\phi}^r(z_h) \right)^2 \right] = \mathbb{E}^{\text{real}, \pi_{\text{exp}}^{h-1}} \left[P_h^{\text{real}}(\mathcal{S}' | z_h)^2 \right]$$

這意味著對於所有的 $z \in \bar{\mathcal{Z}}_h$ ，

$$\mathbb{E}^{\text{real}, \pi_{\text{exp}}^{h-1}} \left[P_h^{\text{real}}(\mathcal{S}' | z_h)^2 \right] \geq \frac{1}{\gamma} \cdot P_h^{\text{real}}(\mathcal{S}' | z)^2$$

對於 $h' < h$ ，定義

$$\mathcal{S}_{h',i} := \left\{ s : w_h^{\text{real}, \pi}(\mathcal{Z}' | s_{h'} = s) \in [2^{-i+1}, 2^{-i}] \right\}$$

針對 $w_h^{\text{real}, \pi}(\mathcal{Z} | s_{h'} = s) := \mathbb{P}^{\text{real}, \pi}[z_h \in \mathcal{Z} | s_{h'} = s]$ 。請注意，我們接著得到 $w_h^{\text{real}, \pi}(\mathcal{Z}' | \mathcal{S}_{h',i}) \in [2^{-i+1}, 2^{-i}]$ 。根據我們剛才展示的結果，對於 $z \in \bar{\mathcal{Z}}_{h'}$ ，我們得到

$$\mathbb{E}^{\text{real}, \pi_{\text{exp}}^{h'-1}} \left[P_{h'}^{\text{real}}(\mathcal{S}_{h'+1,i} | z_{h'})^2 \right] \geq \frac{1}{\gamma} \cdot P_{h'}^{\text{real}}(\mathcal{S}_{h'+1,i} | z)^2$$

這意味著

$$\mathbb{E}^{\text{real}, \pi_{\text{exp}}^{h'-1}} \left[P_{h'}^{\text{real}}(\mathcal{S}_{h'+1,i} | z_{h'}) \right] \geq \frac{1}{\gamma} \cdot P_{h'}^{\text{real}}(\mathcal{S}_{h'+1,i} | z)^2$$

固定 $z \in \bar{\mathcal{Z}}_{h'}$ 。請注意

$$\begin{aligned}
w_h^{\text{real}, \pi}(\mathcal{Z}' \mid z_{h'} = z) &= \mathbb{E}_{s \sim P_{h'}^{\text{real}}(\cdot \mid z)} \left[w_h^{\text{real}, \pi}(\mathcal{Z}' \mid s_{h'+1} = s) \right] \\
&= \sum_{i=1}^{\infty} \mathbb{E}_{s \sim P_{h'}^{\text{real}}(\cdot \mid z)} \left[w_h^{\text{real}, \pi}(\mathcal{Z}' \mid s_{h'+1} = s) \cdot \mathbb{I}\{s \in \mathcal{S}_{h'+1, i}\} \right] \\
&\leq \sum_{i=1}^{\infty} 2^{-i+1} P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) \\
&= \sum_{i=1}^{\lfloor \log 4/\kappa \rfloor} 2^{-i+1} P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) + \kappa \\
&\leq \sum_{i=1}^{\lfloor \log 4/\kappa \rfloor} 2^{-i+1} P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) \cdot \mathbb{I}\{P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) \geq \kappa\} + 3\kappa \\
&\leq 2 \sum_{i=1}^{\lfloor \log 4/\kappa \rfloor} \mathbb{E}_{s \sim \lambda_i} \left[w_h^{\text{real}, \pi}(\mathcal{Z}' \mid s_{h'+1} = s) \right] P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) \cdot \mathbb{I}\{P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) \geq \kappa\} + 3\kappa
\end{aligned}$$

對於任何 $\lambda_i \in \Delta_{\mathcal{S}'+1, i}$ 。另請注意，由於 $\pi_{\text{exp}}^{h'-1}$ 對於所有 $h'' \geq h'$ 均隨機進行遊戲，我們得到：

$$w_h^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{Z}' \mid s_{h'+1} = s) \geq \frac{1}{A^{h-h'}} \cdot w_h^{\text{real}, \pi}(\mathcal{Z}' \mid s_{h'+1} = s),$$

由於在任何給定的回合中， $\pi_{\text{exp}}^{h'-1}$ 有 $1/A^{h-h'}$ 的機率會執行與 π 從第 h' 步到第 h 步相同的動作序列。因此，我們可以對上述內容進行界定：

$$\begin{aligned}
&\leq 2A^{h-h'} \cdot \sum_{i=1}^{\lfloor \log 4/\kappa \rfloor} \mathbb{E}_{s \sim \lambda_i} \left[w_h^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{Z}' \mid s_{h'+1} = s) \right] P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) \cdot \mathbb{I}\{P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) \geq \kappa\} + 3\kappa \\
&\stackrel{(a)}{\leq} \frac{2A^{h-h'} \gamma}{\kappa} \cdot \sum_{i=1}^{\lfloor \log 4/\kappa \rfloor} \mathbb{E}_{s \sim \lambda_i} \left[w_h^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{Z}' \mid s_{h'+1} = s) \right] \mathbb{E}^{\text{real}, \pi_{\text{exp}}^{h'-1}}[P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z_{h'})] \mathbb{I}\{P_{h'}^{\text{real}}(\mathcal{S}_{h'+1, i} \mid z) \geq \kappa\} + 3\kappa \\
&\leq \frac{2\gamma A^{h-h'}}{\kappa} \cdot \sum_{i=1}^{\lfloor \log 4/\kappa \rfloor} \mathbb{E}_{s \sim \lambda_i} \left[w_h^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{Z}' \mid s_{h'+1} = s) \right] \cdot w_{h'+1}^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{S}_{h'+1, i}) + 3\kappa \\
&\stackrel{(b)}{=} \frac{2\gamma A^{h-h'}}{\kappa} \cdot \sum_{i=1}^{\lfloor \log 4/\kappa \rfloor} \sum_{s \in \mathcal{S}_{h'+1, i}} w_h^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{Z}' \mid s_{h'+1} = s) w_{h'+1}^{\text{real}, \pi_{\text{exp}}^{h'-1}}(s) + 3\kappa \\
&\leq \frac{2\gamma A^{h-h'}}{\kappa} \cdot w_h^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{Z}') + 3\kappa
\end{aligned}$$

其中 (a) 遵循 (B.5) 且由於 $P_{h'}^{\text{real}}(\mathcal{S}_{h', i} \mid z) \geq \kappa$ ，而 (b) 則遵循選擇

$\lambda_i(s) = w_{h'+1}^{\text{real}, \pi_{\text{exp}}^{h'-1}}(s) / w_{h'+1}^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{S}_{h'+1, i}) \cdot \mathbb{I}\{s \in \mathcal{S}_{h'+1, i}\}$ 。因此，對於所有的 $z \in \overline{\mathcal{Z}}_{h'}$ ，我們得到：

$$w_h^{\text{real}, \pi}(\mathcal{Z}' \mid z_{h'} = z) \leq \frac{2\gamma A^{h-h'}}{\kappa} \cdot w_h^{\text{real}, \pi_{\text{exp}}^{h'-1}}(\mathcal{Z}') + 3\kappa$$

控制事件。考慮事件 $\mathcal{E} := \{z_h \in \mathcal{Z}'\}$ 與 $\mathcal{E}_{h'} := \{z_{h'} \in \overline{\mathcal{Z}}_{h'}\}$ 。我們接著得到

$$\begin{aligned}
w_h^{\text{real}, \pi}(\mathcal{Z}') &= \mathbb{P}^{\text{real}, \pi}[\mathcal{E}] \\
&= \mathbb{P}^{\text{real}, \pi}[\mathcal{E} \cap \mathcal{E}_{h-1}] + \mathbb{P}^{\text{real}, \pi}[\mathcal{E} \cap \mathcal{E}_{h-1}^c] \\
&= \sum_{h'=h-k^*+1}^h \mathbb{P}^{\text{real}, \pi} \left[\mathcal{E} \cap \mathcal{E}_{h'-1} \cap \bigcap_{i=h'}^{h-1} \mathcal{E}_i^c \right] + \mathbb{P}^{\text{real}, \pi} \left[\mathcal{E} \cap \mathcal{E}_{h-k^*-1} \cap \bigcap_{i=h-k^*}^{h-1} \mathcal{E}_i^c \right] \\
&\leq \sum_{h'=h-k^*+1}^h \mathbb{P}^{\text{real}, \pi}[\mathcal{E} \cap \mathcal{E}_{h'-1}] + \mathbb{P}^{\text{real}, \pi} \left[\mathcal{E} \cap \mathcal{E}_{h-k^*-1} \cap \bigcap_{i=h-k^*}^{h-1} \mathcal{E}_i^c \right]
\end{aligned}$$

我們現在分析這些項。首先，請注意

$$\mathbb{P}^{\text{real}, \pi}[\mathcal{E} \cap \mathcal{E}_{h'-1}] = \mathbb{P}^{\text{real}, \pi}[\mathcal{E} \mid \mathcal{E}_{h'-1}] \mathbb{P}^{\text{real}, \pi}[\mathcal{E}_{h'-1}] \leq \mathbb{P}^{\text{real}, \pi}[\mathcal{E} \mid \mathcal{E}_{h'-1}] = w_h^{\text{real}, \pi}(\mathcal{Z}' \mid z_{h'-1} \in \overline{\mathcal{Z}}_{h'-1})$$

我們接著可以限制

$$w_h^{\text{real}, \pi} \left(\mathcal{Z}' \mid z_{h'-1} \in \overline{\mathcal{Z}}_{h'-1} \right) \leq \frac{2\gamma A^{h-h'-1}}{\kappa} \cdot w_h^{\text{real}, \pi_{\text{exp}}^{h'-2}} (\mathcal{Z}') + 3\kappa$$

其中不等式由 (B.6) 推導而得。對於第二項，我們得到

$$\begin{aligned} \mathbb{P}^{\text{real}, \pi} \left[\mathcal{E} \cap \mathcal{E}_{h-k^*-1} \cap \bigcap_{i=h-k^*}^{h-1} \mathcal{E}_i^c \right] &\leq \mathbb{P}^{\text{real}, \pi} \left[\mathcal{E} \cap \bigcap_{i=h-k^*}^{h-1} \mathcal{E}_i^c \right] \\ &= \mathbb{P}^{\text{real}, \pi} \left[\mathcal{E} \mid \bigcap_{i=h-k^*}^{h-1} \mathcal{E}_i^c \right] \cdot \prod_{j=1}^{k^*} \mathbb{P}^{\text{real}, \pi} \left[\mathcal{E}_{h-j}^c \mid \bigcap_{i=h-k^*}^{h-j-1} \mathcal{E}_i^c \right]. \end{aligned}$$

然而請注意，對於所有的 j ， $\mathbb{P}^{\text{real}, \pi} \left[\mathcal{E} \mid \bigcap_{i=h-k^*}^{h-1} \mathcal{E}_i^c \right] \leq \xi$ 且 $\mathbb{P}^{\text{real}, \pi} \left[\mathcal{E}_{h-j}^c \mid \bigcap_{i=h-k^*}^{h-j-1} \mathcal{E}_i^c \right] \leq \xi$ 。因此我們可以將上述內容限制為

$$\xi^{k^*+1} \leq \kappa$$

綜上所述，我們得到

$$w_h^{\text{real}, \pi} (\mathcal{Z}') \leq \sum_{h'=h-k^*+1}^h \frac{2\gamma A^{h-h'-1}}{\kappa} \cdot w_h^{\text{real}, \pi_{\text{exp}}^{h'-2}} (\mathcal{Z}') + 4\kappa$$

此外，由於 $\pi_{\text{exp}} = \text{unif} \left(\{\pi_{\text{exp}}^h\}_{h=1}^H \right)$ ，我們有 $w_h^{\text{real}, \pi_{\text{exp}}^{h'-2}} (\mathcal{Z}') \leq H w_h^{\text{real}, \pi_{\text{exp}}} (\mathcal{Z}')$ ，因此我們得出結論

$$w_h^{\text{real}, \pi} (\mathcal{Z}') \leq \frac{4H\gamma A^{k^*-2}}{\kappa} \cdot w_h^{\text{real}, \pi_{\text{exp}}} (\mathcal{Z}') + 4\kappa$$

B.3 無約束上限之證明

定理 2。假設滿足以下兩個條件之一：

對於每個 h, π_{exp}^h ，在 $h' > h$ 期間均勻隨機地執行動作，

$$\lambda_{\min} \left(\Lambda_{\pi_{\text{exp}}^h, h}^s \right) \geq \bar{\lambda}_{\min}$$

以及

$$T \geq c \cdot \frac{V_{\max}^4 H^4 d^2 A^{2(k^*-2)} \log(2H|\mathcal{F}|/\delta)}{\epsilon^4 \epsilon_{\text{sim}}^2}$$

針對

$$k^* = \left\lceil \frac{\log_A \frac{64HV_{\max}}{\epsilon}}{\log_A 1/\xi} \right\rceil, \quad \xi = 2\sqrt{\frac{2HA}{\bar{\lambda}_{\min}}} \cdot \epsilon_{\text{sim}}.$$

$$\epsilon_{\text{sim}} \leq \epsilon/4H^2 \text{ 以及}$$

$$T \geq \frac{16H^2 \log \frac{4}{\delta}}{\epsilon^2}$$

則至少有 $1 - \delta$ 的機率，演算法 1 會回傳一個 $\hat{\pi}$ 使得 $V_0^{\text{real}, \pi^{\text{real}, *}} - V_0^{\text{real}, \hat{\pi}} \leq \epsilon$ 。
證明。我們考慮上述的每個條件。

條件 1。首先，根據我們對 π_{exp} 的假設，並將引理 B.4 應用於 $\kappa = \frac{\epsilon}{64HV_{\max}}$ 與 $\gamma = \frac{d}{H\epsilon_{\text{sim}}}$ ，對於任何 π 與 $\mathcal{Z}' \subseteq \mathcal{S} \times \mathcal{A}$ ，我們得到

$$w_h^{\text{real}, \pi} (\mathcal{Z}') \leq \frac{256dHV_{\max} A^{k^*-2}}{\epsilon \epsilon_{\text{sim}}} \cdot w_h^{\text{real}, \pi_{\text{exp}}} (\mathcal{Z}') + \frac{\epsilon}{16HV_{\max}}$$

對於

$$k^* = \left\lceil \frac{\log_A \frac{64HV_{\max}}{\epsilon}}{\log_A 1/\xi} \right\rceil, \quad \xi = 2\sqrt{\frac{2HA}{\bar{\lambda}_{\min}}} \cdot \epsilon_{\text{sim}}$$

根據 Lemma B. 1, 我們接著可得出, 機率至少為 $1 - \delta^6$,

$$\begin{aligned} V_0^{\text{real}, \pi^{\text{real}, *}} - V_0^{\text{real}, \hat{\pi}} &\leq \frac{256dHV_{\max}A^{k^*-2}}{\epsilon\epsilon_{\text{sim}}} \cdot 4H\sqrt{\frac{256V_{\max}^2 \log(2H|\mathcal{F}|/\delta)}{T}} + \epsilon/4 \\ &\leq \epsilon/2 \end{aligned}$$

其中最後一個不等式是在我們對 T 的條件下成立。

條件 2。根據 Lemma A.3, 我們得到 $V_0^{\text{real}, *} - V_0^{\text{real}, \pi^{\text{sim}, *}} \leq 2H^2\epsilon_{\text{sim}}$ 。因此, 若 $\epsilon_{\text{sim}} \leq \epsilon/4H^2$, 則我們得到 $V_0^{\text{real}, *} - V_0^{\text{real}, \pi^{\text{sim}, *}} \leq \epsilon/2$ 。

結論。根據我們所展示的內容, 只要滿足我們的其中一個條件, 機率至少為 $1 - \delta/2$, 存在 $\pi \in \{\pi^{\hat{f}}, \pi^{\text{sim}, *}\}$ 使得 $V_0^{\text{real}, *} - V_0^{\text{real}, \pi} \leq \epsilon/2$ 。將此策略表示為 $\hat{\pi}$ 。

請注意 $V_0^{\text{real}, \pi} = \mathbb{E}^{\text{real}, \pi} \left[\sum_{h=0}^{H-1} r_h \right]$ 且幾乎確定 (almost surely) $\sum_{h=0}^{H-1} r_h \in [0, H]$ 。考慮在真實環境中執行 π 共 $T/4$ 個回合 (episodes), 並令 R^i 代表第 i 個回合的總回報 (total return)。令

$$\hat{V}_0^\pi := \frac{4}{T} \sum_{i=1}^{T/4} R^i$$

根據 Hoeffding 不等式, 我們得到在機率至少為 $1 - \delta/4$ 的情況下:

$$|\hat{V}_0^\pi - V_0^{\text{real}, \pi}| \leq H\sqrt{\frac{4 \log \frac{4}{\delta}}{T}}$$

因此, 如果

$$T \geq \frac{16H^2 \log \frac{4}{\delta}}{\epsilon^2}$$

我們得到 $|\hat{V}_0^\pi - V_0^{\text{real}, \pi}| \leq \epsilon/2$ 。對兩者 $\pi \in \{\pi^{\hat{f}}, \pi^{\text{sim}, *}\}$ 進行聯集界限 (Union bounding) 處理後, 我們得到在機率至少為 $1 - \delta/2$ 的情況下:

$$V_0^{\text{real}, \hat{\pi}} \geq \hat{V}_0^{\hat{\pi}} - \epsilon/4 \geq \hat{V}_0^{\tilde{\pi}} - \epsilon/4 \geq V_0^{\text{real}, \tilde{\pi}} - \epsilon/2$$

由此可得

$$V^{\text{real}, *} - V_0^{\text{real}, \hat{\pi}} \leq V^{\text{real}, *} - V_0^{\text{real}, \tilde{\pi}} + \epsilon/2 \leq \epsilon.$$

證明源於聯集界限 (union bound) 以及我們對 T 的條件 (請注意, (B.8) 在兩種情況下皆成立)。

定理 1 之證明。我們首先假設 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$, 其中 ζ 為由 Algorithm 1 提供給 Algorithm 5 的輸入正規化值, 以及定理 2 的條件 1, 並證明在此情況下 A^{k^*-2} 至多為問題參數的多項式。

首先, 根據 Lemma C. 7, 在假設 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$ 的情況下, 由 Algorithm 5 回傳之策略均勻混合 (uniform mixture) 所產生的策略 π_{exp}^h , 在假設 3 之下, 將以至少 $1 - \delta$ 的機率滿足 $\lambda_{\min} \left(\mathbf{\Lambda}_{\pi_{\text{exp}}^h}^s \right) \geq \frac{\lambda_{\min}^*}{8d}$ 。將 $\bar{\lambda}_{\min} \leftarrow \frac{\lambda_{\min}^*}{8d}$ 代入定理 2, 我們得到 $\xi = 2\sqrt{\frac{16dHA}{\lambda_{\min}^*}} \cdot \epsilon_{\text{sim}}$ 。現在請注意

$$A^{k^*-2} \leq A^{\frac{\log_A 64HV_{\max}/\epsilon}{\log_A 1/\xi}} = \left(\frac{64HV_{\max}}{\epsilon} \right)^{1/\log_A 1/\xi}$$

那麼我們只需證明 $1/\log_A 1/\xi \leq 1 \iff 1/A \geq \xi$ 即可。然而，這顯然符合我們對 ϵ_{sim} 的條件。因此，只要

$$T \geq c \cdot \frac{V_{\max}^6 H^6 d^2 \log(2HT|\mathcal{F}|/\delta)}{\epsilon^6 \epsilon_{\text{sim}}^2}$$

根據 Theorem 2, 我們可得 $\hat{\pi}$ 為 ϵ -optimal。

現在，若 $\epsilon_{\text{sim}} \leq \epsilon/4H^2$ 且 $T \geq \frac{16H^2 \log 4/\delta}{\epsilon}$ ，根據 Theorem 2, 我們同樣可得 $\hat{\pi}$ 為 ϵ -optimal。因此，在第一種情況下，我們最多需要

$$T \geq c \cdot \frac{V_{\max}^6 H^{10} d^2 \log(2HT|\mathcal{F}|/\delta)}{\epsilon^8}$$

即可產生一個 ϵ -optimal 的策略，否則我們將處於第二種情況。

假設 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$ 的前提仍需證明。請注意，(4.2) 的條件僅在第一種情況中是必要的。此外，若 $\epsilon_{\text{sim}} \leq \epsilon/4H^2$ ，我們將處於第二種情況。因此，在第一種情況下，我們將得到

$$\frac{\epsilon}{4H^2} \leq \epsilon_{\text{sim}} \leq \frac{\lambda_{\min}^*}{64dHA^3}$$

重新整理後，為了符合第一種情況，我們得到

$$\frac{16dA^3\epsilon}{H} \leq \lambda_{\min}^*$$

根據我們對 $\zeta = \frac{4A^3\epsilon}{H}$ 的選擇，可得出 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$ 。根據 Lemma C.7 以及我們對 ζ 的選擇，Oracle 4.2 最多被呼叫 $\text{poly}(d, H, \epsilon^{-1}, \log \frac{1}{\delta})$ 次，而我們僅呼叫 Oracle 4.1 的 oracle H 次。結果可透過 Union Bound 與重新縮放 δ 得出。

B.4 縮減版本空間 (Reducing the Version Space)

正如我們所指出的，一般而言，在我們不假設 ϕ^r 為未知的情況下， $\log |\mathcal{F}|$ 可能會顯著大於維度。我們或許可以希望，在能夠存取 $\mathcal{M}^{\text{sim}}$ 的情況下，我們可以稍微減少這種依賴性。接下來我們將展示，在能夠存取以下受限迴歸 Oracle (Constrained Regression Oracle) 的情況下，這是可能的。

Oracle B.1 (受限迴歸 Oracle)。我們假設可以存取一個迴歸 Oracle，使得對於任何 h 以及資料集 $\{(s^t, a^t, y^t)\}_{t=1}^T$ 和 $\{(\tilde{s}^t, \tilde{a}^t, \tilde{y}^t)\}_{t=1}^{\tilde{T}}$ ，我們可以計算：

$$\hat{f}_h = \arg \min_{f \in \mathcal{F}_h} \sum_{t=1}^T (f(s^t, a^t) - y^t)^2 \quad \text{s.t.} \quad \sum_{t=1}^{\tilde{T}} (f(\tilde{s}^t, \tilde{a}^t) - \tilde{y}^t)^2 \leq \gamma$$

雖然一般而言 Oracle B.1 的 Oracle 無法簡化為 Oracle 4.1 的 Oracle，但在 $\mathcal{F}$ 的某些條件下，這是可能的。有了這個 Oracle，我們得到以下結果。

Theorem 3. 假設 $\epsilon_{\text{sim}} \leq \frac{\lambda_{\min}^*}{64dHA^3}$ 。那麼如果

$$T \geq \tilde{\mathcal{O}} \left(\frac{d^2 H^{16}}{\epsilon^8} \cdot \log \frac{H|\tilde{\mathcal{F}}|}{\delta} \right)$$

以至少 $1 - \delta$ 的機率，演算法 4 會回傳策略 $\hat{\pi}$ 並滿足 $V_0^{\text{real}, \pi^{\text{real}, *}} - V_0^{\text{real}, \hat{\pi}} \leq \epsilon$ ，其中

$$\tilde{\mathcal{F}} := \left\{ f \in \mathcal{F} : \sup_{\pi} \left(\mathbb{E}^{\text{sim}, \pi} [f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h)] \right)^2 \leq \alpha \cdot \epsilon_{\text{sim}}^2 \right\}$$

對於 $\alpha = \tilde{\mathcal{O}} \left(AdH^3 \cdot \log^2 \frac{\log |\mathcal{F}|/\delta}{\epsilon_{\text{sim}}} \right)$ 。此外，Oracle 4.2 與 Oracle B.1 的運算 oracle 最多被呼叫 $\text{poly}(d, A, H, \epsilon^{-1}, \log \frac{|\mathcal{F}|}{\delta})$ 次。

定理 3 顯示，我們不需要支付 $\mathcal{F}$ 的完整複雜度，而只需支付在 $\mathcal{M}^{\text{sim}}$ 上具備 Bellman 一致性 (Bellman-consistent) 之 $\mathcal{F}$ 子集的代價。

Algorithm 4 sim-to-real transfer via simulated exploration (Sim2Explore)



```

input: tolerance  $(\epsilon)$ , confidence  $(\delta)$ , budget  $(T, Q)$ -value function  $(\pi_{\text{exp}}^h \leftarrow) \text{LearnExpPolicies } (\left(\mathcal{M}^{\text{exp}} \leftarrow \mathcal{I} \leftarrow \mathcal{H}^{\epsilon} \right) \text{ for } (\ell=1,2, \dots, \iota) \text{ do}$ 
     $(\bar{\epsilon}^{\ell} \leftarrow 2^{-\ell}, T^{\ell} \leftarrow T / 2^{\ell})$ 
    Run exploration procedure of Lemma C. 3 with  $(\beta_{\ell} \leftarrow \frac{\epsilon}{2^{\ell}})$ 
     $(\widehat{\pi}^{\ell} \leftarrow \text{ExploreReal}(\left(\mathcal{M}^{\text{exp}} \leftarrow \mathcal{I} \leftarrow \mathcal{H}^{\epsilon} \right) \text{ for } (\ell=1,2, \dots, \iota) \text{ do}$ 
     $(\widehat{V}_{\ell} \leftarrow \text{average return running } (\pi_{\text{exp}}^h \leftarrow) \text{ for } (\ell=1,2, \dots, \iota) \text{ do}$ 
return  $(\widehat{\pi} \leftarrow \arg \max_{\ell \in [1, \iota]} \widehat{V}_{\ell})$ 

```

定理 4。假設滿足以下兩個條件之一：

對於每個 h, π_{exp}^h ，在 $h' > h$ 期間均勻隨機地執行動作，

$$\lambda_{\min}(\Lambda_{\pi_{\text{exp}}^h, h}^s) \geq \bar{\lambda}_{\min}$$

以及

$$T \geq c \cdot \frac{V_{\max}^4 H^4 d^2 A^{2(k^*-2)} \iota \log(16H|\tilde{\mathcal{F}}|/\delta)}{\epsilon^4 \epsilon_{\text{sim}}^2},$$

對於

$$k^* = \left\lceil \frac{\log_A \frac{64HV_{\max}}{\epsilon}}{\log_A 1/\xi} \right\rceil, \quad \xi = 2\sqrt{\frac{2HA}{\bar{\lambda}_{\min}}} \cdot \epsilon_{\text{sim}}$$

與

$$\begin{aligned} \tilde{\mathcal{F}} &:= \{f \in \mathcal{F} : \sup_{\pi} (\mathbb{E}^{\text{sim}, \pi} [f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h)])^2 \\ &\leq c \left(\log \frac{\log \frac{32H|\mathcal{F}|}{\delta}}{V_{\max} \epsilon_{\text{sim}}^2} + 1 \right) AdHV_{\max}^2 \log \frac{48d \log \frac{32H|\mathcal{F}|}{\delta}}{V_{\max} \epsilon_{\text{sim}}^2} \cdot \epsilon_{\text{sim}}^2 \} \end{aligned}$$

$$\epsilon_{\text{sim}} \leq \epsilon/16H^2 \text{ 與}$$

$$T \geq c \cdot \frac{H^2 \iota \log \frac{16\iota}{\delta}}{\epsilon^2}$$

則至少有 $1 - \delta$ 的機率，Algorithm 4 會回傳一個策略 $\hat{\pi}$ ，使得 $V_0^{\text{real}, \pi^{\text{real}, *}} - V_0^{\text{real}, \hat{\pi}} \leq \epsilon$ 。
證明。我們將證明分為兩種情況。

情況 1: $\epsilon_{\text{sim}} \geq \epsilon/16H^2$ 。令 $\bar{\ell} = \lfloor \log_2 \epsilon_{\text{sim}}^{-1} \rfloor$ 並注意在此情況下 $\bar{\ell} < \iota$ ，且這是一個確定性數值。此外，請注意 $\gamma^{\bar{\ell}} \in [10V_{\max}^2 \epsilon_{\text{sim}}^2, 40V_{\max}^2 \epsilon_{\text{sim}}^2]$ 且 $\bar{\epsilon}^{\bar{\ell}} \in [\epsilon_{\text{sim}}, 2\epsilon_{\text{sim}}]$ 。根據我們對 π_{exp} 的假設，並對 $\kappa = \frac{\epsilon}{64HV_{\max}}$ 與 $\gamma = \frac{d}{H\epsilon_{\text{sim}}}$ 應用 Lemma B. 4，對於任何 π 與 $\mathcal{Z}' \subseteq \mathcal{S} \times \mathcal{A}$ ，我們得到

$$w_h^{\text{real}, \pi}(\mathcal{Z}') \leq \frac{256dHV_{\max} A^{k^*-2}}{\epsilon \epsilon_{\text{sim}}} \cdot w_h^{\text{real}, \pi_{\text{exp}}}(\mathcal{Z}') + \frac{\epsilon}{16HV_{\max}}$$

對於

$$k^* = \left\lceil \frac{\log_A \frac{64HV_{\max}}{\epsilon}}{\log_A 1/\xi} \right\rceil, \quad \xi = 2\sqrt{\frac{2HA}{\bar{\lambda}_{\min}}} \cdot \epsilon_{\text{sim}}$$

根據 Lemma B.1, 只要 $\beta^{\bar{\ell}}$ 與 $\gamma^{\bar{\ell}}$ 滿足

$$2V_{\max}^2 \epsilon_{\text{sim}}^2 + \frac{43V_{\max}^2 \beta_{\bar{\ell}}^2}{dH} \cdot \log \frac{8H|\mathcal{F}_h|}{\delta} + 6V_{\max}^2 \beta_{\bar{\ell}} \sqrt{\frac{\log \frac{8H|\mathcal{F}_h|}{\delta}}{dH}} \leq \gamma^{\bar{\ell}}$$

我們得出機率至少為 $1 - 2\delta$,

$$V_0^{\text{real}, \pi^{\text{real}, *}} - V_0^{\text{real}, \hat{\pi}^{\bar{\ell}}} \leq \frac{256dHV_{\max} A^{k^*-2}}{\epsilon \epsilon_{\text{sim}}} \cdot 4H \sqrt{\frac{256V_{\max}^2 \log(4H|\tilde{\mathcal{F}}^{\bar{\ell}}|/\delta)}{T^{\bar{\ell}}}} + \epsilon/4$$

其中

$$\tilde{\mathcal{F}}^{\bar{\ell}} := \left\{ f \in \mathcal{F} : \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h))^2 \right] \leq 2\gamma^{\bar{\ell}}, \forall h \in [H] \right\}$$

然而, 由於 $V_{\max}^2 \epsilon_{\text{sim}} \leq \frac{1}{10} \gamma^{\bar{\ell}}$, 且根據我們對 $\beta^{\bar{\ell}} = \frac{\gamma^{\bar{\ell}}}{20V_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}$ 的選擇, 我們可以看到 (B.10) 已達成, 因此結論成立。請注意, 根據 Lemma C.5, 我們得出機率至少為 $1 - \delta$:

$$\begin{aligned} \tilde{\mathcal{F}}^{\bar{\ell}} &\subseteq \left\{ f \in \mathcal{F} : \sup_{\pi} \left(\mathbb{E}^{\text{sim}, \pi} [f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h)] \right)^2 \right. \\ &\leq \left(4 \log \frac{1}{\beta_{\bar{\ell}}} + 6 \right) A \cdot \left[48dH \log \frac{48d}{\beta_{\bar{\ell}}^2} \cdot 2\gamma^{\bar{\ell}} + V_{\max}^2 \sqrt{96dH \log \frac{48d}{\beta_{\bar{\ell}}^2} \log \frac{1}{\delta} \cdot \beta_{\bar{\ell}}} \right] \Big\} \\ &\subseteq \left\{ f \in \mathcal{F} : \sup_{\pi} \left(\mathbb{E}^{\text{sim}, \pi} [f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h)] \right)^2 \right. \\ &\leq c \left(\log \frac{\log \frac{8H|\mathcal{F}|}{\delta}}{V_{\max} \epsilon_{\text{sim}}^2} + 1 \right) AdHV_{\max}^2 \log \frac{48d \log \frac{8H|\mathcal{F}|}{\delta}}{V_{\max} \epsilon_{\text{sim}}^2} \cdot \epsilon_{\text{sim}}^2 \Big\} \\ &=: \tilde{\mathcal{F}} \end{aligned}$$

其中第二個包含關係遵循我們對 $\beta_{\bar{\ell}}$ 的設定, 以及對 $\gamma^{\bar{\ell}}$ 的界限。
由於 $T^{\bar{\ell}} \leftarrow T/2\iota$, 因此若

$$T \geq c \cdot \frac{d^2 H^4 V_{\max}^4 A^{2(k^*-2)} \iota \log(4H|\tilde{\mathcal{F}}|/\delta)}{\epsilon^4 \epsilon_{\text{sim}}^2}$$

則可得出 $V_0^{\text{real}, \pi^{\text{real}, *}} - V_0^{\text{real}, \hat{\pi}^{\bar{\ell}}} \leq \epsilon/2$ 。

情況 2: $\epsilon_{\text{sim}} \leq \epsilon/16H^2$ 。根據 Lemma B.5 以及我們對 $T_{\text{sim}}^{\bar{\ell}}$ 的選擇, 我們有至少 $1 - \delta$ 的機率滿足

$$V_0^{\text{real}, *} - V_0^{\text{real}, \hat{\pi}^{\iota}} \leq 6H \left(2 \log \frac{20V_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}{\gamma^{\iota}} + 3 \right) \cdot \sqrt{192AdH \log \frac{960dV_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}{\gamma^{\iota}} \cdot \gamma^{\iota} + 4H^2 \epsilon_{\text{sim}}}$$

根據我們對 $\iota = \mathcal{O} \left(\log_2 \frac{V_{\max} AdH}{\epsilon} \right)$ 的選擇, 且由於 $\gamma^{\iota} = 10V_{\max}^2 (\bar{\epsilon}^{\iota})^2 = 10V_{\max}^2 \cdot 2^{-2\iota}$, 我們可以對 $V_0^{\text{real}, *} - V_0^{\text{real}, \hat{\pi}^{\iota}} \leq \epsilon/2$ 進行界定 (bound)。

完成證明。在任一情況下, 我們得知機率至少為 $1 - \delta$ 時, 存在某個 $\hat{i} \in [l]$ 使得 $V_0^{\text{real}, *} - V_0^{\text{real}, \hat{\pi}^{\hat{i}}} \leq \epsilon/2$ 。

請注意 $V_0^{\text{real}, \pi} = \mathbb{E}^{\text{real}, \pi} \left[\sum_{h=0}^{H-1} r_h \right]$ 且 $\sum_{h=0}^{H-1} r_h \in [0, H]$ 幾乎確定 (almost surely) 發生。考慮在真實環境中執行 π 共 n 個回合 (episodes), 並令 R^i 表示第 i 個回合的總回報。令

$$\widehat{V}_0^\pi := \frac{1}{n} \sum_{i=1}^n R^i$$

根據 Hoeffding 不等式，我們得知機率至少為 $1 - \delta/\iota$ 時：

$$\left| \widehat{V}_0^\pi - V_0^{\text{real}, \pi} \right| \leq H \sqrt{\frac{\log \frac{2\iota}{\delta}}{n}}$$

因此，如果

$$n \geq \frac{16H^2 \log \frac{2\iota}{\delta}}{\epsilon^2}$$

我們得到 $\left| \widehat{V}_0^\pi - V_0^{\text{real}, \pi} \right| \leq \epsilon/2$ 。然而，由於我們各執行了 $\pi \in \widehat{\Pi}^\ell T_\ell/2 = T/2\iota$ 次，且在任一情況下我們皆假設 $T \geq \frac{c\iota H^2}{\epsilon^2} \cdot \log \frac{4\iota}{\delta}$ ，因此這將會被滿足。對所有 π^ℓ 進行聯集界限（Union bounding）後，我們得到機率至少為 $1 - \delta$ ：

$$V_0^{\text{real}, \widehat{\pi}} \geq \widehat{V}_0^{\widehat{\pi}} - \epsilon/4 \geq \widehat{V}_0^{\widehat{\pi}^i} - \epsilon/4 \geq V_0^{\text{real}, \widehat{\pi}^i} - \epsilon/2$$

由此可知

$$V_0^{\text{real}, \star} - V_0^{\text{real}, \widehat{\pi}} \leq V_0^{\text{real}, \star} - V_0^{\text{real}, \widehat{\pi}^i} + \epsilon/2 \leq \epsilon.$$

結果隨後透過聯集界限與重新縮放 δ 得出。

定理 3 之證明。推導過程與定理 1 的證明類似，但以定理 4 取代定理 2。Oracle 呼叫次數的界限則源自於引理 C.3 以及我們對 β_ℓ 的選擇。

引理 B.5。機率至少為 $1 - \delta$ ，對於某些 ℓ ，我們有

$$\begin{aligned} V_0^{\text{sim}, \star} - V_0^{\text{sim}, \widehat{\pi}^\ell} &\leq 6H \left(2 \log \frac{20V_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}{\gamma^\ell} + 3 \right) \cdot \sqrt{192AdH \log \frac{960dV_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}{\gamma^\ell} \cdot \gamma^\ell}, \\ V_0^{\text{real}, \star} - V_0^{\text{real}, \widehat{\pi}^\ell} &\leq 6H \left(2 \log \frac{20V_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}{\gamma^\ell} + 3 \right) \cdot \sqrt{192AdH \log \frac{960dV_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}{\gamma^\ell} \cdot \gamma^\ell} + 4H^2 \epsilon_{\text{sim}}. \end{aligned}$$

證明。根據引理 C.4，機率至少為 $1 - \delta$ ，我們有

$$\begin{aligned} V_0^{\text{sim}, \star} - V_0^{\text{sim}, \widehat{\pi}^\ell} &\leq 2H \left(2 \log \frac{1}{\beta_\ell} + 3 \right) \cdot \left[\beta_\ell \sqrt{512V_{\max}^2 A \log \frac{8H|\mathcal{F}|}{\delta}} + \sqrt{96AdH \log \frac{48d}{\beta_\ell^2} \cdot \gamma^\ell} \right. \\ &\quad \left. + \sqrt{2AV_{\max}^2 \sqrt{96dH \log \frac{48d}{\beta_\ell^2} \log \frac{2}{\delta}} \cdot \beta_\ell} \right] \\ &\leq 6H \left(2 \log \frac{20V_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}{\gamma^\ell} + 3 \right) \cdot \sqrt{192AdH \log \frac{960dV_{\max}^2 \log \frac{8H|\mathcal{F}|}{\delta}}{\gamma^\ell} \cdot \gamma^\ell} \end{aligned}$$

其中第二個不等式根據我們對 β_ℓ 的設定成立。
我們有

$$V_0^{\text{real}, \star} - V_0^{\text{real}, \widehat{\pi}^t} = V_0^{\text{real}, \star} - V_0^{\text{real}, \pi^{\text{sim}, \star}} + V_0^{\text{real}, \pi^{\text{sim}, \star}} - V_0^{\text{sim}, \pi^{\text{sim}, \star}} + V_0^{\text{sim}, \pi^{\text{sim}, \star}} - V_0^{\text{sim}, \widehat{\pi}^t} + V_0^{\text{sim}, \widehat{\pi}^t} - V_0^{\text{real}, \widehat{\pi}^t}$$

根據引理 A.3，我們可以限制

$$V_0^{\text{real}, \star} - V_0^{\text{real}, \pi^{\text{sim}, \star}} \leq 2H^2 \epsilon_{\text{sim}}$$

且根據引理 A.1，我們可以限制

$$V_0^{\text{real}, \pi^{\text{sim}, \star}} - V_0^{\text{sim}, \pi^{\text{sim}, \star}} \leq H^2 \epsilon_{\text{sim}}, \quad V_0^{\text{sim}, \hat{\pi}^\ell} - V_0^{\text{real}, \hat{\pi}^\ell} \leq H^2 \epsilon_{\text{sim}}$$

將此結果與我們對 $V_0^{\text{sim}, \star} - V_0^{\text{sim}, \hat{\pi}^\ell}$ 的限制結合，即可得出結果。

C 在模擬環境中學習

在本節中，我們為主要結果提供額外的輔助引理，並特別關注 linear in sim。在附錄 C.1 中，我們提供了幾項關鍵的技術性結果，用以證明 sim 可被用於縮減 version space，如定理 4 所示。為了利用 sim 縮減 version space，必須從 sim 中收集足夠豐富的數據，我們在附錄 C.2 中提供了關於此數據收集的結果。最後，在附錄 C.3 中，我們提供了一套在 sim 中計算探索策略 (exploration policies) 的程序，並最終將其轉移至 real。

在附錄 C.1 與 C.2 中，我們將假設 $\tilde{f}$ 與 $\hat{f}$ 遞迴定義為：

$$\tilde{f}_h := \arg \min_{f_h \in \mathcal{F}_h} \frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(f_h(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{r}_h^t - \max_{a'} \hat{f}_{h+1}(\tilde{s}_{h+1}^t, a') \right)^2$$

且 $\hat{f}_h \in \mathcal{F}_h$ 為滿足以下條件的假設：

$$\frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(\hat{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2 \leq \gamma$$

參數為 $\gamma > 0$ 。

在附錄 C.1 中，我們對數據生成過程 (data generating process) 做出以下假設。

假設 5. 考慮數據集 $\mathcal{D}_{\text{sim}} = \{(\tilde{s}_0^t, \tilde{a}_0^t, \tilde{r}_0^t, \dots, \tilde{s}_{H-1}^t, \tilde{a}_{H-1}^t, \tilde{r}_{H-1}^t)\}_{t=1}^{T_{\text{sim}}}$ 。我們假設 $\mathcal{D}_{\text{sim}}$ 中的回合 t 是透過執行一個 $\mathcal{F}_{t-1}$ -可測策略 (measurable policy) $\tilde{\pi}_{\text{exp}}^t$ 所生成的，並記作 $\pi_{\text{exp}}^{\text{sim}} = \text{unif}(\{\tilde{\pi}_{\text{exp}}^t\}_{t=1}^{T_{\text{sim}}})$ 。

我們在附錄 C.2 中提供了 $\pi_{\text{exp}}^{\text{sim}}$ 的具體實例。在附錄 C.3 中，我們提供了一套學習策略集的程序，這些策略能在模擬環境 (sim) 中誘導出滿秩共變量 (full-rank covariates)，這是讓真實環境 (real) 獲得良好探索效能的關鍵要素。

C.1 利用來自模擬環境 (sim) 的數據進行正規化

Lemma C.1. 以至少 $1 - \delta$ 的機率：

$$\frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(\mathcal{T}^{\text{real}} \hat{f}_{h+1}(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2 \leq 2V_{\text{max}}^2 \epsilon_{\text{sim}}^2 + \frac{512V_{\text{max}}^2}{T_{\text{sim}}} \cdot \log \frac{4|\mathcal{F}_h|}{\delta} + V_{\text{max}}^2 \sqrt{\frac{2 \log \frac{2|\mathcal{F}_h|}{\delta}}{T_{\text{sim}}}}$$

證明。首先，根據 Assumption 4，請注意 $\mathcal{T}^{\text{real}} \hat{f}_{h+1} \in \mathcal{F}_h$ 。

根據 Azuma-Hoeffding 不等式與聯集界限 (union bound)，我們得出以至少 $1 - \delta$ 的機率，對於每個 $f, f' \in \mathcal{F}_h$ ：

$$\begin{aligned} \frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} (f_h(\tilde{s}_h^t, \tilde{a}_h^t) - f'_h(\tilde{s}_h^t, \tilde{a}_h^t))^2 &\leq \frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\text{sim}, \tilde{\pi}_{\text{exp}}^t} \left[(f_h(\tilde{s}_h, \tilde{a}_h) - f'_h(\tilde{s}_h, \tilde{a}_h))^2 \right] + V_{\text{max}}^2 \sqrt{\frac{2 \log |\mathcal{F}_h| / \delta}{T_{\text{sim}}}} \\ &= \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[(f_h(s_h, a_h) - f'_h(s_h, a_h))^2 \right] + V_{\text{max}}^2 \sqrt{\frac{2 \log |\mathcal{F}_h| / \delta}{T_{\text{sim}}}} \end{aligned}$$

特別地，這意味著

$$\frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(\mathcal{T}^{\text{real}} \hat{f}_{h+1}(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2 \leq \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\mathcal{T}^{\text{real}} \hat{f}_{h+1}(s_h, a_h) - \tilde{f}_h(s_h, a_h) \right)^2 \right] + V_{\text{max}}^2 \sqrt{\frac{2 \log |\mathcal{F}_h| / \delta}{T_{\text{sim}}}}$$

我們可以界定

$$\begin{aligned} \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\mathcal{T}^{\text{real}} \hat{f}_{h+1}(s_h, a_h) - \tilde{f}_h(s_h, a_h) \right)^2 \right] &\leq \underbrace{2 \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\mathcal{T}^{\text{real}} \hat{f}_{h+1}(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right]}_{(a)} \\ &\quad + \underbrace{2 \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) - \tilde{f}_h(s_h, a_h) \right)^2 \right]}_{(b)} \end{aligned}$$

為了界定 (a) 的範圍，我們注意到

$$\begin{aligned} \mathcal{T}^{\text{real}} \hat{f}_{h+1}(s_h, a_h) - \tilde{f}_h(s_h, a_h) &= \mathbb{E}^{\text{real}} \left[\max_{a'} \hat{f}_{h+1}(s', a') \mid s, a \right] - \mathbb{E}^{\text{sim}} \left[\max_{a'} \hat{f}_{h+1}(s', a') \mid s, a \right] \\ &= \sum_{s'} (P_h^{\text{real}}(s' \mid s, a) - P_h^{\text{sim}}(s' \mid s, a)) \cdot \max_{a'} \hat{f}_{h+1}(s', a') \\ &\leq V_{\max} \cdot \sum_{s'} |P_h^{\text{real}}(s' \mid s, a) - P_h^{\text{sim}}(s' \mid s, a)| \\ &\leq V_{\max} \epsilon_{\text{sim}} \end{aligned}$$

其中最後一個不等式遵循假設 1。這得出 (a) $\leq 2V_{\max}^2 \epsilon_{\text{sim}}^2$ 。為了界定 (b) 的範圍，我們應用 Song et al. (2022) 的 Lemma 3，得出在機率至少為 $1 - \delta$ 的情況下，

$$(b) \leq \frac{512V_{\max}^2}{T_{\text{sim}}} \cdot \log \frac{4|\mathcal{F}_h|}{\delta}$$

將這些結果與聯集界限 (union bound) 結合，即可得出結果。
Lemma C.2. 考慮集合

$$\hat{\mathcal{F}}_h := \left\{ f_h \in \mathcal{F}_h : \frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(f_h(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2 \leq \gamma \right\}$$

則以機率 $1 - 2\delta$ ，我們得到

$$\hat{\mathcal{F}}_h \subseteq \left\{ f_h \in \mathcal{F}_h : \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \leq \gamma + 18V_{\max}^2 \sqrt{\frac{\log \frac{4|\mathcal{F}_h|}{\delta}}{T_{\text{sim}}}} \right\}$$

證明。根據 Azuma-Hoeffding 不等式，我們得到至少有 $1 - \delta$ 的機率，對於每個 $f_h, f'_h \in \mathcal{F}_h$ ，

$$\mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - f'_h(s_h, a_h) \right)^2 \right] - V_{\max}^2 \sqrt{\frac{2 \log |\mathcal{F}_h| / \delta}{T_{\text{sim}}}} \leq \frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(f_h(\tilde{s}_h^t, \tilde{a}_h^t) - f'_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2$$

這特別意味著，對於任何 $f_h \in \mathcal{F}_h$ ，

$$\mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \tilde{f}_h(s_h, a_h) \right)^2 \right] - V_{\max}^2 \sqrt{\frac{2 \log |\mathcal{F}_h| / \delta}{T_{\text{sim}}}} \leq \frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(f_h(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2.$$

我們可以寫成

$$\begin{aligned} &\mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \tilde{f}_h(s_h, a_h) \right)^2 \right] \\ &= \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] + \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\tilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \\ &\quad - 2 \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\tilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right) \left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right) \right] \\ &\geq \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \\ &\quad - 2 \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\tilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right) \left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right) \right] \end{aligned}$$

根據 Song 等人 (2022) 的 Lemma 3，機率至少為 $1 - \delta$ ，

$$\mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\tilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \leq \frac{256V_{\max}^2}{T_{\text{sim}}} \cdot \log \frac{2|\mathcal{F}_h|}{\delta}$$

因此，我們可以將最後一項限制為

$$\begin{aligned}
& \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\tilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right) \left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right) \right] \\
& \leq V_{\max} \cdot \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left| \tilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right| \right] \\
& \leq V_{\max} \cdot \sqrt{\mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(\tilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right]} \\
& \leq V_{\max} \cdot \sqrt{\frac{256V_{\max}^2}{T_{\text{sim}}} \cdot \log \frac{2|\mathcal{F}_h|}{\delta}}.
\end{aligned}$$

綜上所述，我們已經證明對於任何 $f_h \in \mathcal{F}_h$ ，機率至少為 $1 - 2\delta$ ：

$$\frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(f_h(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2 \geq \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] - 18V_{\max}^2 \sqrt{\frac{\log 2|\mathcal{F}_h|/\delta}{T_{\text{sim}}}}$$

因此，如果

$$\frac{1}{T_{\text{sim}}} \sum_{t=1}^{T_{\text{sim}}} \left(f_h(\tilde{s}_h^t, \tilde{a}_h^t) - \tilde{f}_h(\tilde{s}_h^t, \tilde{a}_h^t) \right)^2 \leq \gamma,$$

接著

$$\mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \right] \leq \gamma + 18V_{\max}^2 \sqrt{\frac{\log 2|\mathcal{F}_h|/\delta}{T_{\text{sim}}}}$$

結果由聯集界限（union bound）推導而得。

C. 2 使用 CoverTraj 進行資料收集

引理 C.3. 考慮針對每個 $h \in [H]$ 執行 Wagenmaker et al. (2022) 的 CoverTraj 演算法，其參數為 $m \leftarrow \lceil \log_2 1/\beta \rceil$ 與 $\gamma_i \leftarrow 2^i \cdot \beta$ （其中 $\beta \in [0, 1]$ ），並將 RegMin 設定為 Oracle 4.2 的策略最佳化 oracle。則此程序所收集的

$$T_{\text{sim}} := H \cdot \sum_{i=1}^m \left\lceil \frac{24d}{2^i \cdot \beta^2} \log \frac{48d}{2^i \cdot \beta^2} \right\rceil$$

回合，呼叫策略最佳化 Oracle（policy optimization oracle）最多 T_{sim} 次，並產生共變量 $\Lambda_{h,i}$ 與集合 $\mathcal{X}_{h,i}$ ，使得對於每個 $i \in [m]$ ，

$$\sup_{\pi} w_h^{\text{sim}, \pi}(\mathcal{X}_{h,i}) \leq 2^{-i+1} \quad \text{and} \quad \phi^\top \Lambda_{h,i}^{-1} \phi \leq 2^{2i} \cdot \beta^2, \forall \phi \in \mathcal{X}_{h,i}$$

且 $\sup_{\pi} w_h^{\text{sim}, \pi}(\mathcal{B}^d \setminus \cup_{i=1}^m \mathcal{X}_{h,i}) \leq \beta$ 。此外，我們得到

$$\frac{12dH}{\beta^2} \leq T_{\text{sim}} \leq \frac{48dH}{\beta^2} \log \frac{48d}{\beta^2}$$

證明。將 RegMin 以 Oracle 4.2 的 Oracle 實例化，我們得到 Wagenmaker et al. (2022) 的定義 5.1 在 $\mathcal{C}_1 = \mathcal{C}_2 = 0$ 的情況下成立。因此，我們在每個階段 i 收集到精確的（使用 Wagenmaker et al. (2022) 附錄中給出的 K_i 精確形式）

$$K_i = \left\lceil 2^i \cdot \frac{24d}{\gamma_i^2} \log \frac{48 \cdot 2^i d}{\gamma_i^2} \right\rceil$$

回合。結果隨後由 Wagenmaker et al. (2022) 的定理 3 得出。

引理 C.4. 考慮執行引理 C.3 的程序來收集數據。則至少有 $1 - 2\delta$ 的機率，我們得到

$$V_0^{\text{sim},\star} - V_0^{\text{sim},\pi^{\hat{f}}} \leq 2H \left(2 \log \frac{1}{\beta} + 3 \right) \cdot \left[\beta \sqrt{512V_{\max}^2 A \log(4H|\mathcal{F}|/\delta)} + \sqrt{96AdH \log \frac{48d}{\beta^2}} \cdot \gamma \right. \\ \left. + \sqrt{2AV_{\max}^2 \sqrt{96dH \log \frac{48d}{\beta^2}} \log \frac{1}{\delta}} \cdot \beta \right]$$

證明。根據引理 A.4：

$$V_0^{\text{sim},\star} - V_0^{\text{sim},\pi^{\hat{f}}} \leq \max_{\pi \in \{\pi^{\hat{f}}, \pi^{\text{sim},\star}\}} \sum_{h=0}^{H-1} 2 \left| \mathbb{E}^{\text{sim},\pi} \left[\hat{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right] \right| \\ \leq \max_{\pi \in \{\pi^{\hat{f}}, \pi^{\text{sim},\star}\}} \sum_{h=0}^{H-1} 2 \mathbb{E}^{\text{sim},\pi} \left[\left| \hat{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right| \right]$$

令 $g(z_h) := \left| \hat{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right|$ 且 $\mathbf{\Lambda}_{h-1} = \sum_{i=1}^m \mathbf{\Lambda}_{h,i} + I$ ，對於依據引理 C.3 所收集的 $\mathbf{\Lambda}_{h,i}$ ，並注意

$$\mathbb{E}^{\text{sim},\pi} [g(z_h)] = \mathbb{E}^{\text{sim},\pi} \left[\int g(z) dP_h^\pi(z \mid z_{h-1}) \right] \\ = \mathbb{E}^{\text{sim},\pi} \left[\iint g(z) \pi(a \mid s) da \, d\boldsymbol{\mu}_{h-1}^s(s)^\top \boldsymbol{\phi}^s(z_{h-1}) \right] \\ = \mathbb{E}^{\text{sim},\pi} \left[\iint g(z) \pi(a \mid s) da \, d\boldsymbol{\mu}_{h-1}^s(s)^\top \mathbf{\Lambda}_{h-1}^{1/2} \mathbf{\Lambda}_{h-1}^{-1/2} \boldsymbol{\phi}^s(z_{h-1}) \right] \\ \leq \mathbb{E}^{\text{sim},\pi} \left[\left\| \int g(z) \pi(a \mid s) da \, d\boldsymbol{\mu}_{h-1}^s(s) \right\|_{\mathbf{\Lambda}_{h-1}} \cdot \|\boldsymbol{\phi}^s(z_{h-1})\|_{\mathbf{\Lambda}_{h-1}^{-1}} \right] \\ = \left\| \iint g(z) \pi(a \mid s) da \, d\boldsymbol{\mu}_{h-1}^s(s) \right\|_{\mathbf{\Lambda}_{h-1}} \cdot \mathbb{E}^{\text{sim},\pi} \left[\|\boldsymbol{\phi}^s(z_{h-1})\|_{\mathbf{\Lambda}_{h-1}^{-1}} \right]$$

我們分別對這些項進行界定 (bound)。首先，我們得到

$$\mathbb{E}^{\text{sim},\pi} \left[\|\boldsymbol{\phi}^s(z_{h-1})\|_{\mathbf{\Lambda}_{h-1}^{-1}} \right] \leq \sum_{i=1}^m \max_{\phi \in \mathcal{X}_{h-1,i}} \|\phi\|_{\mathbf{\Lambda}_{h-1}^{-1}} \cdot \sup_{\pi} \mathbb{E}^{\text{sim},\pi} [\mathbb{I} \{ \boldsymbol{\phi}^s(z_{h-1}) \in \mathcal{X}_{h-1,i} \}] \\ + \max_{\phi \in \mathcal{B}^d \setminus \bigcup_{i=1}^m \mathcal{X}_{h-1,i}} \|\phi\|_{\mathbf{\Lambda}_{h-1}^{-1}} \cdot \sup_{\pi} \mathbb{E}^{\text{sim},\pi} [\mathbb{I} \{ \boldsymbol{\phi}^s(z_{h-1}) \in \mathcal{X}_{h-1,i} \}] \\ \stackrel{(a)}{\leq} \sum_{i=1}^{\ell} \gamma_i \cdot 2^{-i+1} + \beta \\ \leq (2m+1)\beta$$

其中 (a) 遵循引理 C.3，且由於 $\|\boldsymbol{\phi}\|_{\mathbf{\Lambda}_{h-1}^{-1}} \leq 1$ 始終成立。現在我們轉而限制第一項的範圍。請注意

$$\left\| \iint g(z) \pi(a \mid s) da \, d\boldsymbol{\mu}_{h-1}^s(s) \right\|_{\mathbf{\Lambda}_{h-1}} \\ = \sqrt{\sum_{t=1}^{T_{\text{sim}}} \left(\iint g(z) \pi(a \mid s) da \, d\boldsymbol{\mu}_{h-1}^s(s)^\top \boldsymbol{\phi}_{h-1}^t \right)^2}$$

$$\begin{aligned}
&= \sqrt{\sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi} [g(z_h) \mid z_{h-1}^t]^2} \\
&\leq \sqrt{\sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi} [g(z_h)^2 \mid z_{h-1}^t]} \\
&\stackrel{(a)}{\leq} \sqrt{A \cdot \sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi_{\text{exp}}^{h-1,t}} [g(z_h)^2 \mid z_{h-1}^t]} \\
&= \sqrt{A \cdot \sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi_{\text{exp}}^{h-1,t}} \left[\left(\widehat{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \widehat{f}_{h+1}(s_h, a_h) \right)^2 \mid z_{h-1}^t \right]} \\
&\leq \sqrt{2A \cdot \sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi_{\text{exp}}^{h-1,t}} \left[\left(\widetilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \widehat{f}_{h+1}(s_h, a_h) \right)^2 \mid z_{h-1}^t \right] + 2A \cdot \sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi_{\text{exp}}^{h-1,t}} \left[\left(\widetilde{f}_h(s_h, a_h) - \widehat{f}_h(s_h, a_h) \right)^2 \mid z_{h-1}^t \right]} \\
&\leq \sqrt{512V_{\text{max}}^2 A \log(4H|\mathcal{F}|/\delta) + 2A \cdot \sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi_{\text{exp}}^{h-1,t}} \left[\left(\widetilde{f}_h(s_h, a_h) - \widehat{f}_h(s_h, a_h) \right)^2 \mid z_{h-1}^t \right]}
\end{aligned}$$

其中 (a) 使用了 $\pi_{\text{exp}}^{h-1,t}$ 在步驟 h 隨機執行動作的事實，而根據引理 C.6, (b) 以至少 $1 - \delta$ 的機率成立。根據 Azuma-Hoeffding 不等式，我們得到機率為 $1 - \delta$ ：

$$\begin{aligned}
\sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi_{\text{exp}}^{h-1,t}} \left[\left(\widetilde{f}_h(s_h, a_h) - \widehat{f}_h(s_h, a_h) \right)^2 \mid z_{h-1}^t \right] &\leq \sum_{t=1}^{T_{\text{sim}}} \left(\widetilde{f}_h(s_h^t, a_h^t) - \widehat{f}_h(s_h^t, a_h^t) \right)^2 + \sqrt{2V_{\text{max}}^4 T_{\text{sim}} \log 1/\delta} \\
&\leq T_{\text{sim}} \gamma + \sqrt{2V_{\text{max}}^4 T_{\text{sim}} \log 1/\delta}
\end{aligned}$$

其中最後一個不等式遵循 $\widehat{f}_h$ 的定義。
總結來說，我們已經證明，機率至少為 $1 - 2\delta$ ：

$$V_0^{\text{sim},*} - V_0^{\text{sim},\pi^{\widehat{f}}} \leq 2H(2m+1)\beta \cdot \sqrt{512V_{\text{max}}^2 A \log(4H|\mathcal{F}|/\delta) + 2AT_{\text{sim}}\gamma + 2AV_{\text{max}}^2 \sqrt{2T_{\text{sim}} \log 1/\delta}}$$

使用引理 C.3 中給出的 $T_{\text{sim}} \leq \frac{48dH}{\beta^2} \log \frac{48d}{\beta^2}$ ，我們可以將其限制為

$$\begin{aligned}
&\leq 2H(2m+1) \left[\beta \sqrt{512V_{\text{max}}^2 A \log(4H|\mathcal{F}|/\delta)} + \sqrt{96AdH \log \frac{48d}{\beta^2}} \cdot \gamma \right. \\
&\quad \left. + \sqrt{2AV_{\text{max}}^2 \sqrt{96dH \log \frac{48d}{\beta^2} \log \frac{1}{\delta}}} \cdot \beta \right]
\end{aligned}$$

結果隨之而來。
引理 C.5。假設

$$\mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[\left(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h) \right)^2 \right] \leq \gamma$$

這意味著，機率至少為 $1 - \delta$ ，

$$\begin{aligned}
&\sup_{\pi} \left(\mathbb{E}^{\text{sim}, \pi} [f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h)] \right)^2 \\
&\leq \left(4 \log \frac{1}{\beta} + 6 \right) A \cdot \left[48d \log \frac{48d}{\beta^2} \cdot \gamma + V_{\text{max}} \sqrt{96d \log \frac{48d}{\beta^2} \log \frac{1}{\delta}} \cdot \beta \right].
\end{aligned}$$

因此，

$$\begin{aligned}
& \left\{ f \in \mathcal{F} : \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{\text{sim}}} \left[(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h))^2 \right] \leq \gamma \right\} \\
& \subseteq \left\{ f \in \mathcal{F} : \sup_{\pi} \left(\mathbb{E}^{\text{sim}, \pi} [f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h)] \right)^2 \right. \\
& \quad \left. \leq \left(4 \log \frac{1}{\beta} + 6 \right) A \cdot \left[48dH \log \frac{48d}{\beta^2} \cdot \gamma + V_{\max}^2 \sqrt{96dH \log \frac{48d}{\beta^2} \log \frac{1}{\delta} \cdot \beta} \right] \right\}
\end{aligned}$$

證明。我們遵循與 Lemma C.4 證明類似的論證。令 $g(z_h) := f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h)$ ，透過與 (C.1) 相同的計算，我們得到

$$\mathbb{E}^{\text{sim}, \pi} [g(z_h)] \leq \left\| \iint g(z) \pi(a | s) da \, d\mu_{h-1}^s(s) \right\|_{\Lambda_{h-1}} \cdot \mathbb{E}^{\text{sim}, \pi} [\|\phi^s(z_{h-1})\|_{\Lambda_{h-1}^{-1}}]$$

且如同 Lemma C.4 的證明，我們可以限制

$$\mathbb{E}^{\text{sim}, \pi} [\|\phi^s(z_{h-1})\|_{\Lambda_{h-1}^{-1}}] \leq (2m+1)\beta$$

與

$$\left\| \iint g(z) \pi(a | s) da \, d\mu_{h-1}^s(s) \right\|_{\Lambda_{h-1}} \leq \sqrt{A \cdot \sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi_{\text{exp}}^{h-1,t}} \left[(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h))^2 \mid z_{h-1}^t \right]}$$

根據 Azuma-Hoeffding 不等式，我們能以至少 $1 - \delta$ 的機率得出以下界限

$$\begin{aligned}
\sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\pi_{\text{exp}}^{h-1,t}} \left[(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h))^2 \mid z_{h-1}^t \right] & \leq T_{\text{sim}} \cdot \mathbb{E}^{\pi_{\text{exp}}^{\text{sim}}} \left[(f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h))^2 \right] \\
& + \sqrt{2V_{\max}^4 T_{\text{sim}} \log 1/\delta} \\
& \leq T_{\text{sim}} \gamma + \sqrt{2V_{\max}^4 T_{\text{sim}} \log 1/\delta}
\end{aligned}$$

其中最後一個不等式由假設得出，且 $\pi_{\text{exp}}^{\text{sim}} = \text{unif} \left(\left\{ \pi_{\text{exp}}^{h-1,t} \right\}_{t=1}^{T_{\text{sim}}} \right)$ 。綜上所述，對於所有的 π ，我們得到

$$\mathbb{E}^{\text{sim}, \pi} [f_h(s_h, a_h) - \mathcal{T}^{\text{sim}} f_{h+1}(s_h, a_h)] \leq (2m+1)\beta \cdot \sqrt{AT_{\text{sim}}\gamma + AV_{\max}^2 \sqrt{2T_{\text{sim}} \log 1/\delta}}$$

使用引理 C.3 中給出的 $T_{\text{sim}} \leq \frac{48dH}{\beta^2} \log \frac{48d}{\beta^2}$ ，我們可以將其限制為

$$\leq (2m+1) \sqrt{48AdH \log \frac{48d}{\beta^2} \cdot \gamma} + (2m+1) \sqrt{AV_{\max}^2 \sqrt{96dH \log \frac{48d}{\beta^2} \log \frac{1}{\delta} \cdot \beta}}$$

此結果可由代數運算得出。

引理 C.6。至少有 $1 - \delta$ 的機率，對於每個同時存在的 $h \in [H]$ ，我們得到

$$\sum_{t=1}^{T_{\text{sim}}} \mathbb{E}^{\text{sim}, \pi_{\text{exp}}^{h-1,t}} \left[\left(\tilde{f}_h(s_h, a_h) - \mathcal{T}^{\text{sim}} \hat{f}_{h+1}(s_h, a_h) \right)^2 \mid s_{h-1}^t, a_{h-1}^t \right] \leq 256V_{\max}^2 \log(4H|\mathcal{F}|/\delta)$$

證明。此結果源自 Song 等人 (2022) 的引理 3。

C. 3 學習滿秩策略 (Full-Rank Policies)

Algorithm 5 Learn Exploration Policies in $\mathcal{M}^{\text{sim}}$ (LearnExp) 
input: environment $\mathcal{M}$, confidence δ , regularization ζ
 $\mathbb{A}_R \rightarrow$ policy optimization oracle of Oracle 4.2

```

for \ (j=1,2,3, \ldots, \mathcal{O}\left(\log _2\left(\frac{d}{\zeta}\right) \cdot \log \left(N_{j}\right) \rightarrow \left\lceil 2^{j / 3}\right\rceil-1, K_{j}\right) \rightarrow \left\lceil 2^{j / 3}\right\rceil-1, K_{j}\right)
// DynamicOED algorithm from Wagenmaker et al. (2023)
\ (\boldsymbol{\Sigma}_{j}, \Pi_{j}) \rightarrow \operatorname{DynamicOED}\left(\mathcal{M}_{j}, \mathcal{A}_{j}, \mathcal{R}_{j}, \mathcal{O}_{j}\right)
if \ (\lambda_{\min }\left(\boldsymbol{\Sigma}_{j}\right) \geq 12544 d \log \frac{d}{\zeta})
    break
return \ (\Pi_{j})

```

我們考慮在模擬環境中執行 Wagenmaker et al. (2023) 的 MinEig 演算法 (Algorithm 6)。對於固定的 h ，我們以 $\psi(\tau) = \phi(s_h, a_h)\phi(s_h, a_h)^\top$, $D = 1$ 實例化 Wagenmaker et al. (2023) 附錄 C 的設定，並將 $\mathbb{A}_{\mathcal{R}}$ 設為 Oracle 4.2 的策略最佳化 oracle (因此 $C_{\mathcal{R}} = 0$)，且為 MinEig 設定 $N = 1$ 。我們注意到，在給定策略最佳化 oracle 的情況下，此演算法在計算上是有效率的。

Lemma C.7. 對於 $\mathcal{M} \leftarrow \mathcal{M}^{\text{sim}}$ ，Algorithm 5 將呼叫 Oracle 4.2 至多 $\tilde{\mathcal{O}}\left(\frac{d}{\zeta} \cdot \log \frac{1}{\delta} + \zeta^{-9} \cdot \log^{3/2} \frac{1}{\delta}\right)$ 次，且在假設 3 成立以及若 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$ 的情況下，至少有 $1 - \delta$ 的機率會回傳策略 Π ，使得

$$\lambda_{\min} \left(\frac{1}{|\Pi|} \sum_{\pi \in \Pi} \Lambda_{\pi, h}^s \right) \geq \frac{\lambda_{\min}^*}{8d}$$

且每個 $\pi \in \Pi$ 會隨機執行動作持續 $h' > h$ 。

證明。我們首先論證，若 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$ ，則至少有 $1 - \delta$ 的機率使 (C.2) 成立。令 $\mathcal{E}$ 表示每次呼叫 DynamicOED 的成功事件，並注意根據我們對 δ_j 的選擇，我們有 $\mathbb{P}[\mathcal{E}] \geq 1 - \delta/2$ 。令 j^* 表示使 j 成立的最小值，使得

$$\frac{\lambda_{\min}^*}{4d} T_j \geq 12544d \log \frac{4 + 64T_j}{\delta} \quad \text{and} \quad T_j \geq c \cdot \zeta^{-9} \cdot \log^{3/2} \frac{jT_j}{\delta}.$$

根據 Wagenmaker 等人 (2023) 的 Lemma C. 4，且若 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$ ，則在 $\mathcal{E}$, $\lambda_{\min}(\Sigma_{j^*}) \geq \frac{\lambda_{\min}^*}{4d} T_{j^*}$ 上，我們可得出 Algorithm 5 的終止條件將被滿足。根據 Wagenmaker 等人 (2023) 的 Lemma C. 5，可推導出以至少 $1 - \delta/2$ 的機率，我們得到 $\lambda_{\min} \left(\frac{1}{|\Pi_{j^*}|} \sum_{\pi \in \Pi_{j^*}} \Lambda_{\pi, h}^s \right) \geq \frac{\lambda_{\min}^*}{8d}$ (由於 $T_{j^*} = |\Pi_{j^*}|$)，即為所需的結論。

假設 Algorithm 5 在某些 $j < j^*$ 的情況下終止。這意味著 $\frac{\lambda_{\min}^*}{4d} T_j < 12544d \log \frac{4 + 64T_j}{\delta}$ 。然而，在這種情況下，我們接著會得到

$$\lambda_{\min}(\Sigma_j) \geq 12544d \log \frac{4 + 64T_j}{\delta} \geq \frac{\lambda_{\min}^*}{4d} T_j.$$

根據 Wagenmaker 等人 (2023) 的引理 C. 5，在機率至少為 $1 - \delta/2$ 的情況下，可得出

$$\lambda_{\min} \left(\frac{1}{|\Pi_j|} \sum_{\pi \in \Pi_j} \Lambda_{\pi, h}^s \right) \geq \frac{\lambda_{\min}^*}{8d}.$$

由此可知，假設 T_j 足夠大以滿足 (C.3)，且在 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$ 成立的情況下，Algorithm 5 將會終止並回傳一組滿足 (C.2) 的策略集，其機率至少為 $1 - \delta$ 。請注意 $T_j = \mathcal{O}(2^j)$ 。鑑於 Algorithm 5 直到 $j = \mathcal{O}\left(\log_2 \left(\frac{d}{\zeta} \cdot \log \frac{1}{\delta} + \zeta^{-9} \cdot \log^{3/2} \frac{1}{\delta}\right)\right) \geq \mathcal{O}\left(\log_2 \left(\frac{d^2}{\lambda_{\min}^*} \cdot \log \frac{1}{\delta} + \zeta^{-9} \cdot \log^{3/2} \frac{1}{\delta}\right)\right)$ 才會終止，若 $\zeta \leq \frac{\lambda_{\min}^*}{4d}$ ，則 T_j 將足夠大以滿足 (C.3)。由於 DYNAMICOED 在第 j 輪最多呼叫 Oracle 4.2 共 T_j 次，且 T_j 的總和受限於 j 的最大值 (如 $\tilde{\mathcal{O}}\left(\frac{d}{\zeta} \cdot \log \frac{1}{\delta} + \zeta^{-9} \cdot \log^{3/2} \frac{1}{\delta}\right)$ 所示)，再加上 $\pi \in \Pi$ 為 $h' > h$ 選擇的動作與 DynamicOED 的運作無關，因此可以將其設定為隨機，證明隨之完成。

D 下界證明

D.1 命題 1、3 與 4 之證明

建構。考慮以下組合鎖 (combination lock) 的變體。我們令動作空間為 $\mathcal{A} = \{1, 2\}$ ，並假設有兩個狀態 $\mathcal{S} = \{s_1, s_2\}$ ，以及時界 (horizon) H 。我們從狀態 s_1 開始。Sim 動態定義如下：

$$\begin{aligned} \forall h < H-1: \quad & P_h^{\text{sim}}(s_1 | s_1, a_1) = 1, \quad P_h^{\text{sim}}(s_2 | s_1, a_2) = 1 \\ & P_{H-1}^{\text{sim}}(s_1 | s_1, a_1) = P_{H-1}^{\text{sim}}(s_2 | s_1, a_1) = P_{H-1}^{\text{sim}}(s_1 | s_1, a_2) = P_{H-1}^{\text{sim}}(s_2 | s_1, a_2) = 1/2 \\ \forall h \in [H]: \quad & P_h^{\text{sim}}(s_2 | s_2, a) = 1, a \in \{a_1, a_2\} \end{aligned}$$

我們定義兩個 Real 實例 $\mathcal{M}_1 := \mathcal{M}^{\text{real}, 1}$ 與 $\mathcal{M}_2 := \mathcal{M}^{\text{real}, 2}$ ，兩者皆具備：

$$\begin{aligned} \forall h < H-1: \quad & P_h^{\text{real}}(s_1 | s_1, a_1) = 1, \quad P_h^{\text{real}}(s_2 | s_1, a_2) = 1 \\ \forall h \in [H]: \quad & P_h^{\text{real}}(s_2 | s_2, a) = 1, a \in \{a_1, a_2\} \end{aligned}$$

針對 $\mathcal{M}_1$ ：

$$\begin{aligned} P_{H-1}^{\text{real}}(s_1 | s_1, a_1) &= 1/2 + \epsilon_{\text{sim}}, P_{H-1}^{\text{real}}(s_2 | s_1, a_1) = 1/2 - \epsilon_{\text{sim}}, \\ P_{H-1}^{\text{real}}(s_1 | s_1, a_2) &= 1/2 - \epsilon_{\text{sim}}, P_{H-1}^{\text{real}}(s_2 | s_1, a_2) = 1/2 + \epsilon_{\text{sim}}, \end{aligned}$$

以及針對 $\mathcal{M}_2$ ：

$$\begin{aligned} P_{H-1}^{\text{real}}(s_1 | s_1, a_1) &= 1/2 - \epsilon_{\text{sim}}, P_{H-1}^{\text{real}}(s_2 | s_1, a_1) = 1/2 + \epsilon_{\text{sim}}, \\ P_{H-1}^{\text{real}}(s_1 | s_1, a_2) &= 1/2 + \epsilon_{\text{sim}}, P_{H-1}^{\text{real}}(s_2 | s_1, a_2) = 1/2 - \epsilon_{\text{sim}}. \end{aligned}$$

請注意， $\mathcal{M}_1, \mathcal{M}_2$ 與 sim 僅在狀態 s_1 的步驟 $H-1$ 有所不同。此外，顯而易見的是 $\mathcal{M}_1$ 與 $\mathcal{M}_2$ 皆符合假設 1，其模型误差 (misspecification) 為 ϵ_{sim} 。由於這是一個表格型 MDP (tabular MDP)，顯而易見地假設 2 在 $d=4$ 的情況下同樣成立，且假設 3 在 $\lambda_{\min}^* = 1/4$ 的情況下亦成立。我們將獎勵函數 (reward function) 定義如下（請注意，此函數為確定性的，且對所有實例皆相同）：

$$\begin{aligned} \forall h \in [H]: \quad & r_h(s_1, a_2) = 1/2 + \epsilon_{\text{sim}}(1/2 - h/4H) \\ & r_H(s_1, a) = 1, a \in \{a_1, a_2\} \end{aligned}$$

其餘所有獎勵皆視為 0。

在模擬 (sim) 中，我們觀察到最佳策略 (optimal policy) 總是執行 a_2 。在 $\mathcal{M}_1$ 與 $\mathcal{M}_2$ 中，最佳策略對於所有 $h < H-1$ 都執行 a_1 ；對於 $\mathcal{M}_1$ ，在 $H-1$ 時執行 a_1 ；而對於 $\mathcal{M}_2$ ，則在 $H-1$ 時執行 a_2 。請注意，對於 $\mathcal{M}_1$ 與 $\mathcal{M}_2$ ，我們皆得到 $V_0^* = 1/2 + \epsilon_{\text{sim}}$ 。

對於 $\mathcal{F}$ 最自然的選擇應是所有表格化 Q -value 函數的集合，然而，此集合為無限集，需要涵蓋論證 (covering argument) 才能納入。為求簡化，考慮 $\mathcal{F}_H$ 為映射至 $\{0, 1\}$ 的函數集合，而 $\mathcal{F}_h$ 為映射至包含 $\{0, 1/2 - \epsilon_{\text{sim}}, 1/2 + \epsilon_{\text{sim}}\} \cup \{1/2 + \epsilon_{\text{sim}}(1/2 - h'/4H)\}_{h'=0}^H$ 之有限集的函數集合。注意此類集合符合 Assumption 4，且我們可以將其建構為滿足 $\log |\mathcal{F}| \leq \mathcal{O}(H)$ 。

直接策略轉移 (Direct Policy Transfer) 的下界 (Proposition 3)。我們考慮帶有隨機探索的直接 sim2real 轉移。特別是如前所述，模擬中的最佳策略總是執行 a_2 ，因此我們考慮 ζ -greedy 策略，該策略在每個狀態下以機率 $1 - \zeta$ 執行 a_2 ，並以機率 ζ 執行 $\text{unif}(\{a_1, a_2\})$ 。將此策略表示為 $\hat{\pi}$ 。接著我們希望求得以下項的下界：

$$\inf_{\hat{\pi}} \sup_{i \in \{1, 2\}} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}} [V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}}]$$

在執行我們的程序 T 個回合 (episodes) 後。注意在 $\mathcal{M}_1$ 上，無論 $\hat{\pi}$ 在其他狀態中選擇何種動作，我們皆有

$$V_0^{\mathcal{M}_1, \star} - V_0^{\mathcal{M}_1, \hat{\pi}} \geq \frac{\epsilon_{\text{sim}}}{2} (1 - \hat{\pi}_{H-1}(a_1 | s_1))$$

由於 $\hat{\pi}$ 唯一能獲得獎勵 $1/2 + \epsilon_{\text{sim}}$ 的方式是在第 $H-1$ 步於 s_1 執行 a_1 ，且所有其他動作序列最多只能獲得獎勵 $1/2 + \epsilon_{\text{sim}}/2$ 。對於 $\mathcal{M}_2$ 也是同理，我們得到

$$V_0^{\mathcal{M}_2, \star} - V_0^{\mathcal{M}_2, \hat{\pi}} \geq \frac{\epsilon_{\text{sim}}}{2} (1 - \hat{\pi}_{H-1}(a_2 | s_1))$$

利用這一點，並將對 $i \in \{1, 2\}$ 取最大值替換為其平均值，我們得到

$$\begin{aligned} \inf_{\hat{\pi}} \sup_{i \in \{1, 2\}} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}} \left[V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}^2} \right] &\geq \inf_{\hat{\pi}} \frac{1}{2} \mathbb{E}^{\mathcal{M}_1, \hat{\pi}} \left[\frac{\epsilon_{\text{sim}}}{2} (1 - \hat{\pi}_{H-1}(a_1 | s_1)) \right] + \frac{1}{2} \mathbb{E}^{\mathcal{M}_2, \hat{\pi}} \left[\frac{\epsilon_{\text{sim}}}{2} (1 - \hat{\pi}_{H-1}(a_2 | s_1)) \right] \\ &= \frac{\epsilon_{\text{sim}}}{2} \left[1 - \frac{1}{2} \cdot \sup_{\hat{\pi}} \left(\mathbb{E}^{\mathcal{M}_1, \hat{\pi}} [\hat{\pi}_{H-1}(a_1 | s_1)] + \mathbb{E}^{\mathcal{M}_2, \hat{\pi}} [\hat{\pi}_{H-1}(a_2 | s_1)] \right) \right]. \end{aligned}$$

由於 $\hat{\pi}_{H-1}(a_1 | s_1) = 1 - \hat{\pi}_{H-1}(a_2 | s_1)$ ，我們有

$$\begin{aligned} \mathbb{E}^{\mathcal{M}_1, \hat{\pi}} [\hat{\pi}_{H-1}(a_1 | s_1)] + \mathbb{E}^{\mathcal{M}_2, \hat{\pi}} [\hat{\pi}_{H-1}(a_2 | s_1)] &= 1 + \mathbb{E}^{\mathcal{M}_1, \hat{\pi}} [\hat{\pi}_{H-1}(a_1 | s_1)] - \mathbb{E}^{\mathcal{M}_2, \hat{\pi}} [\hat{\pi}_{H-1}(a_1 | s_1)] \\ &\leq 1 + \text{TV} \left(\mathbb{P}^{\mathcal{M}_1, \hat{\pi}}, \mathbb{P}^{\mathcal{M}_2, \hat{\pi}} \right) \\ &\leq 1 + \sqrt{\frac{1}{2} \text{KL} \left(\mathbb{P}^{\mathcal{M}_1, \hat{\pi}} \| \mathbb{P}^{\mathcal{M}_2, \hat{\pi}} \right)} \end{aligned}$$

其中 TV 代表全變分距離 (total-variation distance)，KL 代表 KL 散度 (KL-divergence)，而最後一個不等式是由 Pinsker 不等式推導而來。因此我們有

$$\inf_{\hat{\pi}} \sup_{i \in \{1, 2\}} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}^2} \left[V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}^3} \right] \geq \frac{\epsilon_{\text{sim}}}{4} \left(1 - \sqrt{\frac{1}{2} \text{KL} \left(\mathbb{P}^{\mathcal{M}_1, \hat{\pi}} \| \mathbb{P}^{\mathcal{M}_2, \hat{\pi}} \right)} \right)$$

請注意，由於 $\mathcal{M}_1$ 與 $\mathcal{M}_2$ 僅在狀態 s_1 與步驟 $H-1$ 有所不同，我們得到

$$\begin{aligned} \text{KL} \left(\mathbb{P}^{\mathcal{M}_1, \hat{\pi}} \| \mathbb{P}^{\mathcal{M}_2, \hat{\pi}} \right) &= \mathbb{E}^{\mathcal{M}_1, \hat{\pi}} [T_{H-1}(s_1, a_1)] \text{KL} \left(P_{H-1}^{\mathcal{M}_1}(\cdot | s_1, a_1) \| P_{H-1}^{\mathcal{M}_2}(\cdot | s_1, a_1) \right) \\ &\quad + \mathbb{E}^{\mathcal{M}_1, \hat{\pi}} [T_{H-1}(s_1, a_2)] \text{KL} \left(P_{H-1}^{\mathcal{M}_1}(\cdot | s_1, a_2) \| P_{H-1}^{\mathcal{M}_2}(\cdot | s_1, a_2) \right) \end{aligned}$$

其中 $T_{H-1}(s_1, a_i)$ 表示在 T 個 episode 之後，於步驟 $H-1$ 造訪 (s_1, a_i) 的總次數（參見例如 Tirinzoni et al. (2021)）。我們得到

$$\begin{aligned} \text{KL} \left(P_{H-1}^{\mathcal{M}_1}(\cdot | s_1, a_1) \| P_{H-1}^{\mathcal{M}_2}(\cdot | s_1, a_1) \right) &= \text{KL} \left(P_{H-1}^{\mathcal{M}_1}(\cdot | s_1, a_2) \| P_{H-1}^{\mathcal{M}_2}(\cdot | s_1, a_2) \right) \\ &= \frac{1}{4} \log \frac{1/4}{3/4} + \frac{3}{4} \log \frac{3/4}{1/4} \leq \frac{3}{5} \end{aligned}$$

其中最後一個不等式在 $\epsilon_{\text{sim}} \leq 1/6$ 成立時保持不變。請注意，策略到達步驟 $H-1$ 之 s_1 的唯一方法是連續執行動作 $a_1 H-1$ 。由於 $\hat{\pi}$ 在任何給定步驟中執行 a_1 的機率僅為 $\zeta/2$ ，因此 $\hat{\pi}$ 在任何給定 episode 的步驟 $H-1$ 到達 s_1 的機率僅為 $(\zeta/2)^{H-1}$ 。因此，

$$\begin{aligned} \text{KL} \left(\mathbb{P}^{\mathcal{M}_1, \hat{\pi}} \| \mathbb{P}^{\mathcal{M}_2, \hat{\pi}} \right) &\leq \frac{3}{5} \left(\mathbb{E}^{\mathcal{M}_1, \hat{\pi}} [T_{H-1}(s_1, a_1)] + \mathbb{E}^{\mathcal{M}_1, \hat{\pi}} [T_{H-1}(s_1, a_2)] \right) \\ &= \frac{3}{5} \mathbb{E}^{\mathcal{M}_1, \hat{\pi}} [T_{H-1}(s_1)] \\ &= \frac{3}{5} \left(\frac{\zeta}{2} \right)^{H-1} \cdot T \end{aligned}$$

我們因而得到：

$$\inf_{\hat{\pi}} \sup_{i \in \{1, 2\}} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}} \left[V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}} \right] \geq \frac{\epsilon_{\text{sim}}}{4} \left(1 - \sqrt{\frac{3}{10} \left(\frac{\zeta}{2} \right)^{H-1} \cdot T} \right)$$

因此我們得到 $\inf_{\hat{\pi}} \sup_{i \in \{1, 2\}} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}} \left[V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}} \right] \geq \epsilon_{\text{sim}} / 8$ ，除非

$$T \geq \frac{5}{6} \cdot \left(\frac{2}{\zeta} \right)^{H-1}$$

無 sim 之 ζ -Greedy 的下界（命題 1）。為了量化 ζ -greedy 演算法的效能，我們必須指定當它尚未從給定的 (s, a, h) 觀察到任何樣本時，如何選擇 $\hat{f}$ 。遵循 Dann 等人 (2022) 定理 2 的做法，為了避免過於樂觀或悲觀的初始化，我們假設重播

緩衝區 (replay buffer) 已使用來自每個 (s, a, h) 的單個樣本進行初始化。請注意，若使用其他初始化方式，結論仍然成立，例如在沒有來自 (s, a, h) 的觀察值時，初始化 $\hat{f}_h(s, a) = 0$ 或進行隨機初始化。

假設來自 $(s_1, a_1, H-1)$ 的觀察值轉移至 s_2 ，這發生的機率至少為 $1/4$ 。在這種情況下，對於每個 h ， $\hat{f}_h^0(s_1, a_2) \geq \hat{f}_h^0(s_1, a_1)$ ，我們得到以下結果。因此，遵循 ζ -greedy 策略，我們得到 $\pi_h^0(a_1 | s_1) \leq 1/2$ 。將此事件標記為 $\mathcal{E}_0$ 。此外，我們唯一能得到 $\hat{f}_h^0(s_1, a_2) < \hat{f}_h^0(s_1, a_1)$ 的方式是再次訪問 $(s_1, a_1, H-1)$ 並觀察到轉移至 s_1 。然而，為了讓這種情況發生，我們必須連續執行動作 $a_1 H-1$ 次，在這種情況下，發生的機率至多為 $\max\{1/2, \zeta/2\}^{H-1} \leq 1/2^{H-1}$ 。

遵循直接策略轉移 (direct policy transfer) 案例中的論點，我們得到

$$\begin{aligned} \inf_{\hat{\pi}} \sup_{i \in \{1,2\}} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}} [V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}}] &\geq \inf_{\hat{\pi}} \sup_{i \in \{1,2\}} \frac{1}{4} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}} [V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}} | \mathcal{E}_0] \\ &\geq \frac{\epsilon_{\text{sim}}}{16} \left(1 - \sqrt{\frac{3}{10} \mathbb{E}^{\mathcal{M}_1} [T_{H-1}(s_1) | \mathcal{E}_0]} \right) \end{aligned}$$

其中 $\mathbb{E}^{\mathcal{M}_1} [T_{H-1}(s_1) | \mathcal{E}_0]$ 是在執行 ζ -greedy 策略 T 個回合後，造訪 $(s_1, H-1)$ 的預期次數。我們可以將其重寫為

$$\mathbb{E}^{\mathcal{M}_1} [T_{H-1}(s_1) | \mathcal{E}_0] = \sum_{t=1}^T \mathbb{E}^{\mathcal{M}_1} [\mathbb{I}\{s_{H-1} = s_1\} | \mathcal{E}_0]$$

令 $\mathcal{E}$ 為我們在前 T 輪中到達 $(s_1, H-1)$ 的事件。則，

$$\begin{aligned} \mathbb{E}^{\mathcal{M}_1} [\mathbb{I}\{s_{H-1} = s_1\} | \mathcal{E}_0] &= \mathbb{E}^{\mathcal{M}_1} [\mathbb{I}\{s_{H-1} = s_1\} | \mathcal{E}, \mathcal{E}_0] \mathbb{P}^{\mathcal{M}_1} [\mathcal{E} | \mathcal{E}_0] + \mathbb{E}^{\mathcal{M}_1} [\mathbb{I}\{s_{H-1} = s_1\} | \mathcal{E}^c, \mathcal{E}_0] \mathbb{P}^{\mathcal{M}_1} [\mathcal{E}^c | \mathcal{E}_0] \\ &\leq \mathbb{P}^{\mathcal{M}_1} [\mathcal{E} | \mathcal{E}_0] + \mathbb{E}^{\mathcal{M}_1} [\mathbb{I}\{s_{H-1} = s_1\} | \mathcal{E}^c, \mathcal{E}_0] \end{aligned}$$

根據我們剛才的論證，我們得到 $\mathbb{P}^{\mathcal{M}_1} [\mathcal{E} | \mathcal{E}_0] \leq T \cdot \frac{1}{2^{H-1}}$ 以及 $\mathbb{E}^{\mathcal{M}_1} [\mathbb{I}\{s_{H-1} = s_1\} | \mathcal{E}^c, \mathcal{E}_0] \leq \frac{1}{2^{H-1}}$ 。因此， $\mathbb{E}^{\mathcal{M}_1} [T_{H-1}(s_1) | \mathcal{E}_0] \leq \frac{2T^2}{2^{H-1}}$ 。由此可知，

$$\inf_{\hat{\pi}} \sup_{i \in \{1,2\}} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}} [V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}}] \geq \frac{\epsilon_{\text{sim}}}{16} \left(1 - \sqrt{\frac{3}{10} \frac{2T^2}{2^{H-1}}} \right)$$

因此除非，否則我們得到 $\inf_{\hat{\pi}} \sup_{i \in \{1,2\}} \mathbb{E}^{\mathcal{M}_i, \hat{\pi}} [V_0^{\mathcal{M}_i, \star} - V_0^{\mathcal{M}_i, \hat{\pi}}] \geq \epsilon_{\text{sim}} / 32$

$$T \geq \sqrt{\frac{5}{8} \cdot 2^{H-1}}$$

探索策略轉移的上限 (命題 4)。為了獲得演算法 1 的上限，只要滿足以下條件，我們即可應用定理 1：

$$\epsilon_{\text{sim}} \leq \frac{\lambda_{\min}^*}{64dHA^3}$$

請注意，在我們的設定中，我們有 $d = 4, A = 2, \lambda_{\min}^* = 1/4$ ，因此此條件簡化為 $\epsilon_{\text{sim}} \leq \frac{1}{8192H}$ 。將 $\mathcal{F}$ 簡單設定為上述定義的 Q 函數集合 (因此 $V_{\max} = H$)，定理 1 則指出，在機率至少為 $1 - \delta$ 的情況下，只要滿足 $T \geq c \cdot \frac{H^{17}}{\epsilon^8} \cdot \log \frac{H}{\delta}$ ，演算法 1 就能學習到 ϵ 最佳策略。

D.2 命題 5 之證明

我們定義了三個 MDP： $\mathcal{M}^{\text{sim}}$ ，以及兩個可能的真實 MDP，分別為 $\mathcal{M}_1 := \mathcal{M}^{\text{real}, 1}$ 與 $\mathcal{M}_2 := \mathcal{M}^{\text{real}, 2}$ 。在所有情況下，我們都有狀態 $\mathcal{S} = \{s_1, s_2\}$ 、動作 $\mathcal{A} = \{a_1, a_2, a_3, a_4\}$ 以及 $H = 2$ ，並將起始狀態設定為 s_1 。我們定義

$$P_1^{\text{sim}}(s_1 | s_1, a_1) = 1, \quad P_1^{\text{sim}}(s_1 | s_1, a) = P_1^{\text{sim}}(s_2 | s_1, a) = 1/2, a \in \{a_2, a_3, a_4\}.$$

對於 $\mathcal{M}_1$ 與 $\mathcal{M}_2$ ，我們得到：

$$P_1^{\text{real}}(s_1 | s_1, a_1) = 1, P_1^{\text{real}}(s_1 | s_1, a_4) = P_1^{\text{real}}(s_2 | s_1, a_4) = 1/2$$

對於 $\mathcal{M}_1$ ，我們得到

$$P_1^{\text{real}}(s_2 | s_1, a_2) = 1 + \epsilon_{\text{sim}}, P_1^{\text{real}}(s_1 | s_1, a_2) = 1 - \epsilon_{\text{sim}}, P_1^{\text{real}}(s_1 | s_1, a_3) = P_1^{\text{real}}(s_2 | s_1, a_3) = 1/2$$

而對於 $\mathcal{M}_2$ ，

$$P_1^{\text{real}}(s_2 | s_1, a_3) = 1 + \epsilon_{\text{sim}}, P_1^{\text{real}}(s_1 | s_1, a_3) = 1 - \epsilon_{\text{sim}}, P_1^{\text{real}}(s_1 | s_1, a_2) = P_1^{\text{real}}(s_2 | s_1, a_2) = 1/2.$$

除了所有 a 的情況為 $r_2(s_2, a) = 1$ 之外，我們將其餘各處的獎勵 (reward) 皆設為 0。

請注意，這些都可以表示為 $d = 2$ 維度中的線性 MDP，因此假設 2 成立。特別是對於 $\mathcal{M}^{\text{sim}}$ ，我們可以採用：

$$\begin{aligned} \phi^s(s, a_1) &= e_1, \phi^s(s, a) = e_2, a \in \{a_2, a_3, a_4\}, s \in \mathcal{S} \\ \mu_1^s(s_1) &= [1, 1/2], \mu_1^s(s_2) = [0, 1/2] \end{aligned}$$

對於 $\mathcal{M}_1$ ，我們則可以改為採用：

$$\begin{aligned} \phi^r(s, a_1) &= e_1, \phi^r(s, a) = [1/2, 1/2], a \in \{a_3, a_4\}, s \in \mathcal{S}, \\ \phi^r(s, a_2) &= [1/2 - \epsilon_{\text{sim}}, 1/2 + \epsilon_{\text{sim}}], s \in \mathcal{S}, \\ \mu_1^r(s_1) &= [1, 0], \mu_1^r(s_2) = [0, 1]. \end{aligned}$$

$\mathcal{M}_2$ 的推導過程類似，只需將 a_2 與 a_3 的角色互換即可。

顯而易見，在此實例中，兩種 $\mathcal{M}^{\text{real}}$ 的選擇皆符合假設 1。在 $\mathcal{M}^{\text{sim}}$ 上，若策略 π_{exp} 在所有狀態下以機率 $1/2$ 執行動作 a_1 ，並以機率 $1/2$ 執行動作 a_4 ，則滿足 $\lambda_{\min} \left(\mathbb{E}^{\text{sim}, \pi_{\text{exp}}} \left[\phi^s(s_h, a_h) \phi^s(s_h, a_h)^\top \right] \right) \geq 1/2$ (這顯示假設 3 成立)。

然而請注意， π_{exp} 並不會執行動作 a_2 或 a_3 。由於 $\mathcal{M}_1$ 與 $\mathcal{M}_2$ 僅在 a_2 和 a_3 上有所不同，執行 π_{exp} 將無法區分 $\mathcal{M}_1$ 與 $\mathcal{M}_2$ 。由於 a_2 是 $\mathcal{M}_1$ 上的最佳動作，而 a_3 是 $\mathcal{M}_2$ 上的最佳動作，因此執行 π_{exp} 將無法識別 $\mathcal{M}_1$ 與 $\mathcal{M}_2$ 上的最佳策略。這可以透過與附錄 D.1 相同的方式進行形式化，從而得出所述結果。

E 實驗細節

E.1 教學用表格範例

考慮以下組合鎖 (combination lock) 的變體。我們設定動作空間為 $\mathcal{A} = \{1, 2\}$ ，並假設有兩個狀態 $\mathcal{S} = \{s_1, s_2\}$ ，以及時間步長 (horizon) H 。我們從狀態 s_1 開始。Sim 動態特性如下：

$$\begin{aligned} \forall h < H - 1: \quad & P_h^{\text{sim}}(s_1 | s_1, a_1) = 1, \quad P_h^{\text{sim}}(s_2 | s_1, a_2) = 1 \\ & P_{H-1}^{\text{sim}}(s_1 | s_1, a_1) = 1/4, P_{H-1}^{\text{sim}}(s_2 | s_1, a_1) = 3/4, P_{H-1}^{\text{sim}}(s_2 | s_1, a_2) = 1 \\ \forall h \in [H]: \quad & P_h^{\text{sim}}(s_2 | s_2, a) = 1, a \in \{a_1, a_2\} \end{aligned}$$

而真實動態 (real dynamics) 如下：

$$\begin{aligned} \forall h < H - 1: \quad & P_h^{\text{real}}(s_1 | s_1, a_1) = 1, \quad P_h^{\text{real}}(s_2 | s_1, a_2) = 1 \\ & P_{H-1}^{\text{real}}(s_1 | s_1, a_1) = 3/4, P_{H-1}^{\text{real}}(s_2 | s_1, a_1) = 1/4, P_{H-1}^{\text{real}}(s_2 | s_1, a_2) = 1 \\ \forall h \in [H]: \quad & P_h^{\text{real}}(s_2 | s_2, a) = 1, a \in \{a_1, a_2\} \end{aligned}$$

請注意，兩者僅在 $h = H - 1$ 時的 (s_1, a_1) 有所不同，且我們得到 $\epsilon_{\text{sim}} = 1/2$ 。我們將獎勵函數 (reward function) 定義如下 (請注意這是確定性的，且在模擬與真實環境中皆相同)：

$$\begin{aligned} \forall h \in [H]: \quad & r_h(s_1, a_2) = 1/8 - h/8H \\ & r_H(s_1, a) = 1/5, a \in \{a_1, a_2\} \end{aligned}$$

且所有其他獎勵均視為 0。

此範例的直覺如下。無論在模擬或真實環境中，代理人 (agent) 獲得獎勵的唯一方式，要麼是在第 H 步時處於狀態 s_1 ，要麼是在任何時間點於狀態 s_1 採取動作 a_2 。在模擬環境中，即使採取了達成此目標的最佳動作序列，在第 H 步時處於狀態 s_1 的機率也僅有 $1/4$ (由於最後一次轉移所致)，因此旨在進入 s_1 的策略所獲得的平均獎勵僅為 $1/4$ 。相比之下，如果我們在 s_1 採取動作 a_2 ，我們將始終收集至少 $3/8$ 的獎勵 (且越早採取動作 a_2 ，收集的獎勵越多，最高可達 $1/2$)。因此，在模擬環境中，在 s_1 的最佳做法始終是執行 a_2 。然而，如果我們執行了哪怕一次 a_2 ，我們就會轉移出 s_1 且不再返回，因此我們將沒有機會在第 H 步時到達 s_1 。

在真實環境中，最後一步的轉移被翻轉了，因此如果我們採取達成此目標的最佳動作序列，現在結束於 s_1 的機率為 $3/4$ ，而其期望獎勵也隨之變為 $3/4$ 。由於在 s_1 中採取 a_2 的獎勵沒有改變，且其範圍限制在 $1/2$ ，因此在真實環境中，最佳策略是尋求在最後一步結束於 s_1 。

在結束時停留在 s_1 的挑戰在於，這需要在每一步都執行動作 a_1 。就此而言，這是一個經典的組合鎖 (combination lock) 案例，隨機探索將會失敗，需要 $\Omega(2^H)$ 個回合才能到達最終狀態（因為在每個狀態隨機採取 a_1 的機率會隨著時間範圍呈指數級下降）。同樣地，如果我們將最佳策略從模擬環境轉移到真實環境，它將永遠不會採取動作 a_1 ，因此最後永遠無法到達 s_1 ；而如果我們將帶有隨機探索的模擬環境最佳策略進行轉移，它也會因為與從頭開始隨機探索相同的理由而失敗。

然而，請注意我們可以從模擬環境轉移一個能夠以機率 1 在倒數第二步到達 s_1 的策略，即在每一步都採取動作 a_1 的策略。因此，如果在模擬環境中，我們的目標是學習能夠遍歷 MDP 的探索策略，並轉移這些探索策略，它們將可以成功轉移，並讓我們在最後一步輕鬆到達 s_1 ，進而快速確定這在真實環境中確實是最佳選擇。

我們在附錄 E.1 中提供了關於此案例的額外實驗結果。




圖 7: 圖 9: 在第 5.2 節的實例上進行探索策略轉移 (Exploration Policy Transfer) 的效能表現，變數包含狀態數量、動作數量與時間步長 (horizon)。我們繪製了達到 0.35 獎勵 (約等於完成任務) 所需的樣本數量。所有結果皆為 20 次試驗的平均值。當增加狀態數量時，我們加入額外的 0 獎勵狀態 (即圖 2 中以黃色標示的狀態)；當增加動作數量時，我們加入額外的低獎勵動作 (即行為與圖 2 中動作 a_2 相同的動作)。我們觀察到，增加狀態數量與時間步長會增加所需的樣本數，而增加動作數量則不會顯著影響。然而，我們強調這是針對特定範例的結果，這種縮放比例可能不適用於所有範例——不過，定理 1 (Theorem 1) 為所有範例提供了一個上界。

Algorithm 6 sim2real transfer using OS for exploration and SAC for optimization



```

Input: Simulator  $\mathcal{M}^{\text{sim}}$ , real environment  $\mathcal{M}^{\text{real}}$ ,
reward balancing  $\alpha$ , reward threshold  $\epsilon$ , exploration set size  $N$ 
Pre-train Exploration Policies in  $\mathcal{M}^{\text{sim}}$  :
Initialize  $\pi_{\text{exp}} = \left\{ \pi_{\theta}(\cdot \mid z) \mid z \in \{1 \dots N\} \right\}$ 
Initialize discriminator  $D_{\phi}$ 
for  $(i=1)$  to  $(N)$  do  $\triangleright$  Learn diverse exploration policies
    Sample latent  $(z \sim \text{unif}(1, n))$  and initial state  $(s_0)$ 
    for  $(t=1)$  to  $\text{max\_steps\_per\_episode}$  do
        Sample action  $(a_t \sim \pi_{\theta}(a_t \mid s_t, z))$ .
        Step environment:  $(s_{t+1} \sim p(s_{t+1} \mid s_t, a_t))$ 
        Compute discriminator score  $(d_t = D(s_{t+1}, z))$ 
        Compute exploration reward  $(r_e(s_{t+1}, z) = \log \frac{\exp(d_t)}{\sum \exp(d)})$ 
        if  $(R_{\pi} \geq \epsilon)$  then
            Compute reward  $(r_t = r(s_t, a_t) + \alpha \cdot r_e)$ 
        else
            Compute reward  $(r_t = r(s_t, a_t))$ 
        Let  $(D \leftarrow D \cup \{(s_t, a_t, r_t)\})$ 
    Update  $(\pi_{\theta})$  to maximize  $(J_{\pi})$  with SAC.

```

```

    Update  $(\phi)$  to maximize  $(J_u)$ ,  $\phi \leftarrow \phi + \eta \nabla_{\phi} J_u$ 
    Compute  $(R_{\pi} = \sum_t r_t)$ 
    Explore in  $(\mathcal{M}^{\text{real}})$  and Estimate Optimal Policy :
    Initialize SAC agent (either from scratch or to weights of optimal sim policy).
    while not converged do
        Sample  $(z \sim \text{unif}(1, n))$ , play  $(\pi_{\theta}(\cdot | z))$ 
        Roll out SAC policy for one step, perform standard SAC update.

```

E. 2 實際演算法細節

我們工作的核心在於將強化學習微調中的最佳策略訓練與探索策略解耦。具體而言，我們提出了一個框架，使用一組多樣化的探索策略從環境中收集樣本。當我們對收集到的樣本進行 off-policy RL 更新以提取最佳策略時，這些探索策略是固定的。我們的理論推導表明，這種解耦可以提高樣本效率和整體的學習效能。

我們的框架與以下兩者互補：(a) 產生多樣化策略的 RL 多樣性或探索研究，以及 (b) 優化策略的 off-policy RL 演算法。開發者可以接入 (a) 從模擬器中提取一組探索策略，並將其用於真實世界的數據收集，同時使用 (b) 來優化最終策略。使用模擬器提取一組探索策略，且每個策略不一定針對當前任務進行優化的設計選擇，使我們與 (a) 和 (b) 中的先前研究有所區別。

我們提供了一個實用的框架實作，採用受 One Solution is Not All You Need (OS) (Kumar et al., 2020) 啟發的方法來提取探索策略，並使用 Soft Actor Critic (SAC) (Kumar et al., 2020) 來優化最佳策略。我們在 Algorithm 6 中詳細說明了此實作。OS 訓練一組策略，不僅優化任務獎勵，還優化辨別器獎勵 (discriminator reward)，其中辨別器會鼓勵每個策略達成不同的狀態。與 OS 不同之處在於

超參數	數值
獎勵平衡 α (OS)	$\{\frac{1}{38}i - \frac{1}{38} : i = 1, 2, \dots, 20\}$
學習率	0.0003
Q 更新幅度 τ	0.005
折扣因子 γ	0.99
批次大小	2048
每個回合的步數 (steps per episode)	45
重播緩衝區大小 (replay buffer size)	5×10^6
訓練步數 N (於 $\mathcal{M}^{\text{real}}$)	7×10^7

表 1: Tycho 訓練與微調所使用的超參數

仔細平衡任務與探索獎勵，以確保所有策略都有機會解決目標任務，我們則強調僅需具備多樣化的策略。由於已知存在 sim-to-real 差距，我們假設某些在模擬器中未能解決任務的次佳策略，實際上對現實世界中的探索有所幫助，這使我們能夠簡化任務與探索之間的平衡。我們使用標準的現成 SAC 更新來優化策略。

E. 3 TychoEnv sim2sim 實驗細節

針對 TychoEnv 實驗，我們執行了演算法 6 的變體。我們設定 $n = 20$ ，並將獎勵設為 $r_t^i = (1 - \alpha_i)r + \alpha_i r_e$ ，其中我們將 α_i 從 0 變動至 0.5。雖然我們在 $\mathcal{M}^{\text{real}}$ 中使用稀疏獎勵 (sparse reward)，但為了加速 $\mathcal{M}^{\text{sim}}$ 中的訓練，我們使用了根據代理人與目標距離進行懲罰的密集獎勵 (dense reward)。我們在 $\mathcal{M}^{\text{sim}}$ 中訓練了 7 M 個步數以取得探索策略 (exploration policies)。我們發現最有效的方法並非單純轉移在 $\mathcal{M}^{\text{sim}}$ 中訓練完成的收斂版探索策略，而是在整個訓練過程中儲存策略權重，並轉移所有這些策略。由於這些策略中的大多數在 $\mathcal{M}^{\text{sim}}$ 中無法獲得任何獎勵，因此我們執行了一個初始篩選階段，從中識別出數個能獲得獎勵的策略（這可以從圖 6 中初始獎勵為 0 的區域看出）。接著我們在 $\mathcal{M}^{\text{real}}$ 中執行從頭開始初始化的 SAC，並將這些精煉後的探索策略所收集的數據餵入重播緩衝區 (replay buffer)。我們發現最有效的方法是僅在探索策略觀察到獎勵的集數 (episodes) 中，才將其數據注入重播緩衝區。我們執行 UTD 為 3 且目標熵 (target entropy) 為 -3 的原生 SAC。我們採用來自 stable-baselines3 (Raffin et al., 2021) 的 SAC 實作。

對於直接策略轉移 (direct policy transfer)，我們在 $\mathcal{M}^{\text{sim}}$ 中訓練一個策略至收斂以解決該任務 (使用 SAC)，接著轉移此單一策略，其餘步驟則遵循與上述相同的程序。

在 $\mathcal{M}^{\text{real}}$ 中，我們選擇的獎勵函數為：若末端執行器 (end effector) 接觸到球，則數值為 50，否則為 0。如果機器人成功接觸到球，該回合 (episode) 即告結束。為了生成逼真且可轉移的環境，我們更改了控制頻率 (在 $\mathcal{M}^{\text{real}}$ 中將其加倍) 以及動作邊界 (action bounds)。

針對這兩種方法，我們分別執行 $\mathcal{M}^{\text{sim}}$ 訓練程序 4 次，接著針對每一次訓練結果，在 $\mathcal{M}^{\text{real}}$ 中各執行 2 次。圖表中的誤差棒 (error bars) 表示一個標準誤差。

所有實驗均在兩張 Nvidia V100 GPU 以及 32 Intel(R) Xeon(R) 顆 CPU E5-2620 v4 @ 2.10 GHz 上執行。其餘超參數 (hyperparameters) 詳列於表 1。

我們在圖 10 中提供了 Tycho 設置在其他數個基準測試 (baselines) 上的結果。




圖 8: 圖 10: Tycho 上的額外結果，包含在 $\mathcal{M}^{\text{real}}$ 中從頭開始訓練的基準測試，以及在 $\mathcal{M}^{\text{sim}}$ 中訓練探索策略的結果，其獎勵如上所述但帶有 $\alpha_i = 1$ (這相當於單純使用 DIAYN (Eysenbach et al., 2018) 訓練探索策略)。如圖所示，雖然在 $\mathcal{M}^{\text{real}}$ 中從頭開始訓練能夠學習，但其學習速度遠慢於探索策略轉移 (exploration policy transfer)，且最終達到的數值也低得多。此外，訓練探索策略以最大化任務與多樣性獎勵的混合，其效果顯著優於僅訓練其具備多樣性。

超參數	數值
獎勵平衡 α (OS)	0.5
獎勵閾值 ϵ (OS)	-16
學習率	0.0003
Q 更新幅度 τ	0.005
折扣因子 γ	0.99
批次大小 (batch size)	256
每個回合步數 (steps per episode)	45
重播緩衝區大小 (replay buffer size)	1×10^6
訓練步數 N	2×10^7

表 2: Franka 訓練與微調所使用的超參數




圖 9: 圖 11: Franka sim2real 實驗結果，並與在真實環境中從頭開始訓練 (training from scratch) 的結果進行比較。

E. 4 Franka sim2real 實驗細節

我們使用 Algorithm 6 在 Franka 機器人上以 $n = 15$ 訓練策略。
推擊任務 (pushing task) 的獎勵給定如下：

$$r(s_t, a_t) = -\|\mathbf{p}_{ee} - \mathbf{p}_{obj}\|^2 - \|\mathbf{p}_{obj} - \mathbf{p}_{goal}\|^2 + \mathbb{I}_{\mathbf{p}_{obj} - \mathbf{p}_{goal} \leq 0.025} - \mathbb{I}_{\mathbf{p}_{obj} \text{ offtable}}$$

其中 $\mathbf{p}_{goal}$ 是冰球在桌面邊緣的目標位置。

Actor 與 Critic 網路的架構相同，皆由 2 層 MLP 組成，每層大小為 256 並採用 ReLU 激活函數。

我們使用 stable-baselines3 (Raffin et al., 2021) 進行 SAC 實作，並採用其所有的預設超參數。OS 的實作是建立在此 SAC 實作之上。超參數的數值如表 2 所示。在模擬中，我們對冰球的位置加入了均值為 0、標準差為 0.005 公尺的高斯雜訊。探索策略轉移 (exploration policy transfer) 與直接轉移 (direct transfer) 方法所使用的超參數完全相同。

在實體環境進行微調時，我們首先完全從模擬過程中使用的緩衝區 (buffer) 進行採樣。接著，隨著微調的進行，我們逐漸增加從實體緩衝區採樣的比率，其中來自模擬環境 (sim) 的採樣比例等於 $1 - s/3000$ ，而 s 是目前的步數。在 3000 步之後，所有樣本都將從實體緩衝區中取得。

實驗是在標準的 Nvidia RTX 4090 GPU 上運行的。在模擬環境中訓練大約需要 3 小時，而微調則運行了約 90 分鐘。

在圖 11 中，我們提供了在此設置下運行額外基準測試 (baseline) 的結果，即在實體環境中從頭開始訓練策略 (policy)。顯而易見地，這比任何一種轉移方法 (transfer method) 的效果都要差得多。

¹ 為求簡化，我們在此僅關注動力學不匹配 (dynamics mismatch)，但請注意，還可能存在許多其他類型的不匹配，例如感知差異。然而，我們注意到從模擬到實體的動力學偏移 (dynamics shift) 在實務中非常常見，因為我們經常會遇到未建模的動力學組件，例如接觸力 (contact)。

² 假設 ϕ^s 為已知僅是為了簡化問題——若 ϕ^s 同樣未知，使用 $\mathcal{M}^{\text{sim}}$ 中更複雜的演算法工具也能獲得類似的結果。在整篇論文中，我們使用「 ζ -greedy」來指代文獻中更常見的「 ϵ -greedy」方法，以避免此 ϵ 與我們在定義 3.2 的 PAC RL 定義中的 ϵ 產生混淆。雖然為了簡化起見，我們假設可以計算出真正的最佳策略，但我們的結果可以輕易擴展到僅能透過 Oracle 計算出近似最佳策略的情境。

⁵ 若 $\mathbf{\Lambda}_{\pi_{\text{exp}}, h}^{r, h-1}$ 不可逆，我們可以用 $\mathbf{\Lambda}_{\pi_{\text{exp}}, h}^{r, h-1} + \lambda I$ 重複此論證並取 $\lambda \rightarrow 0$ 。

⁶ 請注意，雖然 Lemma B. 1 適用於受限回歸 (constrained regression) 設定，但若我們選擇足夠大的 γ 使約束條件失效，則這等同於此處所考慮的非受限回歸 (unconstrained regression) 設定。