

Fatemeh Mohammadi Amin^{1,3*}, Darwin G. Caldwell²

與 Hans Wernher van de Venn³

¹ 蘇黎世大學，蘇黎世，瑞士。

² 義大利理工學院 (IIT)，熱那亞，義大利。

³ 蘇黎世應用科學大學機電系統研究所，溫特圖爾，瑞士。

*通訊作者。E-mail(s): mohm@zhaw.ch;

摘要

對 3D 環境的強健解釋對於人機協作 (HRC) 應用至關重要，在這些應用中，安全性和運作效率是首要考量。語義分割 (Semantic segmentation) 在此背景下扮演關鍵角色，能實現對環境精確且詳細的理解。考量到有效語義分割對真實工業標註數據的極大需求，本文針對 HRC 量身打造，提出了一種用於 3D 點雲數據語義分割的 Sim2Real 領域自適應 (domain adaptation) 創新方法。我們的重點在於開發一個能從模擬環境強健地過渡到真實世界應用的網路，從而增強其在安全 HRC 中的實用價值與影響力。在這項工作中，我們提出了一種雙流網路架構 (FUSION)，結合了動態圖卷積神經網路 (DGCNN) 與增強殘差層的卷積神經網路 (CNN)，作為工業環境下的 Sim2Real 領域自適應演算法。所提出的模型在真實 HRC 設置與模擬工業點雲上進行了評估，結果顯示其性能超越了現有的先進技術，達到了 97.76% 的分割準確度，且與現有方法相比具有更優異的強健性。

關鍵字：人機協作 (HRC)、語義分割、領域自適應、即時分割

1 緒論

在強調智慧化與彈性自動化的工業 4.0 範式下，安全的機器人協作 (HRC) 變得日益重要。傳統機器人正逐漸被協作機器人 (cobots) 所取代，這些機器人旨在動態的工業環境中與人類進行安全且高效的互動。事實上，協作機器人正越來越多地被用於取代傳統工業機器人以執行彈性任務 [1]，並且可以與人類在同一個工作空間中工作 [2]。

為了與人類進行有效協作，協作機器人需要具備先進的智慧，使其能夠對人類的輸入做出反應，並適應動態環境，以實現流暢、安全且高效的工作流程 [3]。這需要先進的感測與感知能力 [4]，例如 3D 點雲數據的語義分割 (semantic segmentation)，這對於準確理解工業環境中的物體，以及透過偵測潛在危險來確保安全至關重要 [5, 6]。

儘管機器學習技術取得了進步，但在工業環境中部署這些模型仍面臨重大挑戰。對於涉及人類的任務 (如機器人協作) 尤其如此，因為確保人員安全至關重要 [3]。諸如「數據飢渴」 (data hunger, 指因數據集不足導致的性能限制)、使用現實數據集的限制，以及人工標記耗時等因素，阻礙了大規模標記點雲數據集的獲取，而這些數據集對於訓練準確的模型是必不可少的 [7]。為了應對這些挑戰，遷移學習 (transfer learning) 與領域自適應 (domain adaptation) 技術正受到越來越多的探索，這些技術能使模型在不同的數據集和領域之間具備泛化能力 [8]。

本文探討了 HRC 環境中 3D 點雲語義分割的緊迫問題。研究採用了 Sim2Real 領域自適應 (domain adaptation) 技術，這是因為出於安全考量以及設備可用性限制 (如缺乏多樣化的機器人) 和數據收集困難等實際限制，完全使用真實世界數據並不可行。Sim2Real 領域自適應是指旨在將模擬環境中訓練的模型進行調整，使其在真實世界中能高效運行的策略。因此，本研究探索了利用模擬數據作為替代手段，來訓練強健且高效的語義分割模型。利用模擬數據不僅克服了標註真實世界數據集匱乏的問題，還提供了一個受控環境，能生成多樣化且具挑戰性的場景，以進行全面的模型訓練。

利用模擬數據訓練語義分割模型的主要挑戰之一，在於實現數據的真實性與準確性。透過利用尖端的模擬工具，可以生成與工業環境高度相似的合成 3D 點雲，同時保持對物體交互、光照條件和材料屬性等關鍵面向的控制。

在方法論中，利用了一個名為 FUSION 的雙流網路 (two-stream network) 來進行有效的分割。此方法結合了兩種不同的神經網路架構以提升效能，優化系統以執行更精確的分割任務。該網路是所提方法中的關鍵組件。最初，使用模擬數據進行訓練。隨後，對網路進行微調與自適應。




圖 1: FUSION、模擬與真實世界數據集的整體概念圖

透過真實世界的數據應用，確保其在動態的真實工業環境中具備強健的效能與準確的解讀能力。

結果顯示，該方法在人機協作（Human-Robot Collaboration）環境中展現了提升的泛化能力與效能，在真實場景中達到 97.6% 的準確度，在模擬情境中則達到 98.9%。研究結果亦強調了此方法透過確保對人體及相關安全危害進行準確且可靠的識別，能為工業人機協作（HRC）環境中的人員安全做出重大貢獻。本論文的主要貢獻如下：

提出了一種用於分割 3D 稀疏點雲（sparse point cloud）的領域自適應（domain adaptation）演算法。

發布了用於領域自適應的數據集，其中包含真實數據與模擬數據。

這預計將成為首個應用於即時且真實 HRC 場景的領域自適應（Domain Adaptation）演算法，並已在真實世界的實驗室設置中完成測試。

本文其餘章節安排如下：第二節回顧 3D 點雲數據語義分割與 Sim2Real 領域自適應的相關研究；第三節說明所提出的方法論；第四節展示實驗結果；最後，第五節針對研究發現與影響進行討論，並提出未來研究的可能方向。

2 相關研究

2.1 點雲語義分割：HRC 的技術與挑戰

3D LiDAR（光學雷達）點雲的語義分割旨在為每個點分配一個語義標籤，而點雲數據通常具有稀疏且無序的特性 [9]。此任務最常見的策略 [10] 包括基於投影（projection-based）[11-14]、基於體素（voxel-based）[15, 16] 以及基於點（point-based）[17-19] 的方法。深度學習在此領域的研究取得了顯著進展，特別是能夠直接處理原始點雲數據的 PointNet [20] 與 PointNet++ [21] 架構。隨後的進一步發展，如 PointCNN [22] 與 DGCNN [23]，則引入了類卷積運算，增強了局部結構與幾何特徵的擷取能力。然而，這些模型的訓練主要依賴於理想的模擬數據，因此由於領域偏移（domain shift）的影響，其在現實世界中的應用性可能會受到限制。

點雲表示法能夠在不進行離散化的情況下，保留 3D 空間中原始的幾何資訊，因此在現實世界的應用中受到了廣泛關注，包括自動駕駛 [5, 24-29]、導航 [30] 以及機器人 [31] 等應用。直接將點雲轉換為稀疏向量表示是一種基於點的方法，它結合了每個點的鄰域特徵。該領域的多項研究已在各種基準數據集上取得了令人印象深刻的性能。KPConv 算子 [29] 與 RandLA-Net 網路 [32] 在大規模點雲分割中表現優異，並透過減少數據冗餘和自適應採樣技術，提升了記憶體效率與運算資源的利用。儘管有這些進展，但在 HRC 應用中對語義理解的關注仍顯不足，大多數 HRC 研究 [33, 34] 仍集中在基於影像的數據。HRC 的最新發展則專注於感知與控制機制，以及人因工程（Human Factors, HF）的整合，以提升協作環境中的安全性與效率。

在感知部分，先前的研究 [35-37] 對多模態人機互動進行了全面回顧，強調整合視覺、聽覺與觸覺回饋等多種感測輸入，以增強情境覺知與互動品質。此外，Lin 等人 [38] 考慮將先驗資訊與模擬數據結合以改進點雲分割，為提升語義分割準確性提供了寶貴見解。雖然這種多模態數據融合在複雜場景識別方面具有潛力，但提升即時處理能力、魯棒性與安全性，仍是亟待解決的關鍵挑戰。

在此背景下，近期的研究重點在於將人因工程（Human Factors, HF）整合至分割模型中，以增強這些系統的安全性和穩健性 [39, 40]。HF 確保分割模型能專注於與安全相關的關鍵區域 [41, 42]，例如識別共享工作空間中的人員或危險物品 [43]。另一方面，缺乏精確的 3D 資訊是一個重大缺陷，因為這對於準確偵測物體位置至關重要，進而對確保人機互動中的安全起到關鍵作用 [3]。這種缺陷可能導致潛在的傷害 [44]，因此需要嚴格的工業機器人工作站設計以確保符合安全標準 [45]。缺乏工業基準數據集是該研究領域的一個主要缺點。

此外，為每個新任務收集並標註大型數據集既昂貴又耗時，且在擴展性上並不切實際。典型場景通常涉及使用來自另一個領域的訓練數據來執行該領域的偵測任務，這會導致特徵空間或數據分佈出現潛在差異。研究社群已提出多種技術來促進領域間的知識轉移，以抵消性能下降，其中大多數方法集中在 2D 攝影機影像的領域自適應（Domain Adaptation）技術 [8]。

在本文提出的 HRC 分割任務中，由於任務的複雜性和特殊性，並未使用非監督式學習（Unsupervised learning），這可能需要標註數據以確保模型能學習到與人機互動分割直接相關的特徵和模式 [46]。

2.2 基於 LiDAR 的數據集

LiDAR 技術的進步及其在機器人、自動駕駛車輛和環境研究等領域的日益普及，取得了巨大的成就。隨著這些發展，出現了如 S3DIS [47]、Semantic3D [48] 和 SemanticKITTI [49] 等資料集，分別專為自動駕駛車輛以及大規模室內外建模而設計。然而，專門為人機協作（HRC）環境設計的資料集仍存在明顯的缺口。直到最近，市場上仍缺乏針對此類環境量身打造的公開資料集。

為了填補這一空白，我們推出了 COVERED 資料集 [50]。COVERED 資料集利用多個 LiDAR 感測器，在滿足 HRC 環境需求方面取得了重大進展。它捕捉了人類與機器人之間的多種互動情境，這些情境涵蓋了互動、觀察、路過以及自主運作。該資料集納入了協作動態、人類行為的多變性、機器人與 AGV 配置等元素。

COVERED 資料集存在一定的局限性，主要源於人類安全與倫理限制，這使得某些對於有效訓練機器人系統至關重要的危險情境無法在真實環境中執行。為了克服這一點，模擬資料集的使用已納入考量。模擬提供了一個安全的平台，可以在無風險的情況下研究潛在的危險狀況，為系統性的變數分析提供受控環境。

模擬環境結合來自多 LiDAR 感測器的真實世界數據，為機器人執行 HRC 任務提供了強大的解決方案。COVERED 資料集提供了廣泛的現實情境，而模擬則允許對邊緣案例（edge cases）、靈活情境和潛在危害進行調查。兩者結合，能使人機協作的機器人系統更加可靠且安全。

2.3 點雲的領域自適應 (Domain Adaptation)

Sim2Real 領域自適應的概念作為遷移學習的一種特定形式，已成為解決上述問題並減輕模型應用於不同領域時效能下降（此現象稱為領域偏移，domain shift）的解決方案。領域自適應旨在彌合來源領域（source domain）與目標領域（target domain）之間的差距。根據目標領域與來源領域數據的可取得性，這可以分為三大類 [8]：

非監督式遷移學習 (unsupervised transfer learning)，即不使用任何標註數據；

轉導式遷移學習 (transductive transfer learning)，即僅在來源領域中提供標註數據；

歸納式遷移學習 (inductive transfer learning)，其中目標領域 (target domain) 具備可用的標註資料。

儘管 Sim2Real 電腦視覺技術的進步提升了模型從合成影像到真實影像的效能，但在工業環境中針對 3D 點雲語義分割的 Sim2Real 領域自適應 (domain adaptation) 研究仍有待開發。

多位研究人員提出了獨特的方法來解決此領域差距 (domain gap)。Li 等人 [51] 開發了一種領域自適應方法，用以彌合自動駕駛中不同 LiDAR 感測器所取得 3D 點雲之間的差距。Jia 等人 [52] 研究了自動駕駛與移動機器人應用之間的領域差距，以增強移動機器人在人群環境中的導航能力。Langer 等人 [53] 則針對缺乏新感測器設置標註資料的情況，提出了一種用於語義理解的 real-to-real 領域自適應技術（針對不同感測器數據）。

此外，Zhao 等人 [54] 針對 LiDAR 點雲分割提出了 ePointDA，這是一個端到端的模擬到真實領域自適應 (SRDA) 框架，旨在彌合基於模擬影像的數據與真實 LiDAR 數據之間的領域偏移 (domain shift)。Yi 等人將汽車與行人的 LiDAR 採樣領域差距視為表面補全 (surface completion) 任務來處理。最後，Jiang 與 Saripalli [55] 針對自動駕駛任務提出了一種邊界感知 (boundary-aware) 的領域自適應方法，並推出了一個新的 LiDAR 資料集 SemanticUSL，其中包含由移動機器人擷取的交通道路、人行道和越野場景等多元情境。

在工業環境中，3D 點雲資料的語義分割 (semantic segmentation) 在製程優化與機器人技術中具有至關重要的應用 [56-58]。


儘管已有上述研究，但將這些技術應用於增強工業情境與人機協作 (HRC) 中的 3D 點雲資料語義分割仍處於起步階段。本文旨在以此研究基礎為核心，進一步探索遷移學習 (transfer learning) 與領域自適應 (domain adaptation) 在解決工業 3D 點雲語義分割特有的資料匱乏問題上的有效性。本文對這些技術進行了深入探討，重點關注模擬場景與真實世界的評估，旨在為工業應用開發出強健、準確且高效的模型。

3 方法論 (Methodology)


在本研究中，引入了一種 Sim2Real 領域自適應方法，以增強人機協作 (HRC) 環境中的語義理解。圖 1 展示了真實世界與模擬環境的範例資料集。顯而易見地，模擬環境中的物件品質明顯高於真實世界。此方法論利用雙流網路架構（稱為 FUSION）來平行分析點雲，如圖 3 所示。首先，建立了一個緊密模擬真實工業設置的模擬資料集。此模擬環境作為網路的主要訓練場地，使其能夠學習並適應真實環境。隨後應用領域自適應技術，將模型的學習從模擬資料集轉換至真實世界的應用。網路的效能針對離線與線上分割進行了嚴格的評估。

3.1 合成資料集

模擬平台使得應對機器人技術中固有的挑戰成為可能，特別是獲取多樣化、具備標註的真實世界資料。在本研究中，我們使用 NVIDIA 開發的高階機器人模擬平台 IsaacSim [59] 建立了一個合成點雲資料集。



(a) Safe Interaction vs Dangerous Interaction



(b) Real World

圖 2：模擬與真實世界設置

透過在模擬中改變多個參數（例如物體姿態與配置），生成了多樣化且逼真的場景。機器人模型、AGV 以及操作人員的呈現被放置在各種位置與方向，並精心挑選其互動方式，以展示工業環境中可能出現的真實世界場景。潛在危險的同時也建立了在現實世界數據集中可能不常出現或缺失的情境。此數據集旨在模擬受限於現實環境安全法規的特定危險狀況。

合成數據集由 300 個點雲組成，每個點雲反映了機器人、人類與環境元素之間不同的互動情境。這些代表了在人機協作環境中可能出現的多種現實場景。

值得注意的是，此合成數據集經過精心建構，以與我們先前發布的現實世界數據集 COVERED [50] 保持一致。COVERED 數據集的初始版本包含 215 個數據樣本，分為 5 個不同的類別：「Floor」（地板）、「Wall」（牆壁）、「Robot」（機器人）、「Human」（人類）和「AGV」（自動導引車）。在最新的數據集標註更新中，我們引入了兩個額外類別：「Assembly Line」（組裝線）和「Table」（桌子），並增加了約 350 個數據樣本，進一步豐富了數據集的多樣性與適用性。這些增強功能已反映在我們 GitHub 儲存庫¹上的更新版 COVERED 數據集中。

為了全面了解現實世界數據的收集方法與設置，建議參閱文獻 [50]，該文獻概述了用於收集構成目標域（target domain）基礎數據的程序與技術。所收集的合成數據集旨在複製這些現實世界條件，並作為本研究的源域（source domain）。透過將合成數據與現實世界條件對齊，增強了該數據集在領域自適應（domain adaptation）策略中的實用性。

此合成資料集的建立，突顯了致力於強化機器人研究領域高品質資源可用性的決心。其目標是使該資料集成為機器人各個領域（如感知、導航和人機互動）中演算法開發、測試與改進的價值工具。此外，透過將其與我們的真實世界資料集對齊，此合成資料集為推進領域自適應（domain adaptation）研究並解決工業數據匱乏的挑戰提供了獨特的機會，進而可能提升模型性能與人類安全（透過偵測危險互動）。這項進展將極大地支持機器人應用從受控的模擬環境轉移到真實世界場景。圖 2 展示了模擬生成的合成資料集與真實世界設置之間的相似性，並顯示了將模擬數據無縫整合到真實世界應用中的潛力。

3.2 資料預處理

所提出的預處理階段包含幾個關鍵步驟，並統一應用於來源（合成）與目標（真實世界）點雲資料集。首先，對資料集進行零中心化（zero-centered）與正規化（normalized），將所有輸入特徵帶入相同的數值範圍。此過程對於神經網路訓練至關重要，因為它能加速收斂，並防止任何單一特徵因其尺度而對模型產生不成比例的影響。接著，進行超參數調優（hyperparameter tuning）以優化網路性能。透過在預定數值範圍內進行系統化搜尋，確定了在驗證集上表現最佳的超參數。

我們努力確定 K-最近鄰（KNN）演算法的最佳 k 值，並探索了點雲複雜度與密度如何與此最佳 k 值相關聯。透過測試發現，最佳 k 值會受到點雲複雜度與密度的影響。

具體而言，在 COVERED 資料集中（包含平均密度為 11,000 個點且複雜度各異的點雲），較低的 k 值（如 $k = 10$ ）在分割準確度方面始終優於較高的值（如 $k = 20$ ），並證明透過聚焦於最相關的鄰近點能更有效地運作。

在生成初始資料集之後，採用了資料增強（Data Augmentation）技術來增加其豐富度與多樣性。隨機翻轉、縮放、旋轉和雜訊注入等技術被用於創造資料的變體。每個增強後的樣本都保留了原始版本的標籤，確保每個實例都有準確的地面真值（Ground Truth）。資料增強不僅增加了訓練增強資料的數量，還透過呈現各種場景和條件來提高模型的魯棒性（Robustness）。

最後，對點雲進行下採樣（Downsampling），使每個點雲的初始點數達到 11,000 個。此數量是由系統有效訓練網路的能力所決定的。為了優化此過程，根據物件的性質採用了不同的下採樣率：牆壁和地板等靜態物件以 10 : 1 的速率進行下採樣（每十個點保留一個），而動態物件則以 2 : 1 的速率進行下採樣。這種差異化方法確保了能以更詳盡的細節捕捉關鍵的動態互動，從而增強模型在現實場景中的訓練效果及最終性能。

3.3 網路架構

在本節中，我們介紹了一種名為 FUSION 的新型雙流網路，旨在解決點雲語義分割並執行領域自適應（domain adaptation）任務。該網路獨特地結合了動態圖形卷積神經網路（DGCNN）[23] 與具備殘差連接的卷積神經網路（CNN-residual）的優勢。

第一條串流利用了 DGCNN 處理點雲數據的能力。來自 DGCNN 的邊緣卷積操作（EdgeConv）以其透過考慮點與其鄰居之間的關係來捕捉局部幾何結構的能力而聞名，非常適合用於點雲數據。給定點雲 P 中的一個點 p 及其透過 knn 確定的 k 個最近鄰居，EdgeConv 會考慮由點與其鄰居之間的關係所形成的邊緣特徵。在數學上，點 p 及其鄰居 q 的邊緣特徵 h 表示為：

$$h(p, q) = \phi(p - q)$$

其中 ϕ 是一個對點之間的相對空間位置進行編碼的函數。在此網路中，EdgeConv 操作定義為：

$$h'_i = \max_{j:(i,j) \in \mathcal{E}} \Theta \cdot (h_i \oplus (h_j - h_i))$$




圖 3: FUSION 網路：結合 DGCNN 與 CNN-residual 的雙流網路架構。

其中 h_i 與 h_j 分別是點 i 與 j 的特徵向量， $\mathcal{E}$ 代表圖 (graph) 中的邊， Θ 表示網路的可學習參數，而 $\oplus$ 則表示串接 (concatenation)。圖結構在每一層都會進行自適應更新，使得鄰域資訊的計算具有動態性。這種基於動態圖的方法能有效學習幾何與空間特徵，進而對複雜的點雲結構達成穩健的理解。

它還具備對平移與旋轉等特定轉換的不變性。這使得模型能夠捕捉並學習點雲數據中的複雜細節，例如傳統 CNN 經常忽略的密度變化與不規則格式。

作為 DGCNN 的補充，第二條串流結合了具有殘差連接 (residual connections) 的 CNN。殘差連接的整合有助於學習低階與高階的特徵階層，從而增進對各種數據集中輸入數據的理解與處理能力。此外，每隔兩層加入的殘差連接有助於緩解梯度消失問題，使網路能夠有效地學習更深層次的表示。

$$y = F(x) + x$$

在此， $F(x)$ 代表網路學習到的殘差映射，而 x 是殘差區塊 (residual block) 的輸入。這種結構允許梯度更有效地在網路中流動，從而解決梯度消失問題。具體而言，在 CNN 殘差串流中，每個殘差區塊由兩個卷積層組成：

$$F(x) = \text{ReLU}(\text{Conv 2d}(\text{ReLU}(\text{Conv 2d}(x))))$$

透過結合 DGCNN 與 CNN-residual，本研究提出的網路在點雲語義分割以及工業應用場景中的領域自適應 (domain adaptation) 任務上，皆展現了卓越的效能。藉由學習底層幾何結構並利用殘差連接 (residual connections)，此網路為點雲處理任務提供了一個強大的解決方案。它實現了合成數據集與真實世界數據集之間的高效知識轉移，為機器人應用在多樣化真實場景中的實際部署鋪平了道路。

圖 3 展示了所提出的 Fusion 架構。此圖直觀地總結了該網路的雙流 (dual-stream) 特性，並提供了對其功能的直觀理解，同時演示了 DGCNN 與 CNN-residual 部分如何協同工作。每個 2D 卷積層都配有批次正規化 (batch normalization) 操作，以提高訓練穩定性並加快收斂速度。在殘差流中使用 ReLU 能夠透過強大的非線性實現高效訓練並防止梯度消失；而在 DGCNN 流中採用 Leaky ReLU，則能防止神經元飽和並有效處理變動的輸入分佈，確保從動態圖結構數據中進行穩健學習。

4 實驗結果

本節展示了將網路部署於真實世界數據的結果，並針對目前最先進的演算法進行效能基準測試。透過標準化所有評估方法的測試條件，確保了比較的公平性。最終，該網路也在即時場景中進行了測試，以證明其在動態環境中的實際應用性與有效性。此測試旨在驗證所提方法在受控與實況條件下的魯棒性 (robustness) 與可靠性。

4.1 實驗設置

在實驗設置中，80% 的數據分配用於訓練，20% 用於評估。此外，在測試階段，使用了 25 個樣本進行微調，並使用 81 個真實世界數據樣本進行最終測試。系統配置包括 NVIDIA RTX 8000 GPU 搭配 Intel® Xeon® Gold 6256 CPU，為訓練此複雜模型提供了強大的基礎。此配置促進了訓練過程的順暢，並將延遲降至最低。

在訓練過程中，使用交叉熵損失 (cross-entropy loss) 作為分割損失，以引導網路達到最佳解。採用 Adam (Adaptive Moment Estimation) 優化器是因為其效率高且記憶體需求低。學習率初始設定為 0.001，並在訓練過程中根據學習率排程 (餘弦衰減, Cosine decay) 逐漸降低。

4.2 FUSION 效能

在實驗結果中，觀察到一個與該領域更廣泛挑戰一致的現象，即所謂的「Sim-to-Real Gap」(模擬與現實的差距)。當比較在模擬數據集上訓練的機器學習模型效能與其在現實環境中的有效性時，這種差距變得尤為明顯。此差距源於環境複雜度、數據差異、感測器精度、光照條件、物體變異性等因素的差異。這些不一致性凸顯了將模擬模型應用於真實世界情境的挑戰。

首先，該網路僅使用模擬數據進行訓練，達到了令人印象深刻的 98.9% 準確度。然而，將此模型直接部署於真實世界時，此方法的初始語義分割準確度僅為 45%。這種顯著的差異清楚地表明了「Sim-to-Real Gap」的存在。為了縮小這種分歧，我們採用了數據增強 (Data Augmentation) 和微調 (Fine-tuning) 等領域自適應 (Domain Adaptation) 技術。數據增強為我們的模擬數據集引入了多樣性，使其更能代表現實世界的複雜性。

在微調 (fine-tuning) 過程中，模型透過學習一組小規模的真實世界數據 (僅 25 個樣本) 進行改進。在達成此目標的同時，模型仍保留了原始模擬數據訓練中的知識。此過程最引人注目之處在於，它使模型的準確度大幅提升了 52.7%。

針對真實世界數據的評估，我們維持了相同的分類方案，確保資料集包含相同的七個類別：Robot (機器人)、Human (人類)、Wall (牆壁)、Floor (地板)、Assembly Line (裝配線)、Table (桌子) 以及 AGV (自動導引車)。此微調策略的一個重要面向是決定凍結並固定前層的參數，僅保留最後兩個全連接層 (fully connected layers) 進行調整。這確保了這些參數在重新訓練與微調階段保持不變。

凍結前層參數的優勢在於能夠保留初始訓練期間獲得的專業知識，同時使模型能夠針對特定的目標領域獲取新的見解。

當前層的參數被凍結時，它們會受到保護，免於進一步的訓練或變動。這確保了模型不會遺忘已經學到的內容。同時，這也讓模型有機會專注於獲取專為當前任務量身定制的新見解。這種做法能將模型對過往經驗的利用率最大化，同時使其具備適應新挑戰的能力。

這些努力的成果確實非常顯著。當使用包含七個類別的真實世界數據進行評估時，該模型達到了 97.92% 的準確率；而在考慮完整的八個類別時，準確率則為 97.67%。這強調了微調（fine-tuning）過程的成效，以及其將模型適應於真實世界場景並產生高準確度結果的能力。

這項經驗凸顯了採用 Sim2Real 差距緩解技術的重要性，以提高機器學習模型應對真實世界挑戰的適應性。它展示了彌合模擬與現實之間差距的真正潛力，使模型能夠在複雜的真實世界中表現出色。

4.3 效能評估

在本研究中，我們將 FUSION 演算法的效能與幾種尖端演算法進行比較，以確定其在各項指標上的有效性。在評估效能時，我們不僅檢查了總體準確率（Overall Accuracy）、每類準確率（Per-class Accuracy）和平均交併比（Mean Intersection over Union, IoU）等關鍵指標，還考慮了運算時間，這是實際應用中至關重要的一環。總體準確率（OA）作為主要指標，衡量了在總數據集中被正確預測的數據點比例。

表 1：不同演算法的類別 IOU							
演算法	類別 IOU						
	機器人	人員	牆壁	地面	組裝線	表格	AGV
RandLaNet	0.930	0.930	0.953	0.937	0.957	0.880	0.992
PointNet	0.858	0.692	0.904	0.899	0.914	0.870	0.545
DGCNN	0.912	0.699	0.957	0.908	0.959	0.853	0.571
CNN-Residual	0.909	0.829	0.966	0.924	0.960	0.841	0.772
FUSION (本研究)	0.955	0.943	0.974	0.947	0.978	0.923	0.922

表 2：演算法比較				
演算法	指標			時間 (秒)
	整體準確度 (Overall Acc.)	各類別準確度 (Per-class Acc.)	平均交併比 (mIoU)	
RandLaNet	96.34	-	0.944	0.281
PointNet	91.17	88.69	0.856	0.163
DGCNN	93.15	89.94	0.881	0.090
CNN-Residual	94.45	87.84	0.904	0.035
FUSION (本研究)	97.76	96.82	0.954	0.115

交集並分比（Intersection over Union, IoU）衡量兩個集合之間的重疊程度，常用於物件偵測或分割的場景：

$$IoU = \frac{\text{Area_of_Overlap}}{\text{Area_of_Union}} = \frac{TP}{TP + FP + FN}$$

其中：
TP = 真陽性（True Positives，預測正確的點）。
FP = 偽陽性（False Positives，預測錯誤的點）。
FN = 偽陰性 (False Negatives，遺漏的點)
平均交併比 (Mean Intersection over Union, mIoU) 是多個類別或實例的 IoU 平均值：

$$mIoU = \frac{1}{N} \sum_{i=1}^N IoU_i$$

其中：
 N = Number of classes or instances
 IoU_i = IoU for class or instance i

表 1 與表 2 呈現的結果，針對不同演算法的這些指標進行了比較分析。在表 2 中，對各種演算法進行了全面比較，以評估其在 Sim2Real 分割任務中的效能。

Ground truth	RandLaNet	PointNet	DGCNN	CNN-Residual	FUSION (本研究)
Robot Human		Operator AGV	表格	牆壁 地板	未標記

表 3：圖 4：各網路的分割結果，人體分割之比較；綠色矩形表示成功且完整的分割，而紅色矩形則表示欠佳或不準確的分割。

任務。如圖 4 所示，顯而易見地，除了 AGV 分割中 RandLaNet 演算法略勝一籌外，所提出的網路在所有類別（尤其是人體）的表現均優於其他所有方法（「未標記」類別代表點雲中缺乏明確結構資訊或與分割類別無關的區域）。雖然 RandLaNet 在 AGV 分割上的表現略優於 FUSION，但這可歸因於其高效的多尺度採樣和空間一致性，能更好地捕捉像 AGV 這樣的剛性結構。相比之下，FUSION 則針對人體和機器人等複雜且細節豐富的物件進行了優化。




圖 4：圖 5：人機協作（HRC）工業應用中的即時分割結果，包含兩種實驗室設置

這種人體分割至關重要，特別是在工業場景中，精確的人體分割對於安全維護具有決定性作用，例如彈性自動化流程中的人機協作。這些結果顯示，所提出的模型在 Sim2Real 分割領域具有巨大潛力，特別是在需要精確人體偵測的場景中。

此外，該模型在處理速度上展現了顯著的提升，其預測時間僅需頂尖競爭演算法（RandLaNet）的 40%。這種差異在人機協作（HRC）情境中非常重要，因為快速的處理與決策對於流暢且安全的人機互動至關重要。這種 FUSION 方法不僅維持了具競爭力的準確度，在運作效率上更是表現卓越，使其更適用於對快速反應時間有嚴苛要求的即時應用。

4.4 即時結果

在本研究中，我們使用兩種不同的實驗室設置來評估 FUSION 網路在即時場景中的效能，每種設置皆配備了兩個 LiDAR 感測器。為了增強點雲的全面性，我們將來自兩個 LiDAR 感測器的數據進行合併，從而獲得更完整的點雲表示。所得結果令人滿意，證明了該網路在處理真實世界數據方面的功效。觀察結果顯示，預測時間加上視覺化處理平均約為 0.19 秒（優化前的語義分割視覺化請參考此影片²）。

視覺化被公認為是耗時的組件，在真實世界的場景中並不總是必要的。為了優化此過程，我們實施了一項策略，在初始分割後，將地板和牆壁等靜態物體從後續的視覺化中排除。

此外，我們採用了體素大小（voxel size）為 0.05 的下採樣（downsampling），成功將處理時間縮短至 0.098 秒，其中分割與預處理

耗時 0.073 秒（優化後的語義分割視覺化請參考此影片³）。這項優化不僅提高了效率，還突顯了所提方法對動態真實世界環境的適應性。

圖 5 提供了 FUSION 網路在兩種實驗室設置中所取得分割結果的全面視覺化呈現。這些結果對於評估網路性能及其準確區分環境中各種物體與特徵的能力至關重要。在 Lab 1 中，分割結果顯示了對 Human、Robot、AGV 和 Assembly line 等物體的精確識別，展示了該網路在區分不同類別方面的有效性。值得注意的是，兩個實驗室的分割結果均展現出一致性與可靠性，突顯了 FUSION 網路在多樣化真實場景中的強健性（robustness）。這些視覺化結果為網路的能力提供了寶貴的見解，並作為其在即時應用中有效性的關鍵驗證。

5 結論與展望

本研究解決了工業環境下 3D 點雲數據語義分割中 Sim2Real 領域自適應（domain adaptation）的挑戰，並特別強調真實世界的性能表現。工業設置本質上非常複雜，其特點是物體多樣、配置動態且存在不可預測的運動，這需要模型具備強健的真實世界性能。

本研究指出，在彌合模擬數據與真實世界數據之間的領域偏移（domain shift）方面存在顯著差距，這是將機器學習模型有效部署於如 HRC 場景等安全至關重要的工業環境中的主要障礙。

為了彌補這一差距，本研究提出了 FUSION 網路，這是一種結合了動態圖形卷積神經網路（DGCNN）與具備殘差連接的卷積神經網路（CNN-residual）優勢的雙流架構（dual-stream architecture）。此方法利用模擬數據進行初步訓練，隨後針對真實世界的部署進行適應。透過對模擬與真實工業數據集的全面評估，證實了該網路的能力。

採用雙流設計的決策是基於所選兩種網路的獨特優勢。DGCNN 能有效捕捉局部幾何細節，而 CNN-residual 則能處理邊緣、紋理等基礎特徵以及物件表示等高階特徵階層，並有助於解決梯度消失問題。這種結合確保了在從模擬到真實條件的挑戰性轉換過程中，能擁有卓越的性能表現。

總結來說，本文透過「FUSION」雙流網路設計，為彌合模擬與真實工業環境之間的差距做出了貢獻。儘管該領域存在挑戰，實際結果顯示所提方法具有巨大潛力，且優於以往的研究。隨著工業領域適應（domain adaptation）技術的不斷演進，此架構為未來的改進提供了強大且具適應性的基礎。

6 限制與未來工作

雖然本研究展現了令人期待的結果，但仍須正視某些我們旨在未來解決的局限性。我們使用了 Nvidia IsaacSIM 平台，該平台在模擬工業場景方面具有價值，但在準確複製現實世界的動態面向時仍具挑戰性。這種局限性在涉及機器人、人類與動態物體之間互動的場景中尤為明顯。值得注意的是，該軟體無法為動態物體渲染點雲。因此，我們利用人形物體作為真人的替代品，並在每次模擬中手動調整機器人的路徑規劃。

未來的工作將著重於增強模擬能力或探索替代平台，以更好地複製現實世界的動態，從而將更多樣化且動態的元素整合到我們的資料集中。此外，涉及人機協作的關鍵場景（其中與機器人協作的人類工作者安全至關重要）將被優先考慮，特別是在建模與緩解潛在危險情況方面。

為了提高效率，我們旨在將雙流模型（dual-stream model）的運算平行化，從而顯著縮短分割時間並提高反應速度。探索兩個網路流更深層的整合、用於精細特徵提取的注意力機制（attention mechanisms），以及擴展資料集以涵蓋更廣泛的工業環境，將進一步增強我們方法的穩健性與適用性。

參考文獻

- [1] Olender, M., Banas, W.: Cobots-future in production. *International Journal of Modern Manufacturing Technologies, Special Issue, XI 3*, 103-109 (2019)
- [2] Vicentini, F.: Collaborative robotics: a survey. *Journal of Mechanical Design* 143(4), 040802 (2021)
- [3] Mohammadi Amin, F., Rezayati, M., Venn, H.W., Karimpour, H.: A mixed perception approach for safe human-robot collaboration in industrial automation. *Sensors* 20(21), 6347 (2020)
- [4] Hamon, R., Junklewitz, H., Sanchez, I.: Robustness and explainability of artificial intelligence. Publications Office of the European Union (2020)
- [5] Milioto, A., Vizzo, I., Behley, J., Stachniss, C.: Rangenet : Fast and accurate lidar semantic segmentation. In: 2019 *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 4213-4220 (2019). <https://doi.org/10.1109/IROS40897.2019.8967762>
- [6] Guo, Y., Liu, Y., Georgiou, T., Lew, M.S.: A review of semantic segmentation using deep neural networks. *International journal of multimedia information retrieval* 7(2), 87-93 (2018)
- [7] Gao, B., Pan, Y., Li, C., Geng, S., Zhao, H.: Are we hungry for 3d lidar data for semantic segmentation? *CoRR abs/2006.04307* (2020)
- [8] Triess, L.T., Dreissig, M., Rist, C.B., Zöllner, J.M.: A survey on deep domain adaptation for lidar perception. *CoRR abs/2106.02377* (2021) 2106.02377
- [9] Wang, X., Jr., M.H.A., Lee, G.H.: Cascaded refinement network for point cloud completion. *CoRR abs/2004.03327* (2020)
- [10] Guo, Y., Wang, H., Hu, Q., Liu, H., Liu, L., Bennamoun, M.: Deep Learning for 3D Point Clouds: A Survey (2020)
- [11] Yang, Z., Wang, L.: Learning relationships for multi-view 3d object recognition. 於: 2019 *IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 7504-7513 (2019). <https://doi.org/10.1109/ICCV.2019.00760>
- [12] Ma, L., Stückler, J., Kerl, C., Cremers, D.: Multi-view deep learning for consistent semantic mapping with RGB-D cameras. *CoRR abs/1703.08866* (2017)
- [13] Wu, B., Zhou, X., Zhao, S., Yue, X., Keutzer, K.: Squeezesegv2: Improved model structure and unsupervised domain adaptation for road-object segmentation from a lidar point cloud. In: 2019 *International Conference on Robotics and Automation (ICRA)*, pp. 4376-4382 (2019). *IEEE*
- [14] Milioto, A., Vizzo, I., Behley, J., Stachniss, C.: Rangenet: Fast and accurate lidar semantic segmentation. In: 2019 *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 4213-4220 (2019). *IEEE*
- [15] Zhou, Y., Tuzel, O.: Voxelnet: End-to-end learning for point cloud based 3d object detection. *CoRR abs/1711.06396* (2017)
- [16] Meng, H., Gao, L., Lai, Y., Manocha, D.: Vv-net: Voxel VAE net with group convolutions for point cloud segmentation. *CoRR abs/1811.04337* (2018)
- [17] Zhang, Z., Hua, B., Yeung, S.: Shellnet: Efficient point cloud convolutional neural networks using concentric shells statistics. *CoRR abs/1908.06295* (2019)
- [18] Huang, Q., Wang, W., Neumann, U.: Recurrent slice networks for 3d segmentation on point clouds. *CoRR abs/1802.04402* (2018)
- [19] Landrieu, L., Simonovsky, M.: Large-scale point cloud semantic segmentation with superpoint graphs. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (2018)
- [20] Qi, C.R., Su, H., Mo, K., Guibas, L.J.: Pointnet: Deep learning on point sets for 3d classification and segmentation. *CoRR abs/1612.00593* (2016)
- [21] Qi, C.R., Yi, L., Su, H., Guibas, L.J.: Pointnet++: Deep hierarchical feature learning on point sets in a metric space. *CoRR abs/1706.02413* (2017) 1706.02413
- [22] Li, Y., Bu, R., Sun, M., Chen, B.: Pointcnn. *CoRR abs/1801.07791* (2018) 1801.07791
- [23] Wang, Y., Sun, Y., Liu, Z., Sarma, S.E., Bronstein, M.M., Solomon, J.M.: Dynamic graph CNN for learning on point clouds. *CoRR abs/1801.07829* (2018) 1801.07829
- [24] Aksoy, E.E., Baci, S., Cavdar, S.: Salsanet: Fast road and vehicle segmentation in lidar point clouds for autonomous driving. *CoRR abs/1909.08291* (2019)
- [25] Wu, B., Wan, A., Yue, X., Keutzer, K.: Squeezeseg: Convolutional neural nets with recurrent CRF for real-time road-object segmentation from 3d lidar point cloud. *CoRR abs/1710.07368* (2017)
- [26] Zeng, Y., Hu, Y., Liu, S., Ye, J., Han, Y., Li, X., Sun, N.: Rt3d: Real-time 3-d vehicle detection in lidar point cloud for autonomous driving. *IEEE Robotics and Automation Letters* 3(4), 3434-3440 (2018) <https://doi.org/10.1109/LRA.2018.2852843>
- [27] Cortinhal, T., Tzelepis, G., Aksoy, E.E.: Salsanet: Fast semantic segmentation of lidar point clouds for autonomous driving. *CoRR abs/2003.03653* (2020)
- [28] Cheng, R., Razani, R., Taghavi, E., Li, E., Liu, B.: (af)2-s3net: Attentive feature fusion with adaptive feature selection for sparse semantic segmentation network. *CoRR abs/2102.04530* (2021)
- [29] Thomas, H., Qi, C.R., Deschaud, J.-E., Marcotegui, B., Goulette, F., Guibas, L.J.: Kpconv: Flexible and deformable convolution for point clouds. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 6411-6420 (2019)
- [30] Feng, D., Rosenbaum, L., Dietmayer, K.: Towards safe autonomous driving: Capture uncertainty in the deep neural network for lidar 3d vehicle detection. *CoRR abs/1804.05132* (2018)
- [31] Zha, Fu, J., Wang, Zhaoyu, G., Yin-Sheng, L., Yidong, C.: Semantic 3d reconstruction for robotic manipulators with an eye-in-hand vision system. *Applied Sciences* 10, 1183 (2020) <https://doi.org/10.3390/app10031183>
- [32] Hu, Q., Yang, B., Xie, L., Rosa, S., Guo, Y., Wang, Z., Trigoni, N., Markham, A.: Randla-net: Efficient semantic segmentation of large-scale point clouds. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 11108-11117 (2020)

- [33] Fan, J., Zheng, P., Li, S.: Vision-based holistic scene understanding towards proactive human-robot collaboration. *Robotics and Computer-Integrated Manufacturing* (2021) <https://doi.org/10.1016/j.rcim.2021.102304>
- [34] Angleraud, A., Ekrekli, A., Samarawickrama, K., Sharma, G., Pieters, R.: Sensor-based human-robot collaboration for industrial tasks. *Robotics and Computer-Integrated Manufacturing* 86, 102663 (2024) <https://doi.org/10.1016/j.rcim.2023.102663>
- [35] Su, H., Qi, W., Chen, J., Yang, C., Sandoval, J., Laribi, M.A.: 多模態人機互動的最新進展 (Recent advancements in multimodal human-robot interaction). *Frontiers in Neurorobotics* 17 (2023) <https://doi.org/10.3389/fnbot.2023.1084000>
- [36] Liu, J., Luo, H., Wu, D.: 營建業中的人機協作：機器人設計、感知與互動，以及任務分配與執行 (Human-robot collaboration in construction: Robot design, perception and interaction, and task allocation and execution). *Advanced Engineering Informatics* 65, 103109 (2025) <https://doi.org/10.1016/j.aei.2025.103109>
- [37] Duan, J., Zhuang, L., Zhang, Q., Zhou, Y., Qin, J.: 製造業中的多模態感知-融合-控制與人機協作：綜述 (Multimodal perception-fusion-control and human-robot collaboration in manufacturing: a review). *The International Journal of Advanced Manufacturing Technology* 132, 1-23 (2024) <https://doi.org/10.1007/s00170-024-13385-2>
- [38] Lin, J., Zhong, K., Gong, T., Zhang, X., Wang, N.: 人機互動場景下用於點雲分割的先驗資訊輔助神經網路 (Prior information-assisted neural network for point cloud segmentation in human-robot interaction scenarios). *IEEE Robotics and Automation Letters* 9(5), 4186-4193 (2024) <https://doi.org/10.1109/LRA.2024.3376974>
- [39] Alharasees, O., Adali, O.H., Kale, U.: 自主無人機時代的人因工程：人工智慧對操作員績效與安全的影響，第 798-805 頁 (2023). <https://doi.org/10.1109/ICUAS57906.2023.10156037>
- [40] de Nobile, A., Bibbo, D., Russo, M., Conforto, S.: 關注協作機器人中評估人因工程的定量方法。《International Journal of Industrial Ergonomics》104, 103663 (2024) <https://doi.org/10.1016/j.ergon.2024.103663>
- [41] Chen, H., Li, S., Fan, J., Duan, A., Yang, C., Navarro-Alarcon, D., Zheng, P.: 智慧製造中的人機迴路機器人學習：以人為本的視角。《IEEE Transactions on Automation Science and Engineering》PP, 1-1 (2025) <https://doi.org/10.1109/TASE.2025.3528051>
- [42] Lasota, P.A., Song, T., Shah, J.A., (2017). <https://doi.org/10.1561/23000000052>
- [43] Hopko, S., Wang, J., Mehta, R.: Human factors considerations and metrics in shared space human-robot collaboration: A systematic review. *Frontiers in Robotics and AI* 9 (2022) <https://doi.org/10.3389/frobt.2022.799522>
- [44] Jiang, B., Gainer, C.: A cause-and-effect analysis of robot accidents. *Journal of Occupational Accidents* 9, 27-45 (1987)
- [45] El-Shamouty, M., Wu, X., Yang, S., Albus, M., Huber, M.F.: Towards safe human-robot collaboration using deep reinforcement learning. In: 2020 IEEE International Conference on Robotics and Automation (ICRA), pp. 4899-4905 (2020). <https://doi.org/10.1109/ICRA40945.2020.9196924>
- [46] Amaral, P., Silva, F., Santos, V.: Recognition of grasping patterns using deep learning for human-robot collaboration. *Sensors* 23(21) (2023) <https://doi.org/10.3390/s23218989>
- [47] Armeni, I., Sener, O., Zamir, A.R., Jiang, H., Brilakis, I., Fischer, M., Savarese, S.: 大型室內空間的 3D 語義解析。收錄於：2016 IEEE 電腦視覺與圖形辨識會議 (CVPR)，第 1534-1543 頁 (2016). <https://doi.org/10.1109/CVPR.2016.170>
- [48] Hackel, T., Savinov, N., Ladicky, L., Wegner, J.D., Schindler, K., Pollefeys, M.: [Semantic3d.net](https://www.semantic3d.net/): 一個新的大型點雲分類基準。CoRR abs/1704.03847 (2017)
- [49] Behley, J., Garbade, M., Milioto, A., Quenzel, J., Behnke, S., Stachniss, C., Gall, J.: Semantickitti: 用於光達序列語義場景理解的資料集。收錄於：IEEE/CVF 國際電腦視覺會議論文集，第 9297-9307 頁 (2019)
- [50] Munasinghe, C., Amin, F.M., Scaramuzza, D., Venn, H.W.: COVERED: 用於 3D 語義分割的協作機器人環境資料集。收錄於：2022 IEEE 第 27 屆新興技術與工廠自動化國際會議 (ETFA)，第 1-4 頁 (2022). <https://doi.org/10.1109/ETFA52439.2022.9921525>
- [51] Yi, L., Gong, B., Funkhouser, T.A.: Complete & label: A domain adaptation approach to semantic segmentation of lidar point clouds. CoRR (2020)
- [52] Jia, D., Hermans, A., Leibe, B.: Domain and modality gaps for lidar-based person detection on mobile robots. CoRR abs/2106.11239 (2021)
- [53] Langer, F., Milioto, A., Haag, A., Behley, J., Stachniss, C.: Domain transfer for semantic segmentation of lidar data using deep neural networks. In: 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS) (2020). <https://doi.org/10.1109/IROS45743.2020.9341508>
- [54] Zhao, S., Wang, Y., Li, B., Wu, B., Gao, Y., Xu, P., Darrell, T., Keutzer, K.: epointda: An end-to-end simulation-to-real domain adaptation framework for lidar point cloud segmentation. CoRR (2020)
- [55] Jiang, P., Saripalli, S.: Lidarnet: A boundary-aware domain adaptation model for lidar point cloud semantic segmentation. CoRR (2020)
- [56] Yin, C., Wang, B., Gan, V.J.L., Wang, M., Cheng, J.C.P.: Automated semantic segmentation of industrial point clouds using respointnet++. *Automation in Construction* 130, 103874 (2021) <https://doi.org/10.1016/j.autcon.2021.103874>
- [57] Chen, Z., Xu, H., Chen, W., Zhou, Z., Xiao, H., Sun, B., Xie, X., Kang, W.: PointDC: Unsupervised Semantic Segmentation of 3D Point Clouds via Crossmodal Distillation and Super-Voxel Clustering (2024)
- [58] Wu, C., Bi, X., Pfommer, J., Cebulla, A., Mangold, S., Beyerer, J.: Sim2real Transfer Learning for Point Cloud Segmentation: An Industrial Application Case on Autonomous Disassembly (2023)
- [59] NVIDIA: NVIDIA Isaac Sim. 存取日期：01.02.2024. <https://developer.nvidia.com/isaac/sim>

聲明

6.1 資助

本研究獲得蘇黎世高等教育機構數位化倡議（DIZH）的部分經費資助。

6.2 利益衝突

作者聲明無相關財務或非財務利益衝突。

6.3 出版同意書

作者確認，參與研究的人員已針對圖 2b 中影像的發佈提供知情同意書。

6.4 資料可用性

本研究所使用的部分資料集已公開，可於 <https://github.com/Fatemeh-MA/COVERED> 取得。模擬資料集與程式碼將在本文被接受後公開發佈。

¹ <https://github.com/Fatemeh-MA/COVERED>

² <https://youtu.be/nPzw3DoRVYA>

³ <https://youtu.be/oOLgQdzqvvQ>